Resumen - Cálculo Numérico

Marco Ciafardini

20 de diciembre de 2021

Índice

1 Capítulo 1 **4**
1.1 Métodos de 1 Paso . . . 7
1.1.1 Método de Euler . . . 7
1.1.2 Métodos de Taylor . . . 8
1.1.3 Métodos de Runge-Kutta . . . 11
1.2 Análisis del Error y Convergencia . . . 15
1.2.1 Errores de Truncamiento . . . 15
1.2.2 Convergencia . . . 18
1.3 Aplicación a Sistemas de Ecuaciones . . . 20
1.4 Métodos Multipaso Lineales . . . 21
1.5 Temas del Programa . . . 22

2 Capítulo 2 **23**
2.1 Ecuaciones de Segundo Orden . . . 23
2.2 Temas del programa . . . 24

3 Capítulo 3 **25**
3.1 Normas Matriciales y Número de Condición . . . 26
3.1.1 Normas Matriciales . . . 26
3.1.2 Número de Condición . . . 30
3.2 Métodos Directos . . . 39
3.2.1 Triangulación de Gauss . . . 39
3.2.2 Descomposición LU . . . 40
3.2.3 Descomposición $PA = LU$ . . . 45
3.2.4 Descomposición de Cholesky $A = LL^T$ . . . 45
3.3 Métodos Indirectos . . . 46
3.3.1 Método de Jacobi . . . 46
3.3.2 Método de Gauss-Seidel . . . 46
3.4 Temas del Programa . . . 47

4 Capítulo 6 **48**
4.1 Bisección . . . 48

4.2 Regula Falsi 52
4.3 Punto Fijo 53
4.3.1 Generalidades 53
4.3.2 Método 55
4.4 Newton-Raphson 59
4.5 Secante 63
4.6 Temas del programa 64

Capítulo 1

Capítulo 1

Definición (Ecuación Diferencial Ordinaria)
Sea $F : \mathbb{R}^{n+2} \to \mathbb{R}$ conocida.
Decimos que

$$F\left(x(t), x'(t), x''(t), \cdots, x^{(n)}(t), t\right) = 0 \qquad t \in \mathbb{R}$$

es una *ecuación diferencial ordinaria* (EDO) para $x(t)$.

Definición (Orden)
Definimos el *orden* de una EDO como el máximo orden de derivada que aparezca en ella.

Supongamos que de la ecuación diferencial se puede despejar la derivada de mayor orden. Es decir,

$$x^{(n)}(t) = f\left(x(t), x'(t), \cdots, x^{(n-1)}(t), t\right) \qquad t \in \mathbb{R}$$

con $f : \mathbb{R}^{n+1} \to \mathbb{R}$.

Como ya sabemos, las ecuaciones diferenciales de orden n pueden reescribirse como un sistema de n EDO de orden 1. Como los métodos que presentaremos pueden extenderse a estos sistemas, los estudiaremos en EDOs de orden 1.

$$\begin{cases} x'(t) = f\left(x(t), t\right) & t \geq t_0 \\ x(t_0) = x_0 \end{cases}$$

Definición (Lipschitz)
Sea $f : \mathbb{R} \to \mathbb{R}$.

Decimos que f es *Lipschitz* si se tiene $\forall x_1, x_2 \in \mathbb{R}$

$$|f(x_1) - f(x_2)| \leq K|x_1 - x_2| \tag{1.1}$$

También decimos que g es λ-*Lipschitz*.

Definición (Conjunto Convexo)
Sea $D = \{(t, x)\} \subset \mathbb{R}^2$.
Decimos que D es *convexo* si todo par de elementos puede unirse por una recta.
Es decir, $\forall (t_1, x_2) \wedge (t_2, x_2)$

$$\big((1-\lambda)t_1 + \lambda t_2, (1-\lambda)x_1 + \lambda x_2\big) \in D \qquad \forall \lambda \in [0, 1]$$

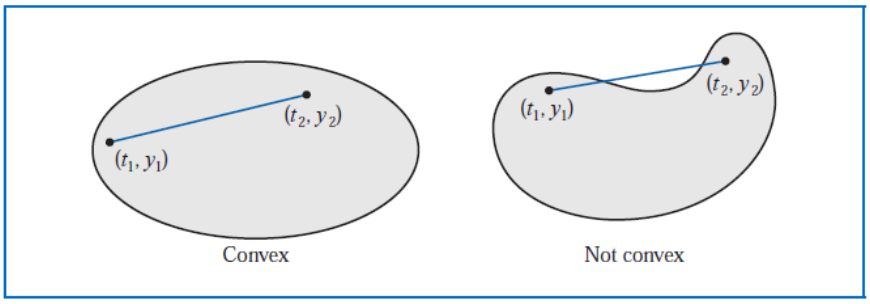

Figura 1.1: Interpretación Geométrica de la definición. En el la figura, y es lo que llamamos x. (Recuperado de [**?**].)

Proposición 1.1 (Condición Suficiente para Lipschitz)
Sea $f : D \to \mathbb{R}$.
Si

$$\left|\frac{\partial f}{\partial x}\right| \leq L \qquad \forall (t, y) \in D$$

Entonces, f es x-Lipschitz en D con L como constante de Lipschitz.

Teorema 1.2 (de Picard-Lindelöf (Existencia y Unicidad))
Sea $I \subset \mathbb{R}$.
Sea $f : \mathbb{R}^2 \to \mathbb{R}$

- continua
- x-Lipschitz $\forall t \in I$.

Entonces, $\forall x_0 \in \mathbb{R}, \exists!\, x(t) : I \to \mathbb{R}$ derivable /

$$\begin{cases} x'(t) = f\left(x(t), t\right) & \forall t \in I \\ x(t_0) = x_0 \end{cases}$$

De ahora en más, consideraremos f x-Lipschitz con constante de Lipschitz L.

Agregar: Estabilidad - Well-posed Problem

1.1 Métodos de 1 Paso

$$\begin{cases} x'(t) = f\left(x(t), t\right) & \forall t \in I \\ x(t_0) = x_0 \end{cases}$$

Buscamos una aproximación **discreta** para $x(t)$ en un intervalo $[t_0, T]$.

Dividimos el intervalo en N valores equiespaciados $\{t_i\}$ con

$$t_i = t_0 + ih \qquad i = 0, \cdots, N$$

con $h = \frac{T-t_0}{N}$ el *paso*.

Buscamos un conjunto de valores $\{x_i\}_{i=0,\cdots,N}$ que aproximen a los valores $\left\{x_(t_i)\right\}_{i=0,\cdots,N}$. Para obtener una aproximación **continua** se puede usar un método de interpolación.

Los métodos de 1 paso tiene las forma

$$x_{i+1} = x_i + h\Phi\left(x_i, t_i, h\right)$$

donde la función Φ se conoce como la *función incremento*.

1.1.1 Método de Euler

Haciendo un desarrollo de Taylor de $x(t)$ alrededor de t_i y evaluando en t_{i+1}, se tiene

$$x(t_{i+1}) = x(t_i) + x'(t_i)(t_{i+1} - t_i) + x''(\xi_i)\frac{(t_{i+1} - t_i)^2}{2}$$

con $\xi_i \in (t_i, t_{i+1})$. Como $h = t_{i+1} - t_i$,

$$= x(t_i) + x'(t_i)h + x''(\xi_i)\frac{h^2}{2}$$

Como $x(t)$ satisface la ecuación diferencial,

$$x(t_{i+1}) = x(t_i) + f\left(x(t_i), t_i\right)h + x''(\xi_i)\frac{h^2}{2}$$

Para construir el método de Euler, despreciamos último término.

$$x(t_{i+1}) \approx x(t_i) + hf\left(x(t_i), t_i\right)$$
$$\boxed{x_{i+1} = x(t_i) + hf\left(x(t_i), t_i\right)}$$

Notemos que, en el método de Euler, la función incremento está dada por

$$\Phi(x_i, t_i, h) = f(x_i, t_i)$$

- Pros
  - Bajo coste computacional.
- Contras
  - Estamos despreciando un término de $O(h^2)$ en cada iteración.

1.1.2 Métodos de Taylor

En el método de Euler, nos quedamos con el desarrollo de Taylor en orden 1, pero podríamos afinar la aproximación quedándonos en un orden superior.

Haciendo un desarrollo de Taylor de $x(t)$ alrededor de t_i y evaluando en t_{i+1}, se tiene

$$x(t_{i+1}) = x(t_i) + x'(t_i)(t_{i+1} - t_i) + x''(t_i)\frac{(t_{i+1} - t_i)^2}{2} + \cdots + x^{k+1}(\xi_i)\frac{(t_{i+1} - t_i)^{k+1}}{(k+1)!}$$

con $\xi_i \in (t_i, t_{i+1})$. El último término lo hacemos corresponer con la potencia $k+1$ por comodidad. Como $h = t_{i+1} - t_i$,

$$= x(t_i) + x'(t_i)h + x''(\xi_i)\frac{h^2}{2} + \cdots + x^{k+1}(\xi_i)\frac{h^{k+1}}{(k+1)!}$$

Derivadas Superiores

Para poder seguir necesitamos las derivadas de orden superior de $x(t)$. Podemos obtenerlas a partir de $x'(t) = f(x(t), t)$ y la Regla de la Cadena.

$$x^j(t) = \frac{\mathrm{d}^j}{\mathrm{d}t^j}x(t)$$

$$\boxed{x^j(t) = \frac{\mathrm{d}^{j-1}}{\mathrm{d}t^{j-1}}f(x,t)}$$

Para $x''(t)$, se tiene

$$\begin{aligned} x''(t) &= \frac{\mathrm{d}}{\mathrm{d}t}x'(t) \\ &= \frac{\mathrm{d}}{\mathrm{d}t}f(x(t), t) \\ &= \frac{\partial}{\partial t}f(x,t) + \frac{\partial}{\partial x}f(x,t)\frac{\mathrm{d}x}{\mathrm{d}t} \\ &= \frac{\partial}{\partial t}f(x,t) + \frac{\partial}{\partial x}\left(f(x,t)\right)f(x,t) \end{aligned}$$

En una notación más compacta,

$$\boxed{x''(t) = f_t(x,t) + f_x(x,t)f(x,t)}$$

De la misma forma, podemos obtener $x'''(t)$.

$$\boxed{\begin{aligned} x'''(t) &= f_{tt}(x,t) + 2f_{tx}(x,t)f(x,t) + f_{xx}(x,t)\left[f(x,t)\right]^2 \\ &\quad + f_x\left[f_t(x,t)) + f_x(x,t)f(x,t)\right] \end{aligned}}$$

Nota: Notación

Notamos a la derivada j-ésima total respecto de t de f como

$$D^j f(x,t) = \frac{\mathrm{d}^j}{\mathrm{d}t^j} f(x,t)$$

$$x(t_{i+1}) = x(t_i) + \sum_{j=1}^{k} \frac{h^j}{j!} D^{j-1} f(x,t) + x^{k+1}(\xi_i)\frac{h^{k+1}}{(k+1)!}$$

Definimos $T_k(t,x,h) \equiv \sum_{j=1}^{k} \frac{h^{j-1}}{j!} D^{j-1} f(x,t)$.

$$x(t_{i+1}) = x(t_i) + hT_k(x_i,t_i,h) + x^{k+1}(\xi_i)\frac{h^{k+1}}{(k+1)!}$$

Para construir un método de Taylor de orden k, despreciamos último término.

$$x(t_{i+1}) \approx x(t_i) + hT_k(x_i,t_i,h)$$

$$\boxed{x_{i+1} = x(t_i) + hT_k(x_i,t_i,h)}$$

Notemos que, en un método de Taylor de orden k, la función incremento está dada por

$$\Phi(x,t,h) = T_k(x,t,h)$$

lo que explica la definición de T anterior.

Observación:

El método de Euler no es más que un método de Taylor de orden 1.

- Pros
  - Estamos despreciando un término de $O(h^{k+1})$ (mucho menor que en Euler) en cada iteración.
- Contras
  - Alto coste computacional: tenemos que calcular todas las derivadas.
  - Tenemos que calcular la expresión de las derivadas

Duda:

Este es un problema mío. Se debe poder (puede) dar una expresión para la derivada k-ésima.

1.1.3 Métodos de Runge-Kutta

Runge (1896) y Kutta (1901) proponen reemplazar $T_k(x,t,h)$ por otra función incremento $\Phi(x,t,h)$ que resulte en aproximaciones del mismo orden pero para la que no se necesite calcular las derivadas de f.

Para un método de Taylor se tiene

$$x(t+h) = x(t) + hT_k(x,t,h) + O\left(h^{k+1}\right)$$

Para la función $\Phi_k(x,t,h)$ se tiene que cumplir, entonces,

$$x(t+h) = x(t) + h\Phi_k(x,t,h) + O\left(h^{k+1}\right)$$

Restando ambas ecuaciones, se tiene

$$\begin{aligned} 0 &= hT_k(x,t,h) - h\Phi_k(x,t,h) + O\left(h^{k+1}\right) \\ \cancel{h}\left[T_k(x,t,h) - \Phi_k(x,t,h)\right] &= O\left(h^{\cancel{k+1}}\right) \\ \boxed{T_k(x,t,h) - \Phi_k(x,t,h) = O\left(h^k\right)} \end{aligned}$$

Se propone una función Φ_k

$$\boxed{\Phi_k(x,t,h) = A_1 f(\gamma_1,\theta_1) + \cdots + A_N f(\gamma_N,\theta_N)}$$

con γ y θ funciones de x,t,h y un(os) parámetro(s) tales que evaluadas en $h=0 \implies \gamma = x \wedge \theta = t$. Es decir, γ,θ son puntos cercanos a x,t.

Duda:

Esta descripción es mía, no la saqué de ningún lado.

Observación
Puede demostrarse que $\exists\, \Phi_k \forall k$. Además,

$$N_{\text{mín}} = \begin{cases} k & k = 1,2,3,4 \\ k+1 & k = 5,6 \\ k+2 & k \geq 7 \end{cases}$$

Método de Runge-Kutta de orden 2

Agregar: Derivación histórica de Runge

Integrando

Proponemos

$$\boxed{\Phi_2(x,t,h) = A_1 f(x,t) + A_2 f(x + \alpha h f(x,t), t + \alpha h)}$$

Es decir, $N = 2$ y

$$\begin{cases} \theta_1 = t \\ \gamma_1 = x \\ \theta_2 = t + h\alpha \\ \gamma_2 = x + h\alpha f(x,t) \end{cases}$$

$$\begin{aligned} A &= T_2(x,t,h) - \Phi_2(x,t,h) \\ &= D^0 f(x,t) + \frac{h}{2} D^1 f(x,t) \\ &- A_1 f(x,t) - A_2 f(x + \alpha h f(x,t), t + \alpha h) \\ &= f(x,t) + \frac{h}{2}\frac{\mathrm{d}}{\mathrm{d}t} f(x,t) \\ &- A_1 f(x,t) - A_2 f(x + \alpha h f(x,t), t + \alpha h) \end{aligned}$$

Haciendo un Desarrollo de Taylor en $h = 0$,

$$\begin{aligned} &= f(x,t) + \frac{h}{2}\frac{\mathrm{d}}{\mathrm{d}t} f(x,t) \\ &- A_1 f(x,t) - A_2 \left[f(x,t) + h \left(\frac{\partial}{\partial t} f(x,t) \frac{\mathrm{d}}{\mathrm{d}h}(t + \alpha h) + \frac{\partial}{\partial x} f(x,t) \frac{\mathrm{d}}{\mathrm{d}h}(x + \alpha h f(x,t)) \right) + O\left(h^2\right) \right] \\ &= f(x,t) + \frac{h}{2}\frac{\mathrm{d}}{\mathrm{d}t} f(x,t) \\ &- A_1 f(x,t) - A_2 \left[f(x,t) + h\big(f_t(x,t)\alpha + f_x(x,t)\alpha f(x,t)\big) + O\left(h^2\right) \right] \\ &= f(x,t) + \frac{h}{2}\frac{\mathrm{d}}{\mathrm{d}t} f(x,t) \\ &- A_1 f(x,t) - A_2 \left[f(x,t) + h\alpha \frac{\mathrm{d}}{\mathrm{d}t} f(x,t) + O\left(h^2\right) \right] \end{aligned}$$

Reagrupando según la potencia de h,

$$A = \Big(1 - A_1 - A_2\Big) f(x,t) + h \left(\frac{\mathrm{d}}{\mathrm{d}t} f(x,t) \right) \left[\frac{1}{2} - A_2 \alpha \right] + O\left(h^2\right)$$

$$\boxed{T_2(x,t,h) - \Phi_2(x,t,h) = \Big(1 - A_1 - A_2\Big) f(x,t) + \left[\frac{1}{2} - A_2\alpha\right] h\frac{\mathrm{d}}{\mathrm{d}t} f(x,t) + O\left(h^2\right)}$$

Para que la diferencia sea de orden $O(h^2)$, los coeficientes de los órdenes menores deben anularse.

$$\begin{cases} 1 - A_1 - A_2 = 0 \\ \dfrac{1}{2} - A_2\alpha = 0 \end{cases}$$

$$\begin{cases} A_1 + A_2 = 1 \\ A_2\alpha = \dfrac{1}{2} \end{cases}$$

$$\boxed{\begin{cases} A_1 = 1 - \dfrac{1}{2\alpha} \\ A_2 = \dfrac{1}{2\alpha} \end{cases}}$$

$$\boxed{\Phi_2(x,t,h) = \left(1 - \frac{1}{2\alpha}\right) f(x,t) + \frac{1}{2\alpha} f(x + \alpha h f(x,t), t + \alpha h)} \tag{1.2}$$

Nota:

A partir de ahora, voy a invertir los argumentos de f.

$$f(x,t) \to f(t,x)$$

Es decir, para cada valor de α tenemos un método de Runge-Kutta de orden 2. Algunos de ellos son:

- Método de Euler Modificado
  $\alpha = \frac{1}{2} \implies A_1 = 0 \wedge A_2 = 1$

$$x_{i+1} = x_i + \frac{h}{2}\left[f\Big(t_i + \frac{h}{2}, x_i + \frac{h}{2} f(t_i, x_i)\Big)\right] \tag{1.3}$$

- Método de Heun (1900)
  $\alpha = 1 \implies A_1 = A_2 = \frac{1}{2}$

$$x_{i+1} = x_i + \frac{h}{2}\left[f\big(t_i, x_i\big) + f\big(t_i, x_i + h f(t_i, x_i)\big)\right] \tag{1.4}$$

Agregar: Interpretación Geométrica

No lo estoy visualizando.

Método de Runge-Kutta de orden 4

$$x_{i+1} = x_1 + \frac{h}{6}\left(K_1 + 2K_2 + 2K_3 + K_4\right)$$

con

$$\begin{cases} K_1 = f\left(t, x\right) \\ K_2 = f\left(t + \frac{h}{2}, x + \frac{h}{2}K_1\right) \\ K_3 = f\left(t + \frac{h}{2}, x + \frac{h}{2}K_2\right) \\ K_4 = f\left(t + \frac{h}{2}, x + \frac{h}{2}K_3\right) \end{cases}$$

Método de Runge-Kutta de orden k

1.2 Análisis del Error y Convergencia

Nota:

Esta sección tiene aplicaciones en otros capítulos.

1.2.1 Errores de Truncamiento

Error de Truncamiento Local

Definición (Error de Truncamiento Local)
Se define el *error de truncamiento local* τ_i como el error que se comete al aproximar $x(t_i + h)$ dado $x(t_i)$. Es decir

$$x(t_i + h) = x(t_i) + h\Phi(t_i, x(t_i, h) + h\tau_i$$

$$\boxed{\tau_i(t_i, x(t_i), h) = \frac{x(t_i + h) - x(t_i)}{h} + \Phi(t_i, x(t_i, h)} \tag{1.5}$$

Definición (Orden del Método)
Decimos que un método es de *orden* k si se tiene

$$\tau = O\left(h^k\right) \tag{1.6}$$

Duda:

Supongo que esto es si $\max_i \tau_i = O\left(h^k\right)$

Proposición 1.3 (Error de Truncamiento Local de un Método de Taylor)
El error de truncamiento local de un método de Taylor de orden k es

$$\tau = \frac{h^k}{(k+1)!} x^{(k+1)}(\xi) \qquad \xi \in (t, t+h)$$

Efectivamente, es un método de orden k.

Demostración.

Se sigue de la fórmula del resto para un desarrollo de Taylor. ■

Nota:

Para acotar una derivada, calculamos la derivada con la Regla de la Cadena y acotamos $x(t)$ con el Teorema del Valor Medio de Lagrange.

Proposición 1.4 (Orden de un Método de Runge-Kutta)
El error de truncamiento local de un método de Runge-Kutta de orden k verifica

$$\tau = O\left(h^k\right)$$

Demostración.

Por definición del método de Runge-Kutta. ■

Error de Truncamiento Global

Definición (Error de Truncamiento Global)
Se define como *error de truncamiento global* al error que se comete en la aproximación del i-ésimo punto. Es decir,

$$e_i := x(t_i) - x_i \tag{1.7}$$

Lema 1.1

$$0 \leq (1+x)^n \leq e^{nx} \qquad \forall x \geq -1 \wedge m \geq 0$$

Teorema 1.5 (Cota para el Error de Truncamiento Global)
Sea la función incremento $\Phi(t, x, h)$ x-Lipschitz con constante de Lipschitz K. Entonces,

$$\boxed{|e_i| \leq \frac{\tau_{\text{máx}}}{K}\left(e^{K(t_i - t_0} - 1\right)} \tag{1.8}$$

Demostración.

$$\begin{cases} x(t_{i+1}) = x(t_i) + h\Phi(t_i, x(t_i), h) + h\tau_i \\ \quad x_{i+1} = x_i \quad\;\; + h\Phi(t_i, x_i \quad , h) \end{cases}$$

Restando ambas ecuaciones y tomando el módulo,

$$|x(t_{i+1}) - x_{i+1}| = |x(t_i) - x_i + h\left(\Phi(t_i, x(t_i), h) - \Phi(t_i, x_i, h)\right) + h\tau|$$

Por la Desigualdad Triangular,

$$|e_{i+1}| \leq |e_i| + h|\Phi(t_i, x(t_i), h) - \Phi(t_i, x_i, h)| + h|\tau_i|$$

Como Φ es x-Lipschitz,

$$\begin{aligned}
&\leq |e_i| + hK|x(t_i) - x_i| + h|\tau_i| \\
&\leq |e_i| + hK|e_i| + h|\tau_i| \\
&\boxed{|e_{i+1}| \leq (1 + hK)\,|e_i| + h|\tau_i|}
\end{aligned}$$

Nos conviene acotar $|\tau_i| \leq \tau_{\text{máx}}$ para poder reescribir la relación de recurrencia como

$$\boxed{|e_{i+1}| \leq (1 + hK)\,|e_i| + h\tau_{\text{máx}}}$$

Definimos $A \equiv (1 + hK)$.

$$\begin{aligned}
|e_i| &\leq A|e_{i-1}| + h\tau_{\text{máx}} \\
&\leq A\left(A|e_{i-2}| + h\tau_{\text{máx}}\right) + h\tau_{\text{máx}} \\
&\vdots \\
&\leq \left(A^{n-1} + \cdots + A + 1\right) h\tau_{\text{máx}} \\
&\leq h\tau_{\text{máx}} \sum_{j=1}^{i} A^{j-1}
\end{aligned}$$

Por la fórmula para la suma de los primeros términos de una progresión geométrica,

$$\begin{aligned}
&\leq h\tau_{\text{máx}} \frac{A^i - 1}{A - 1} \\
&\leq h\tau_{\text{máx}} \frac{(1 + hK)^i - 1}{(\cancel{1} + hK) - \cancel{1}} \\
&\leq \cancel{h}\tau_{\text{máx}} \frac{(1 + hK)^i - 1}{\cancel{h}K)} \\
&\leq \frac{\tau_{\text{máx}}}{K}\left[(1 + hK)^i - 1\right]
\end{aligned}$$

Por el Lema 1.1,

$$|e_i| \leq \frac{\tau_{\text{máx}}}{K}\left(e^{K\cancel{ih}^{\,t_i - t_0}} - 1\right)$$

$$\boxed{|e_i| \leq \frac{\tau_{\text{máx}}}{K}\left(e^{K(t_i - t_0)} - 1\right)}$$

■

Corolario 1.5.1 (Cota para el Error de Truncamiento Global en el Método de Euler)
Sea

$$|x''(t)| \leq M$$

Entonces,

$$|e_i| \leq \frac{hM}{2L}\left(e^{L(t_i - t_0)} - 1\right)$$

Observación: Órdenes de los Errores Globales para distintos métodos

- Euler: $O(h)$.
- Heun: $O(h^2)$.
- Runge-Kutta de orden k: $O\left(h^k\right)$.

Nota:

Recordar que "de orden k" hace referencia al error de truncamiento **local**.

1.2.2 Convergencia

Definición (Convergencia)
Decimos que un método es *convergente* si se tiene

$$\lim_{h \to 0} x(t_n) - x_n = 0 \tag{1.9}$$

Definición (Consistencia)
Decimos que un método es *consistente* si se tiene

$$\lim_{h \to 0} \tau_{\text{máx}} = 0 \tag{1.10}$$

Corolario 1.5.2 (Consistencia $\implies$ Convergencia)
Si un método es consistente, entonces es convergente. Es decir,

$$\lim_{h \to 0} \tau_{\text{máx}} = 0 \implies \lim_{h \to 0} x(t_n) - x_n = 0$$

Demostración.

Se deduce del Teorema 1.5. ■

Teorema 1.6 (Equivalencia Consistencia)
Un método es consistente sí y solo sí se tiene

$$\Phi(t, x, 0) = f(t, x)$$

Nota: Teorema de Lax

La relación entre Convergencia, Consistencia y Estabilidad está dada por el Teorema de Lax.

Si un método es consistente y estable, entonces es convergente.

Duda:

Arriba dijimos que Consistencia implica Convergencia por el Teorema 1.5. Será que el que la función de incremento Φ sea Lipschitz (es decir que se cumplan las condiciones del Teorema), implica estabilidad.

1.3 Aplicación a Sistemas de Ecuaciones

1.4 Métodos Multipaso Lineales

1.5 Temas del Programa

Capítulo 2

Capítulo 2

Vamos a abordar este problema reduciéndolo a un problema de valor iniciales. A este método se lo conoce como *shooting method*.

2.1 Ecuaciones de Segundo Orden

Consideraremos EDO de segundo orden (suponiendo que podemos despejar la derivada segunda)

$$y''(x) = f\left(x, y(x), y'(x)\right)$$

Teorema 2.1 (de Existencia y Unicidad)
Sea una EDO de segundo orden

$$y''(x) = f\left(x, y(x), y'(x)\right)$$

con $f : I \times \mathbb{R} \times \mathbb{R} \to \mathbb{R}$ /

- $$\frac{\partial f}{\partial y} > 0$$
- $$\left|\frac{\partial f}{\partial y'}\right| \leq M$$

Entonces, la EDO tiene una única solución.

Ecuaciones de Segundo Orden Lineales

$$u''(x) = p(x)u'(x)$$

2.2 Temas del programa

Capítulo 3

Capítulo 3

Nota:

Consideraremos, a menos que se indique lo contario, que $\mathbb{K} = \mathbb{R}^n$ o $\mathbb{K} = \mathbb{C}$. También consideramos que $\mathbb{K}^n$ es un $\mathbb{K}$-espacio vectorial.

Nota:

Al elementro neutro de un espacio vectorial lo notamos O o, simplemente, 0.

3.1 Normas Matriciales y Número de Condición

3.1.1 Normas Matriciales

Definición (Norma)
Sea V un $\mathbb{K}$-espacio vectorial.
Sea $\|\cdot\| : V \to \mathbb{R}$ un operador.
Decimos que $\|\cdot\|$ es una *norma* si se tiene

(a)
$$\begin{aligned} \|x\| &> 0 && \forall x \neq O && \text{(Positividad)} \\ \|x\| &= 0 && \text{si } x = O && (3.1) \end{aligned}$$

(b)
$$\|cx\| = |c|\|x\| \qquad \text{(Homogeneidad)}$$

(c) Desigualdad Triangular:

$$\|x + y\| \leq \|x\| + \|y\| \qquad \text{(Desigualdad Triangular)}$$

Definición (p-normas)
Se definen las *p-normas* como

$$\|x\|_p := \left(\sum_i |x_i|^p \right)^{\frac{1}{p}} \qquad \forall p \in \mathbb{R}_{\geq 1} \tag{3.2}$$

Definición (Equivalencia)
Sea V un espacio vectorial.
Sean $\|\cdot\|$ y $\|\cdot\|'$ dos normas en V.
Decimos que son *equivalentes* si se tiene, $\forall x \in V$

$$c\|x\| \leq \|x\|' \leq C\|x\| \tag{3.3}$$

Teorema 3.1 (Equivalencia de Normas)
Todo par de normas en $\mathbb{K}^n$ es equivalente.

Demostración.

Basta con demostrar que toda norma es equivalente a $\|\cdot\|_2$.

Segunda desigualdad: $\|x\| \leq C\|x\|_2$.

Definamos

$$C \equiv \left(\sum_{i=1}^{n} \hat{\mathbf{e}_\mathbf{i}}^2\right)^{\frac{1}{2}}$$

donde $\{\hat{\mathbf{e}_\mathbf{i}}\}_{i=1\cdots n}$ es la base canónica de $\mathbb{K}^n$.

Para $x \in V$, tenemos

$$\|x\| = \left\|\sum_{i=1}^{n} x_i \hat{\mathbf{e}_\mathbf{i}}\right\|$$

Por la Ecuación Desigualdad Triangular,

$$\leq \sum_{i=1}^{n} \|x_i \hat{\mathbf{e}_\mathbf{i}}\|$$

Por la Ecuación Homogeneidad,

$$\leq \sum_{i=1}^{n} |x_i| \|e_i\|$$

Como $|x_i|, \|e_i\| \in \mathbb{K}$, podemos ver al miembro de arriba como el producto vectorial $\langle \cdot,\cdot \rangle_2$ entre los vectores $a = (|x_1|, \cdots, |x_n|)$ y $b = (\|\hat{\mathbf{e_1}}\|, \cdots, \|\hat{\mathbf{e_n}}\|)$ en $\mathbb{K}^n$.

$$\leq \langle a,b \rangle_2$$

Aplicando la Desigualdad de Cauchy-Schwarz,

$$\leq \|\mathbf{a}\|_2 \|\mathbf{b}\|_2$$

$$\leq \left(\sum_{i=1}^{n} |x_i|^2\right)^{\frac{1}{2}} \underbrace{\left(\sum_{i=1}^{n} \|\hat{\mathbf{e}_\mathbf{i}}\|^2\right)^{\frac{1}{2}}}_{C}$$

$$\boxed{\|x\| \leq C\|x\|_2}$$

Primera desigualdad: $c\|x\|_2 \leq \|x\|$.

Supongamos que

$$\nexists K \ / \ \|x\|_2 \leq K\|x\|$$

Agregar: Terminar

Me aburrí.

■

Agregar:

Ejemplos de relaciones de equivalencia para las p-normas.

Definición (Norma Matricial)
Sea $\|\cdot\| : \mathbb{K}^{m\times n} \to \mathbb{R}$.
Decimos que $\|\cdot\|$ es una *norma matricial* si se tiene

(a) $\forall A \in \mathbb{K}^{m\times n}$,

$$\|A\| > 0 \qquad \forall A \neq O \qquad \text{(Positividad)}$$
$$\|A\| = 0 \iff A = O \qquad (3.4)$$

2

(b) $\forall A \in \mathbb{K}^{m\times n} \wedge c \in \mathbb{K}$,

$$\|cA\| = |c|\|A\| \qquad \text{(Homogeneidad)}$$

(c) Desigualdad Triangular.
$\forall A, B \in \mathbb{K}^{m\times n}$,

$$\|A + B\| \leq \|A\| + \|B\| \qquad \text{(Desigualdad Triangular)}$$

Definición (Norma Inducida)
Sean $\|\cdot\|_a$ y $\|\cdot\|_b$ normas en $\mathbb{K}^m$ y $\mathbb{K}^n$, respectivamente.
Sea $x \in \mathbb{K}^n$
Sea $A \in \mathbb{K}^{m\times n}$.
Se define la *norma inducida* correspondiente en $\mathbb{K}^{m\times n}$ como

$$\|A\|_{a,b} := \sup_{\|x\|_a \neq 0} \left\{ \frac{\|Ax\|_b}{\|x\|_a} \right\}$$

En caso que tengamos $\|\cdot\|_a = \|\cdot\|_b \equiv \|\cdot\|$,

$$\begin{aligned} \|A\| &:= \sup_{\|x\|\neq 0} \left\{ \frac{\|Ax\|}{\|x\|} \right\} \\ &= \sup_{\|x\|=1} \{\|Ax\|\} \end{aligned}$$

En el caso que tengamos, además, $m = n$,

$$\begin{aligned} \|A\| &:= \max_{\|x\|\neq 0} \left\{ \frac{\|Ax\|}{\|x\|} \right\} \\ &= \max_{\|x\|=1} \{\|Ax\|\} \end{aligned}$$

Duda:

Es posible que definiciones ser imprecisas (como eufemismo de "incorrectas"): algún $\sup$ podría ser un $\max$, o viceversa. También es posible que las dos definiciones (entiendo que equivalentes) no apliquen en todos los casos.
Me quedo con la última definición, que es como la enunciamos en clase.

Propiedades (de las Normas Inducidas)
Veamos algunas propiedades de las normas inducidas.
Sean $A \in \mathbb{K}^{m\times n}$.

- Las normas inducidas son normas matriciales.

- $$\|Ax\|_b \leq \|A\|_{a,b}\|x\|_a \tag{3.5a}$$

  Demostración.

  En el caso $\|x\|_a = 0$ se cumple trivialmente. Consideremos $\|x\|_a \neq 0$.

  $$\frac{\|Ax\|_b}{\|x\|_a} \leq \max_{\|x\|_a\neq 0} \left\{ \frac{\|Ax\|_b}{\|x\|_a} \right\}$$

  Por la definición de Norma Inducida,

  $$\begin{aligned} \frac{\|Ax\|_b}{\|x\|_a} &\leq \|A\|_{a,b} \\ \|Ax\|_b \frac{\|Ax\|_b}{\|x\|_a} &\leq \|A\|_{a,b}\|x\|_a \end{aligned}$$

  ■

- Norma del Producto.
  Sean $A, B \in \mathbb{K}^{n\times n}$.

  $$\|AB\| \leq \|A\|\|B\| \tag{3.5b}$$

Agregar:

Ejemplos de normas matriciales inducidas.

Ejemplo (de una Norma Matricial No Inducida)
Se define la *norma de Frobenius* o *norma de Hilbert-Schmidt* como

$$\begin{aligned} \|A\|_F &:= \left(\mathrm{Tr}\left(AA^T\right)\right)^{\frac{1}{2}} \\ &= \left(\sum_{i,j} |a_{ij}|\right)^{\frac{1}{2}} \end{aligned} \tag{3.6}$$

Agregar:

Ejemplos de relaciones de equivalencia para la norma de Frobenius.

3.1.2 Número de Condición

Nota:

La definición que vamos a ver no es la definición más general (que aplica a todo tipo de funciones).

Definición (Número de Condición)
Sea $A \in \mathbb{K}^{n\times n}$ una matriz invertible.
Sea $\|\cdot\|$ una norma en $\mathbb{K}^n$.
Se define el *número de condición* de A como

$$\mathrm{Cond}(A) \equiv \kappa := \|A\|\left\|A^{-1}\right\| \tag{3.7}$$

Observación
El número de condición depende de la norma.

Propiedades (del Número de Condición)
Veamos algunas propiedades del número de condición.
Sea $A \in \mathbb{K}^{n\times n}$ una matriz invertible.
Sea $\|\cdot\|$ una norma en $\mathbb{K}^n$.

- $$\mathrm{Cond}(A) = \mathrm{Cond}(A^{-1}) \tag{3.8a}$$

  Demostración.

  $$\begin{cases} \mathrm{Cond}(A) = \|A\|\|A^{-1}\| \\ \mathrm{Cond}(A^{-1}) = \|A^{-1}\|\|A\| \end{cases}$$
  $$\implies \mathrm{Cond}(A) = \mathrm{Cond}(A^{-1})$$

  ■

- $$\mathrm{Cond}(A) \geq 1 \tag{3.8b}$$

  Demostración.

  $$\mathrm{Cond}(A) = \|A\|\|A^{-1}\|$$

  Por la **??**,

  $$\begin{aligned} &\geq \|AA^{-1}\| \\ &\geq \|\mathbb{1}\| \\ \mathrm{Cond}(A) &\geq 1 \end{aligned}$$

  ■

¿Para qué sirve?

Sirve para acotar errores. Veamos algunos teoremas.

Teorema 3.2
Sea $A \in \mathbb{K}^{n\times n}$ invertible.
Sean $x, \Delta x, b, \Delta b \in \mathbb{K}^n$ /

$$\begin{cases} Ax = b \\ A(x + \Delta x) = b + \Delta b \end{cases}$$

Entonces,

$$\frac{1}{\mathrm{Cond}(A)}\frac{\|\Delta b\|}{\|b\|} \leq \frac{\|\Delta x\|}{\|x\|} \leq \mathrm{Cond}(A)\frac{\|\Delta b\|}{\|b\|} \tag{3.9a}$$

Alternativamente, podemos reescribirla como

$$\frac{1}{\mathrm{Cond}(A)}\frac{\|\Delta x\|}{\|x\|} \leq \frac{\|\Delta b\|}{\|b\|} \leq \mathrm{Cond}(A)\frac{\|\Delta x\|}{\|x\|} \tag{3.9b}$$

Demostración.

- $$\boxed{\frac{\|\Delta x\|}{\|x\|} \leq \mathrm{Cond}(A)\frac{\|\Delta b\|}{\|b\|}}$$

$$\begin{aligned} A(x+\Delta x) &= b + \Delta b \\ \cancel{Ax} + A\Delta x &= \cancel{b} + \Delta b \\ \Delta x &= A^{-1}\Delta b \\ \|\Delta x\| &= \left\|A^{-1}\Delta b\right\| \end{aligned}$$

Por la **??**,

$$\begin{aligned} \|\Delta x\| &\leq \left\|A^{-1}\right\|\|\Delta b\| \\ \frac{\|\Delta x\|}{\|x\|} &\leq \left\|A^{-1}\right\|\frac{1}{\|x\|}\|\Delta b\|\frac{\|b\|}{\|b\|} \\ &\leq \left\|A^{-1}\right\|\frac{\|b\|}{\|x\|}\frac{\|\Delta b\|}{\|b\|} \\ &\leq \left\|A^{-1}\right\|\frac{\|Ax\|}{\|x\|}\frac{\|\Delta b\|}{\|b\|} \end{aligned}$$

Por la **??**,

$$\begin{aligned} &\leq \left\|A^{-1}\right\|\frac{\|A\|\cancel{\|x\|}}{\cancel{\|x\|}}\frac{\|\Delta b\|}{\|b\|} \\ &\leq \left\|A^{-1}\right\|\|A\|\frac{\|\Delta b\|}{\|b\|} \end{aligned}$$

$$\boxed{\frac{\|\Delta x\|}{\|x\|} \leq \mathrm{Cond}(A)\frac{\|\Delta b\|}{\|b\|}}$$

- $$\boxed{\frac{1}{\mathrm{Cond}(A)}\frac{\|\Delta b\|}{\|b\|} \leq \frac{\|\Delta x\|}{\|x\|}}$$

$$\begin{cases} Ax = b \\ A(x+\Delta x) = b + \Delta b \end{cases}$$

$$\begin{cases} x = A^{-1}b \\ x + \Delta x = A^{-1}(b+\Delta b) \end{cases}$$

Vemos que podemos intercambiar los papeles de x y b. Consideremos, ahora,

$$\begin{cases} A^{-1}b = x \\ A^{-1}(b+\Delta b) = x + \Delta x \end{cases}$$

Aplicando la desigualdad que acabamos de demostrar, tenemos

$$\frac{\|\Delta b\|}{\|b\|} \leq \cancel{\mathrm{Cond}(A^{-1})}\,\mathrm{Cond}(A)\frac{\|\Delta x\|}{\|x\|}$$

$$\boxed{\frac{1}{\mathrm{Cond}\,A}\frac{\|\Delta b\|}{\|b\|} \leq \frac{\|\Delta x\|}{\|x\|}}$$

■

Teorema 3.3
Sea $A \in \mathbb{K}^{n\times n}$ invertible.
Sean $\Delta A \in \mathbb{K}^{n\times n} \wedge x, \Delta x, b \in \mathbb{K}^n$ /

$$\begin{cases} Ax = b \\ (A+\Delta A)(x+\Delta x) = b \end{cases}$$

Entonces,

$$\frac{\|\Delta x\|}{\|x+\Delta x\|} \leq \mathrm{Cond}(A)\frac{\|\Delta A\|}{\|A\|} \tag{3.10a}$$

Si, además, $\mathrm{Cond}(A)\frac{\|\Delta A\|}{\|A\|} \leq \delta < 1$, se tiene

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{1}{1-\delta}\mathrm{Cond}(A)\frac{\|\Delta A\|}{\|A\|} \tag{3.10b}$$

Demostración.

- Ecuación 3.10a

$$\begin{aligned} (A+\Delta A)(x+\Delta x) &= b \\ A(x+\Delta x) + \Delta A(x+\Delta x) &= b \\ \cancel{Ax} + A\Delta x + \Delta A(x+\Delta x) &= \cancel{b} \\ A\Delta x &= -\Delta A(x+\Delta x) \\ \Delta x &= -A^{-1}\Delta A(x+\Delta x) \\ \|\Delta x\| &= \left\|\cancel{-}A^{-1}\Delta A(x+\Delta x)\right\| \end{aligned}$$

Por la Ecuación 3.5b,

$$\|\Delta x\| \leq \left\|A^{-1}\right\|\|\Delta A(x+\Delta x)\|$$

Por la Ecuación 3.5a,

$$\begin{aligned}
&\leq \left\|A^{-1}\right\| \|\Delta A\| \|x+\Delta x\| \\
&\leq \left\|A^{-1}\right\| \|A\| \frac{\|\Delta A\|}{\|A\|} \|x+\Delta x\| \\
&\boxed{\frac{\|\Delta x\|}{\|x+\Delta x\|} \leq \operatorname{Cond}(A) \frac{\|\Delta A\|}{\|A\|}}
\end{aligned}$$

- Ecuación 3.10b

Por la Ecuación Desigualdad Triangular,

$$\begin{aligned}
\|x+\Delta x\| &\leq \|x\| + \|\Delta x\| \\
\frac{\|x+\Delta x\|}{\|x\|} &\leq \frac{\|x\| + \|\Delta x\|}{\|x\|} \\
&\leq 1 + \frac{\|\Delta x\|}{\|x\|} \\
\frac{\|\Delta x\|}{\cancel{\|x+\Delta x\|}} \frac{\cancel{\|x+\Delta x\|}}{\|x\|} &\leq \left(1 + \frac{\|\Delta x\|}{\|x\|}\right) \frac{\|\Delta x\|}{\|x+\Delta x\|} \\
\frac{\|\Delta x\|}{\|x\|} &\leq \left(1 + \frac{\|\Delta x\|}{\|x\|}\right) \frac{\|\Delta x\|}{\|x+\Delta x\|}
\end{aligned}$$

Por la Ecuación 3.10a,

$$\begin{aligned}
&\leq \left(1 + \frac{\|\Delta x\|}{\|x\|}\right) \operatorname{Cond}(A) \frac{\|\Delta A\|}{\|A\|} \\
&\leq \operatorname{Cond}(A) \frac{\|\Delta A\|}{\|A\|} + \frac{\|\Delta x\|}{\|x\|} \operatorname{Cond}(A) \frac{\|\Delta A\|}{\|A\|}
\end{aligned}$$

Por hipótesis, $\operatorname{Cond}(A) \frac{\|\Delta A\|}{\|A\|} \leq \delta$.

$$\begin{aligned}
\frac{\|\Delta x\|}{\|x\|} &\leq \operatorname{Cond}(A) \frac{\|\Delta A\|}{\|A\|} + \frac{\|\Delta x\|}{\|x\|} \delta \\
&\boxed{\frac{\|\Delta x\|}{\|x\|} \leq \frac{1}{1-\delta} \operatorname{Cond}(A) \frac{\|\Delta A\|}{\|A\|}}
\end{aligned}$$

Duda:

Me parece medio raro haber usado la hipótesis, podríamos haberlo dejado todo en función de $\operatorname{Cond}(A) \frac{\|\Delta A\|}{\|A\|}$.

■

¿Cómo estimarlo?

Hay dos formas para estimarlo: calculando los autovalores o encontrando una matriz singular "parecida" a la matriz original.

Definición (Radio Espectral (Matrices))
Sea $A \in \mathbb{K}^{n\times n}$.
Sean $\{\lambda_i\}_{i=1,\dots,n}$ el conjunto de autovalores de A
Se define el *radio espectral* de A como

$$\rho(A) := \max_{i=1,\dots,n} \{|\lambda_i|\} \tag{3.11}$$

Proposición 3.4
Sea $A \in \mathbb{K}^{n\times n}$.
Entonces,

(a)
$$\|A\|_2 = \sqrt{\rho(A^T A)} \tag{3.12a}$$

(b) Sean $\{\sigma_i\}_{i=1,\dots,n}$ el conjunto de autovalores de $A^T A$ y sean

$$\begin{cases} \sigma_{\text{max.}} = \max\limits_{i=1,\dots,n} \{|\sigma_i|\} \\ \sigma_{\text{min.}} = \min\limits_{i=1,\dots,n} \{|\sigma_i|\} \end{cases}$$

$$\text{Cond}_2(A) = \sqrt{\frac{\sigma_{\text{max.}}}{\sigma_{\text{min.}}}} \tag{3.12b}$$

Demostración.

Solo demostraremos la **??**.

Nota:

Esto podría guiar a la demostración de la Ecuación 3.12a.

$$\text{Cond}_2(A) = \|A\|_2 \left\|A^{-1}\right\|_2$$

Por la Ecuación 3.12a,

$$= \sqrt{\rho(A^T A)}\sqrt{\rho\left[(A^{-1})^T A^{-1}\right]}$$
$$= \sqrt{\rho(A^T A)}\sqrt{\rho\left[((A^T A)^{-1})^T\right]}$$

$$\rho\left[\left((A^TA)^T\right)\right] = \rho\left[\left((A^TA)^{-1}\right)^T\right]$$

Como los autovalores de una matriz y su transpuesta son los mismos.

$$= \rho\left[(A^TA)^{-1}\right]$$

Sean $\{\varsigma_i\}_{i=1,\dots,n}$ el conjunto de autovalores de $(A^TA)^{-1}$.

$$= \max_{i=1,\dots,n}\{|\varsigma_i|\}$$

Proposición (Autovalores de la inversa de una matriz)
Sea $A \in \mathbb{K}^{n\times n}$ invertible.
Sean λ, x un par autovalor-auvector de A.
Entonces, $\frac{1}{\lambda}, x$ es un par autovalor-autovector de A^{-1}.

Demostración.

$$\begin{aligned} A\lambda &= \lambda x \\ A^{-1}Ax &= A^{-1}\lambda x \\ \mathbb{1}x &= \lambda A^{-1}x \\ A^{-1}x &= \frac{1}{\lambda}x \end{aligned}$$

■

$$\begin{aligned} &= \max_{i=1,\dots,n}\left\{\left|\frac{1}{\sigma_i}\right|\right\} \\ &= \min_{i=1,\dots,n}\{|\sigma_i|\} \\ \rho\left[\left((A^TA)^T\right)\right] &= \sigma_{\text{min.}} \end{aligned}$$

Duda:

Tenía que quedar $\frac{1}{\sigma_{\text{min.}}}$.

■

Observación:

Para otras normas podemos obtener cotas con las constantes de las relaciones de equivalencia.

Proposición 3.5
Sea $A \in \mathbb{K}^{n\times n}$ invertible.
Sea $\|\cdot\|$ una norma.
Entonces,

$$\frac{1}{\mathrm{Cond}(A)} = \inf_B \left\{ \frac{\|A-B\|}{\|A\|} \right\} \tag{3.13}$$

con $B \in \mathbb{K}^{n\times n}$ una matriz singular.

Demostración.

Tenemos que $\forall B$ singular $\exists\, x \neq 0$ /

$$\begin{aligned} Bx &= 0 \\ Ax - Bx &= Ax \\ (A-B)x &= Ax \\ A^{-1}(A-B)x &= x \\ \|x\| &= \left\|A^{-1}(A-B)x\right\| \end{aligned}$$

Por la Ecuación 3.5a,

$$\cancel{\|x\|} = \left\|A^{-1}(A-B)\right\| \cancel{\|x\|}$$

Por la **??**,

$$\begin{aligned} 1 &\leq \left\|A^{-1}\right\| \|A-B\| \\ &\leq \left\|A^{-1}\right\| \|A\| \frac{1}{\|A\|} \|A-B\| \\ 1 &\leq \mathrm{Cond}(A) \frac{\|A-B\|}{\|A\|} \\ \frac{1}{\mathrm{Cond}(A)} &\leq \frac{\|A-B\|}{\|A\|} \end{aligned}$$

En particular,

$$\frac{1}{\mathrm{Cond}(A)} \leq \inf_B \left\{ \frac{\|A-B\|}{\|A\|} \right\}$$

Nota:

Claramente, no terminamos la demostración: falta ver que vale la igualdad. La demostración puede verse (aunque creo que tampoco está completa) en la pág. 28 de [**?**].

■

La idea es encontrar la matriz singular que me de una cota superior lo más pequeña posible. Cuanto más chica, mayor es la cota inferior del número de condición. En principio, esto es malo; sin embargo, es preferible afrontar la realidad e intentar acotar el error por abajo lo mejor posible, antes que engañarse a uno mismo eligiendo $B = \mathbb{0}$.

En este capítulo estudiaremos la resolución de sistemas de ecuaciones lineales

$$Ax = b$$

con A no singular. Invertir matrices es computacionalmente caro: no es una opción.

Duda:

¿Es por esto que hacemos todo esto?

Existen dos grandes tipos de métodos: directos y indirectos.

3.2 Métodos Directos

3.2.1 Triangulación de Gauss

Como sabemos las operaciones elementales de filas de una matriz son

- Multiplicación de una fila por un escalar no nulo.

$$E_i \to \lambda E_i$$

- Suma entre filas.

$$E_i \to E_i + E_j$$

- Intercambio de filas.

$$\begin{cases} E_i \to E_j \\ E_j \to E_i \end{cases}$$

Todas estas operaciones pueden representarse en forma matricial.

Las representaciones matriciales de las 2 primeras operaciones están dadas por

- Multiplicación de las fila i-ésima por λ_i.

$$\begin{bmatrix} \lambda_1 & & & & \\ & \ddots & & & \\ & & \lambda_i & & \\ & & & \ddots & \\ & & & & \lambda_n \end{bmatrix}$$

- Suma de filas. (Suma de las filas 1 y 2 en la fila 1.)

$$\begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 1 \end{bmatrix}$$

3.2.2 Descomposición LU

Si no fuera necesario intercambiar filas para realizar la triangulación de Gauss sobre una matriz A, podemos escribir cada paso del método de triangulación de Gauss como una matriz L_i dada por un producto de las representaciones dadas.

El primer paso queda

$$L_1 = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ m_{21} & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ m_{n1} & 0 & \cdots & 1 \end{bmatrix}$$

con $m_{i1} = -\frac{a_{i1}}{a_{11}}$.

El producto es, entonces,

$$L_1 A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ 0 & b_{22} & \cdots & b_{1n} \\ \vdots & \vdots & & \vdots \\ 0 & b_{n2} & \cdots & b_{nn} \end{bmatrix}$$

El segundo paso queda

$$L_2 = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & m_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & m_{2n} & \cdots & 1 \end{bmatrix}$$

con $m_{i2} = -\frac{b_{i2}}{b_{22}}$.

Siguiendo de esta forma, el método de tringulación de Gauss puede representarse como

$$\underbrace{L_{n-1} \cdots L_1}_{\equiv L^{-1}} A = U$$

Comentario Matemático: Matrices Triangulares Inferiores

Definición (Triangular Inferior)
Sea $L \in \mathbb{R}^{n \times n}$.
Decimos que L es *triangular inferior* si $\forall i < j$

$$l_{ij} = 0 \tag{3.14}$$

Propiedades (Propiedades de las Matrices Triangulares Inferiores)
Veamos algunas propiedades de las matrices triangulares inferiores.

(a) Combinación Lineal.

Sean L_1, L_2 triangulares inferiores. Entonces,

$$A = \lambda_1 L_1 + \lambda_2 L_2$$

es triangular inferior.

(b) Producto.
Sean L_1, L_2 triangulares inferiores. Entonces,

$$A = L_1 L_2$$

es triangular inferior.

(c) Determinante.

$$\det(L) = \prod_{i=1}^{n} l_{ii} \tag{3.15a}$$

(d)

$$L \text{ invertible} \iff \forall i, l_i i \neq 0$$

Demostración.

$$L \text{ invertible} \iff \det(L) \neq 0$$

Por la Ecuación 3.15a,

$$\iff \prod_{i=1}^{n} l_{ii} \neq 0$$

$$\boxed{L \text{ invertible} \iff l_{ii}}$$

■

(e)

$$L \text{ invertible} \implies L^{-1} \text{ es triangular inferior}$$

Demostración.
Como L es triangular inferior invertible, se tiene

$$l_i i \neq 0 \qquad \forall i$$

Entonces, puedo aplicar el método de eliminación de Gauss a L sin necesidad de permutar filas.

Nota:

Es hacer $\tilde{L}^{-1} L = \tilde{U}$ pero con $\tilde{U} = \mathbb{1}$. Entonces, $L^{-1} = \tilde{L}^{-1}$.

■

Observación:

Las matrices triangulares inferiores son
- un subespacio vectorial de $\mathbb{K}^{n\times n}$.
- (excluyendo a las matrices triangulares inferiores no invertibles) un grupo.

Se puede verificar que para invertir estas matrices triangulares inferiores basta con cambiar los signos de los m_{ij}.

Existencia y Unicidad de la Descomposición LU

Comentario Matemático: Matrices (Semi)Definidas Positivas/Negativas o Indefinidas

Definición (Submatriz)
Sea $A \in \mathbb{R}^{n\times m}$.
Sean $I_A = \{1, \cdots, n\}$ y $J_A = \{1, \cdots m\}$ los conjuntos de índices de las filas y columnas de A, respectivamente.

Se define la *submatriz* de A como la matriz B resultante de escoger $I_B \subset I_A$ y $J_B \subset J_A$, con I_B y J_B los conjuntos de índices de las filas y columnas de A, respectivamente.
Si $I_B = J_B$, decimos que B es una *submatriz principal* de A.

Sea $k \in I_A$.
Decimos que B es
- una *submatriz principal superior* de A si
$$I_B = \{1, \cdots k\}$$
- una *submatriz principal inferior* de A si
$$I_B = \{k, \cdots n\}$$

Definición (Menores)
Sea $A \in \mathbb{R}^{n\times m}$.
Se define un *menor* de A como el determinante de una submatriz de A

Definición (Matriz Definida Positiva)
Sea $M \in \mathbb{C}^{n\times n}$ hermítica.

Decimos que M es *definida positiva* si $\forall z \in \mathbb{C}^n$

$$z^* M z > 0 \tag{3.16}$$

Observación
Como M es hermítica, $z^* M z \in \mathbb{R}$.

Proposición 3.6 (Definida Positiva: Equivalencias)
Sea $M \in \mathbb{C}^{n \times n}$ hermítica.
Son equivalentes los siguientes enunciados.

(a) M es definida positiva.
(b) Los autovalores de M son positivos.
(c) La operación dada por
$$\langle x,y \rangle \equiv y^* M x$$
define un producto interno en $\mathbb{C}^n$.
(d) **Criterio de Sylvester.** Los menores principales de M son positivos.

Proposición 3.7 (Producto de Matrices por Bloques)
Sean $A, B \in \mathbb{R}^{n \times n}$ /

$$A = \left[\begin{array}{c|c} A_{11} & A_{12} \\ \hline A_{21} & A_{22} \end{array}\right] \qquad B = \left[\begin{array}{c|c} B_{11} & B_{12} \\ \hline B_{21} & B_{22} \end{array}\right]$$

Entonces, el producto de A y B está dado por

$$AB = \left[\begin{array}{c|c} A_{11}B_{11} + A_{12}B_{21} & A_{11}B_{12} + A_{12}B_{22} \\ \hline A_{21}B_{11} + A_{22}B_{21} & A_{21}B_{12} + A_{22}B_{22} \end{array}\right]$$

Teorema 3.8 (de Existencia de la Descomposición LU)
Sea $A \in \mathbb{R}^{n \times n}$ definida positiva.

Duda: Condición más débil

Sea $A^{(k)} \in \mathbb{R}^{k \times k}$ la submatriz de A formada por las primeras k filas y columnas.
Si se tiene
$$\det\left(A^{(k)}\right) \neq 0 \qquad k = 1, \cdots, n$$

Lo saqué de acá.

Entonces, $\exists\, L, U \;/$

$$A = LU$$

Si pedimos, $l_{ii} = 1$, la descomposición es única. Es decir, $\exists!\, L, U \;/\; A = LU$.

Demostración.

Vamos a demostrarlo por inducción.

Supongamos que vale para $A^{(n)} \in \mathbb{n} \times \mathbb{n}$. Es decir, $\exists, L^{(n)}, U^{(n)} \;/$

$$A^{(n)} = L^{(n)} U^{(n)}$$

Escribimos a una matrix $A^{(n+1)} \in \mathbb{R}^{(n+1)\times(n+1)}$ como

$$A^{(n+1)} = \left[\begin{array}{c|c} A^{(n)} & \mathbf{b} \\ \hline \mathbf{c} & a_{nn} \end{array}\right]$$

Proponemos como matrices $L^{(n+1)}$ y $U^{(n+1)}$

$$\begin{cases} L^{(n+1)} = \left[\begin{array}{c|c} L^{(n)} & \mathbf{0} \\ \hline \mathbf{l} & l_{nn} \end{array}\right] \\ U^{(n+1)} = \left[\begin{array}{c|c} U^{(n)} & \mathbf{u} \\ \hline \mathbf{0} & u_{nn} \end{array}\right] \end{cases}$$

Entonces,

$$\left[\begin{array}{c|c} A^{(n)} & \mathbf{b} \\ \hline \mathbf{c} & a_{nn} \end{array}\right] = \left[\begin{array}{c|c} L^{(n)} & \mathbf{0} \\ \hline \mathbf{l} & l_{nn} \end{array}\right] \left[\begin{array}{c|c} U^{(n)} & \mathbf{u} \\ \hline \mathbf{0} & u_{nn} \end{array}\right]$$

Por la Proposición 3.7,

$$= \left[\begin{array}{c|c} L^{(n)}U^{(n)} + \mathbf{00} & L^{(n)}\mathbf{u} + \mathbf{0}u_{nn} \\ \hline \mathbf{l}U^{(n)} + l_{nn}\mathbf{0} & \mathbf{lu} + l_{nn}u_{nn} \end{array}\right]$$

$$\left[\begin{array}{c|c} A^{(n)} & \mathbf{b} \\ \hline \mathbf{c} & a_{nn} \end{array}\right] = \left[\begin{array}{c|c} L^{(n)}U^{(n)} & L^{(n)}\mathbf{u} \\ \hline \mathbf{l}U^{(n)} & \mathbf{lu} + l_{nn}u_{nn} \end{array}\right]$$

$$\begin{cases} A^{(n)} = L^{(n)}U^{(n)} \\ \mathbf{b} = L^{(n)}\mathbf{u} \\ \mathbf{c} = \mathbf{l}U^{(n)} \\ a_{nn} = \mathbf{lu} + l_{nn}u_{nn} \end{cases}$$

Por hipótesis inductiva, la primer ecuación se satisface. Además, como $L^{(n)}$ y $U^{(n)}$ son invertibles, las demás ecuaciones tienen soluciones $\forall \mathbf{l}, \mathbf{u}, l_{nn}, u_{nn}$.

$$\begin{cases} \mathbf{u} = \left(L^{(n)}\right)^{-1}\mathbf{b} \\ \mathbf{l} = \mathbf{c}\left(U^{(n)}\right)^{-1} \\ l_{nn}u_{nn} = a_{nn} - \mathbf{lu} \end{cases}$$

Duda:

En clase dijimos que empezabamos con $n = 2$ pero no veo por qué no podríamos empezar con $n = 1$, donde la descomposición es trivial.

■

El costo computacional de este método es $O\left(\frac{n^3}{3}\right)$.

3.2.3 Descomposición $PA = LU$

3.2.4 Descomposición de Cholesky $A = LL^T$

3.3 Métodos Indirectos

3.3.1 Método de Jacobi

3.3.2 Método de Gauss-Seidel

3.4 Temas del Programa

Capítulo 4

Capítulo 6

En este capítulo, nos ocuparemos de resolver ecuaciones no lineales. Es decir, dada $f : \mathbb{R} \to \mathbb{R}$, hallar r /

$$f(r) = 0$$

4.1 Bisección

Este método se basa en el Teorema 4.2.

Comentario Matemático: Teoremas del Análisis Real

Teorema 4.1 (del Valor Intermedio)
Sea $f : [a, b] \to \mathbb{R}$ una función continua en $[a, b]$.
Sea $f(a) < f(b)$.
Entonces, $\forall u \in [f(a), f(b)], \exists c \in [a, b]$ /

$$f(c) = u$$

Teorema 4.2 (de Bolzano)
Sea $f : [a, b] \to \mathbb{R}$ una función continua en $[a, b]$.
Sea $f(a) < 0 < f(b)$.
Entonces, $\exists c \in [a, b]$ /

$$f(c) = 0$$

Sea $f : [a, b] \to \mathbb{R}$ una función continua en $[a, b]$.
Sea $f(a)f(b) < 0$.

1 Calcular el punto medio c

$$c = \frac{a + b}{2}$$

2 Evaluar la función en c / Calcular $f(c)$.
Si $|f(c)| <$ Tolerancia, devolver c.
Si, no continuar.

3 Evaluar el signo de $f(a)f(c)$ o $f(b)f(c)$.
Si $f(a)f(c) < 0$, reemplazamos b por c y repetimos.
Si $f(b)f(c) < 0$, reemplazamos a por c y repetimos.

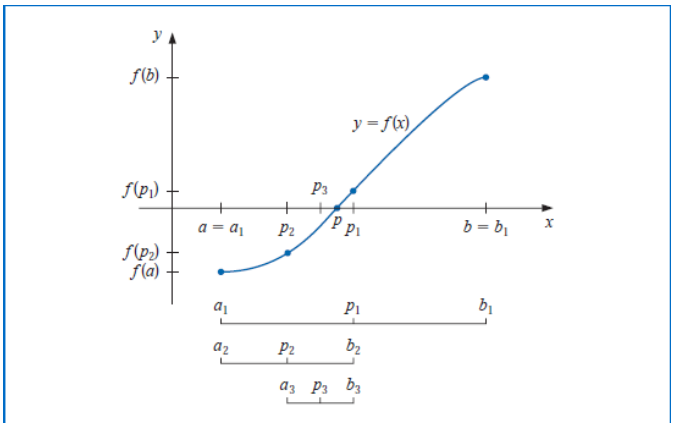

Figura 4.1: Esquema del Método de Bisección. Usamos la letra c en lugar de p. (Recuperado del [**?**].)

$$\boxed{c_k = \frac{b_k - a_k}{2}}$$

Teorema 4.3 (de Convergencia del Método de Bisección)
Sea $f : [a, b] \to \mathbb{R}$ una función continua en $[a, b]$.
Sea $f(a)f(b) < 0$.
Entonces, la sucesión c_n generada por el método de Bisección c_n converge a una raíz r de f. Es decir,

$$\lim_{n\to\infty} c_n = r$$

con $f(r) = 0$.

Demostración.

Tenemos $c_n = \frac{b_n - a_n}{2} \in [a_n, b_n]$. Queremos probar que

a Existen los límites de a_n y b_n.

b Ese límite es el mismo para ambas sucesiones. Por lo tanto, es también el límite de c_n.

c Ese límite es, efectivamente, una raíz.

---

a

- Por un lado, tenemos que las sucesiones $\{a_n\}$ y $\{b_n\}$ son monótonas y acotadas
$$\begin{cases} a = a_1 \geq a_2 \geq \cdots \geq b \\ a \geq \cdots \geq b_2 \geq b_1 = b \end{cases}$$
Por lo tanto, convergen.

- Por otro lado, como cada intervalo mide la mitad que el anterior,
$$\begin{cases} b_{n+1} - a_{n+1} = \dfrac{b_n - a_n}{2} \\ b_1 - a_1 = b - a \end{cases}$$
$$\boxed{b_n - a_n = \frac{b-a}{2^{n-1}}}$$

b
$$b_n - a_n = \frac{b-a}{2^n}$$
$$\lim_{n\to\infty} (b_n - a_n) = \cancelto{0}{\lim_{n\to\infty} \frac{b-a}{2^n}}$$

Como los límites de las sucesiones existen,
$$\lim_{n\to\infty} b_n - \lim_{n\to\infty} a_n = 0$$
$$\boxed{\lim_{n\to\infty} a_n = \lim_{n\to\infty} b_n \equiv r}$$

$$\boxed{\lim_{n\to\infty} a_n = \lim_{n\to\infty} b_n \equiv r \implies \lim_{n\to\infty} c_n = r}$$

c

Comentario Matemático:

Proposición 4.4
Sea $\lim_{n\to\infty} a_n = L$
Sea f continua en L.
Entonces,
$$\lim_{n\to\infty} f(a_n) = f\left(\lim_{n\to\infty a_n}\right) = f(L)$$

$$f(a_n)f(b_n) \leq 0$$
$$\lim_{n\to\infty} f(a_n)f(b_n) \leq 0$$

Sabemos de antemano que el límite de cada producto existe.

$$\begin{aligned}
\lim_{n\to\infty} f(a_n) \lim_{n\to\infty} f(b_n) &\leq 0 \\
f\left(\lim_{n\to\infty} a_n\right) f\left(\lim_{n\to\infty} b_n\right) &\leq 0 \\
[f(r)]^2 &\leq 0 \\
\Longrightarrow \boxed{f(r) = 0}
\end{aligned}$$

■

Teorema 4.5 (Error del Método de Bisección)
El error del método de bisección está acotado por

$$\varepsilon_n \leq \frac{b-a}{2^n}$$

Demostración.

$$\begin{aligned}
\varepsilon_n &= |r - c_n| \\
&\leq \frac{1}{2}(b_n - a_n) \\
&\leq \frac{1}{2}\frac{b-a}{2^{n-1}} \\
\boxed{\varepsilon_n \leq \frac{b-a}{2^n}}
\end{aligned}$$

■

4.2 Regula Falsi

También es conocido como método *de la regla falsa*, *del falso* o *de la falsa posición*.

Sea $f : [a, b] \to \mathbb{R}$ una función continua en $[a, b]$.
Sea $f(a)f(b) < 0$.

1 Interpolamos la función en $[a, b]$ por una recta. Es decir, definimos una recta que pase por $f(a)$ y $f(b)$.

$$y = \frac{f(b) - f(a)}{b - a}(x - a) + f(a)$$

2 Buscamos el cero de esa recta.

$$c = a - f(a)\frac{b - a}{f(b) - f(a)}$$
$$c = \frac{af(b) - bf(a)}{f(b) - f(a)}$$

La última forma es más conveniente para el cálculo numérico por evitar una resta de números (potencialmente cercanos) del mismo signo.

3 Evaluar la función en c / Calcular $f(c)$.
Si $|f(c)| <$ Tolerancia, devolver c.
Si, no continuar.

4 Evaluar el signo de $f(a)f(c)$ o $f(b)f(c)$.
Si $f(a)f(c) < 0$, reemplazamos b por c y repetimos.
Si $f(b)f(c) < 0$, reemplazamos a por c y repetimos.

$$\boxed{c_k = \frac{a_k f(b_k) - b_k f(a_k)}{f(b_k) - f(a_k)}}$$

Agregar:

Parece que no vimos Teorema de Convergencia y Error.

4.3 Punto Fijo

4.3.1 Generalidades

Definición (Punto Fijo)
Sea g una función.
Decimos que p es un *punto fijo* de g si se tiene

$$g(p) = p \tag{4.1}$$

Observación (Equivalencia entre Punto Fijo y Raíz de Función)
Sea $f(r) = 0$.
Siempre podemos definir funciones de la forma

$$g(x) = x + h \circ f(x)$$

con $h \circ f(r) = 0$. Si h es lineal en f, hay una relación inyectiva entre los problemas.

Comentario Matemático: Teorema del Punto Fijo de Brouwer

Definición (Conjunto Convexo)
Sea C un subconjunto de $\mathbb{R}^n$.
Decimos que C es *convexo* si para todo par de puntos la recta que los une está contenida en C. Es decir, $\forall x, y \in C, t \in [0, 1], (1 - t)x + ty \in C$.

Duda:

Como no sabemos que es un subconjunto/subespacio compacto, no nos interesa tanto el teorema que sigue.
Creo que *compacidad* $\Rightarrow$ acotado y cerrado.

Teorema 4.6 (del Punto Fijo de Brouwer)
Sea K un subconjunto convexo y compacto de $\mathbb{R}^n$.
Sea $g : K \to K$ continua.
Entonces, g tiene un punto fijo.

Podemos simplificarlo.

Teorema 4.7 (de Existencia del Punto Fijo)
Sea $I = [a, b]$ un conjunto cerrado.

Sea $g : I \to I$ continua.
Entonces, g tiene *al menos* un punto fijo en I.

Demostración.

Vamos a usar la equivalencia entre punto fijo y raíz de una función para poder usar el Teorema 4.2.

Sea

$$F(x) = g(x) - x$$

- Si $F(a) < 0F(b)$, por el Teorema 4.2, $\exists r \ /$

$$\begin{aligned} F(r) &= 0 \\ g(r) - r &= 0 \\ &\boxed{g(r) = r} \end{aligned}$$

- Si $F(a) = 0 \vee F(b) = 0$,

$$\begin{aligned} F\binom{a}{b} &= 0 \\ g\binom{a}{b} - \tfrac{a}{b} &= 0 \\ &\boxed{g\binom{a}{b} = g\binom{a}{b}} \end{aligned}$$

■

Teorema 4.8 (de Unicidad del Punto Fijo)
Sea $I = [a, b]$ un conjunto cerrado.
Sea $\lambda < 1 \ /$

$$|g'(x)| \leq \lambda$$

Entonces, si existe un punto fijo de g en I es único.

Observación:

No es necesario pedir $g : I \to I$

Demostración.

Vamos a demostrarlo por reducción al absurdo.
Supongamos existen dos puntos fijos r_1, r_2.

Comentario Matemático: Teorema del Valor Medio de Lagrange

Teorema 4.9 (del Valor Medio de Lagrange)
Sea $f : [a, b] \to \mathbb{R}$ continua en $[a, b]$ y derivable en (a, b).
Entonces, $\exists c \in (a, b)$ /

$$f'(c) = \frac{f(b) - f(a)}{b - a} \tag{4.2}$$

$$r_1 - r_2 = g(r_1) - g(r_2)$$

Por el **??**,

$$r_1 - r_2 = g'(c)(r_1 - r_2)$$
$$|r_1 - r_2| = |g'(c)(r_1 - r_2)|$$

Por hipótesis $|g'(c)| < 1$.

$$|r_1 - r_2| < |r_1 - r_2| \Rightarrow\Leftarrow$$

■

4.3.2 Método

Definimos

$$x_{n+1} = g(x_n)$$

Proposición 4.10
Sea g continua.
Si la sucesión $\{x_n\}$ generada por el método del punto fijo converge, entonces, converge a un punto fijo de g. Es decir, si existe el límite,

$$\lim_{n\to\infty} x_n = r$$

con $g(r) = r$.

Demostración.

$$x_{n+1} = g(x_n)$$
$$\lim_{n\to\infty} x_{n+1} = \lim_{n\to\infty} g(x_n)$$

Como g es continua,

$$\lim_{n\to\infty} x_{n+1} = g\left(\lim_{n\to\infty} x_n\right)$$
$$\boxed{r = g(r)}$$

■

El mejor caso que podemos esperar es cuando se satisfagan tanto las condiciones de Existencia como de Unicidad.

Teorema 4.11 (Convergencia y Error del Método del Punto Fijo)
Sea $I = [a, b]$.
Sea $g : I \to I$ continua $/$

$$|g'(x)| \leq \lambda < 1$$

Entonces, la sucesión $\{x_n\}$ generada por el método del punto fijo a partir de una semilla $x_0 \in I$ converge al único punto fijo de g.

Además,

$$\begin{cases} |r - x_n| \leq \lambda^n |r - x_0| & \text{(4.3a)} \\ |r - x_n| \leq \dfrac{\lambda^n}{1-\lambda} |x_1 - x_0| & \text{(4.3b)} \end{cases}$$

Demostración.

Por los teoremas de Existencia y Unicidad, sabemos que el punto fijo r existe y es único.

Como $g : I \to I$, $x_n \in I$ y podemos usar las hipótesis siempre.

Comentario Matemático: Función Lipschitz

Definición (Lipschitz)
Sea $f : \mathbb{R} \to \mathbb{R}$.
Decimos que f es *Lipschitz* si se tiene $\forall x_1, x_2 \in \mathbb{R}$

$$|f(x_1) - f(x_2)| \leq K|x_1 - x_2| \tag{4.4}$$

También decimos que g es λ-*Lipschitz*.

Sean $x, y \in I$.

Por el del Valor Medio de Lagrange, $\exists \xi \in (a, b)$ /

$$\begin{aligned} g(x) - g(y) &= g'(\xi)(x - y) \\ |g(x) - g(y)| &= |g'(\xi)(x - y)| \\ &= |g'(\xi)||x - y| \end{aligned}$$

Por hipótesis, $g'(x) < \lambda$.

$$\boxed{|g(x) - g(y)| \leq \lambda|x - y|}$$

$$|r - x_n| = |g(r) - g(x_{n-1})|$$

Como g es λ-Lipschitz,

$$\leq \lambda|r - x_{n-1}|$$

Repitiendo n veces,

$$\boxed{|r - x_n| \leq \lambda^n|r - x_0|}$$

probando la Ecuación 4.3a. Para ver la convergencia, tomamos límite en ambos miembros.

$$\lim_{n\to\infty} |r - x_n| \leq \lim_{n\to\infty} \lambda^n|r - x_0|$$

Como $\lambda < 1$,

$$\lim_{n\to\infty} |r - x_n| \leq 0$$

$$\implies \boxed{\lim_{n\to\infty} |r - x_n| = 0}$$

$$|r - x_0| = |r - x_1 + x_1 - x_0|$$

Por la Desigualdad Triangular,

$$\begin{aligned} &\leq |r - x_1| + |x_1 - x_0| \\ &\leq |g(r) - g(x_0)| + |x_1 - x_0| \end{aligned}$$

Como g es λ-Lipschitz,

$$\begin{aligned} |r - x_0| &\leq \lambda|r - x_0| + |x_1 - x_0| \\ (1-\lambda)|r - x_0| &\leq |x_1 - x_0| \\ &\boxed{|r - x_0| \leq \frac{1}{1-\lambda}|x_1 - x_0|} \\ \lambda^n|r - x_0| &\leq \frac{\lambda^n}{1-\lambda}|x_1 - x_0| \end{aligned}$$

Por la Ecuación 4.3a, $|r - x_n| \leq \lambda^n|r - x_0|$.

$$\boxed{|r - x_n| \leq \frac{\lambda^n}{1-\lambda}|x_1 - x_0|}$$

■

Corolario 4.11.1 (Vuelta del Teorema 4.11)
Sea g' continua en $[a, b]$ /

$$|g'(x)| < 1$$

Sea $r \in (a, b)$ un punto fijo de g.
Entonces, existe un entorno de r tal que si la semilla x_0 está contenida en ese entorno, la sucesión generada por el método del punto fijo converge. Es decir, $\exists \varepsilon > 0 \ / \ \forall x_0 \in I_\varepsilon = (r - \varepsilon, r + \varepsilon), \lim_{n\to\infty} x_n = r$.

4.4 Newton-Raphson

Sea $f : [a, b] \to \mathbb{R}$ una función derivable en $[a, b]$.
Sea $x_0 \in [a, b]$.

1 Aproximamos la función en $[a, b]$ por la recta tangente en x_0 (Desarrollo de Taylor de Orden 1 en x_0).

$$y = f'(x_0)(x - x_0) + f(x_0)$$

Nota:

Esta aproximación va a ser buena si x_0 está cerca de la raíz.

2 Buscamos el cero de esa recta.

$$x_1 = x_0 - \frac{f(x_0)}{f'(x_0)}$$

3 Evaluar la función en x_1
Si $|f(x_1)| <$ Tolerancia, devolver x_1.
Si, no continuar.

4 Reemplazar x_0 por x_1 y repetir.

$$\boxed{x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}}$$

El método de Newton-Raphson es un método de punto fijo ($x_{n+1} = g(x_n)$).

Observación:

Conviene que la raíz no se anule (tome valores cercanos a 0) cerca de la raíz.

Proposición 4.12
Sea $f \in C^1$.
Si la suceción $\{x_n\}$ genereada por el método de Newton-Raphson converge, entonces, converge a una raíz r de f. Es decir, si existe el límite,

$$\lim_{n\to\infty} x_n = r$$

con $f(r) = 0$.

Demostración.

$$\begin{aligned} f'(x_n)(x_{n+1} - x_n) + f(x_n) &= 0 \\ f(x_n &= -f'(x_n)(x_{n+1} - x_n) \\ \lim_{n\to\infty} f_{x_n} &= \lim_{n\to\infty} (-f'(x_n)(x_{n+1} - x_n)) \end{aligned}$$

Como $f \in C^1$, tanto f como f' son contínuas.

$$\begin{aligned} f\left(\lim_{n\to\infty} x_n\right) &= -f'\left(\lim_{n\to\infty} x_n\right)\left(\lim_{n\to\infty} x_{n+1} - \lim_{n\to\infty} x_n)\right) \\ f(r) &= f'(r)\cancelto{0}{(r-r)} \\ &\boxed{f(r) = 0} \end{aligned}$$

■

Comentario Matemático:

Definición (Cero Simple)
Sea f una función.
Decimos que r es un *cero simple* de f si se tiene

$$\begin{cases} f(r) = 0 \\ f'(r) \neq 0 \end{cases}$$

Teorema 4.13 (de Convergencia y Error de Newton-Raphson)
Sea $f \in C^2([a, b])$.
Sea r un cero simple de f.
Sea $I = [r - \alpha, r + \alpha]$ un entorno cerrado de r.
Sean $\delta, M > 0$ /

$$\begin{cases} |f'(x)| \geq \delta \\ |f''(x)| \leq M \end{cases}$$

Entonces, existe un entorno cerrado de r tal que si la semilla está contenida en ese entorno, la sucesión $\{x_n\}$ generada por el método de Newton-Raphson converge. Es decir, $\exists\, \alpha > \varepsilon > 0$ / $\forall x_0 \in I_\varepsilon = [r - \varepsilon, r + \varepsilon]$

$$\lim_{n\to\infty} x_n = r$$

Además,

$$|e_{n+1}| \leq \frac{1}{2}\frac{M}{\delta}|e_n|^2$$

Demostración.

Elegimos (siempre existe) $\alpha > \varepsilon > 0$ /

$$\frac{1}{2}\frac{M}{\delta}\varepsilon = \lambda < 1$$

$$0 = f(r)$$

Hacemos un desarrollo de Taylor en x_n.

$$\begin{aligned}
&= f(x_n) + f'(x_n)(r - x_n) + \frac{1}{2}f''(\xi_n)(r - x_n)^2 \\
&= f(x_n) + f'(x_n)(r - x_n) + \frac{1}{2}f''(\xi_n)(r - x_n)^2 \\
-f'(x_n)(r - x_n) - f(x_n) &= \frac{1}{2}f''(\xi_n)(r - x_n)^2 \\
(r - x_n) - \frac{f(x_n)}{f'(x_n)} &= \frac{1}{2}\frac{f''(\xi_n)}{f'(x_n)}(r - x_n)^2 \\
(r \cancel{- x_n}) - (x_{n+1} \cancel{- x_n}) &= \\
r - x_{n+1} &= \frac{1}{2}\frac{f''(\xi_n)}{f'(x_n)}(r - x_n)^2 \\
|r - x_{n+1}| &= \left|\frac{1}{2}\frac{f''(\xi_n)}{f'(x_n)}(r - x_n)^2\right| \\
|r - x_{n+1}| &= \frac{1}{2}\frac{|f''(\xi_n)|}{|f'(x_n)|}|r - x_n|^2 \\
&\boxed{\epsilon_{n+1} = \frac{1}{2}\frac{|f''(\xi_n)|}{|f'(x_n)|}\epsilon_n^2}
\end{aligned}$$

Por hipótesis, podemos acotar las derivadas.

$$\boxed{\epsilon_{n+1} \leq \frac{1}{2}\frac{M}{\delta}\epsilon_n^2}$$

Agregar: Terminar

■

Corolario 4.13.1
Sea $f \in C^2(\mathbb{R})$ /

- sea convexa. Es decir, $f''(x) > 0$.

- cambie de signo.

Sea x_0 tal que no sea un mínimo de f.
Entonces, la sucesión $\{x_n\}$ generada por el método de Newton-Raphson converge.

Observación: Comentarios

- Si la función tiene k raíces, podemos clasificar las semillas x_0 en $k+1$ grupos, según a qué raíz convergen o si no convergen.
- Podemos generalizar esto a más dimensiones o a los complejos.

4.5 Secante

4.6 Temas del programa