Resumen - Métodos Estadísticos en Física Experimental

Marco Ciafardini

20 de diciembre de 2021

Índice

1 Introducción **4**
1.1 Definiciones y generalidades 4
1.2 Probabilidad Condicional 8
1.2.1 Teorema de Bayes 12
1.3 Distribución Binomial 14
1.4 Temas del programa 16

2 Distribuciones Discretas **17**
2.1 Distribuciones Discretas 17
2.1.1 Generalidades y definiciones 17
2.1.2 Algunas distribuciones 18
2.2 Temas del programa 28

3 Distribuciones Continuas **29**
3.1 Distribuciones Contínuas 29
3.1.1 Conjuntos, álgebra 29
3.1.2 Función de Probabilidad Acumulada (CDF) 30
3.1.3 Función Densidad de Probabilidad (PDF) 32
3.1.4 Función Característica (CF) 34
3.1.5 Función Generadora de Momentos (MGF) 35
3.1.6 Función Generadora de Probabilidad (PGF) 36
3.1.7 Cambio de Variable 36
3.1.8 Algunas distribuciones 39
3.2 Temas del Programa 43

4 Distribuciones Multidimensionales **44**
4.1 Distribuciones Multivariables 44
4.1.1 Probabilidades Marginal y Condicional 44
4.1.2 Esperanza 46
4.1.3 Varianza y Covarianza 46
4.1.4 Factor de Correlación 48
4.1.5 Función Característica 49

4.1.6 Propagación de Errores: Cambio de Variables 49
4.1.7 Aproximación Lineal 51
4.2 Teorema del Límite Central 54
4.3 Algunas Distribuciones 55
4.3.1 Distribución Multinormal 55
4.4 Temas del Programa 55

5 Teoría de Estimadores **56**
5.1 Generalidades y Definiciones 56
5.1.1 Estimador 56
5.1.2 Consistencia 57
5.1.3 Sesgo 58
5.1.4 Verosimilitud 62
5.2 Eficiencia y Suficiencia 62
5.2.1 Teorema de Cramér-Rao 62
5.2.2 Estimadores Óptimos y Eficiencia 65
5.2.3 Suficiencia 72
5.3 Temas del Programa 76

6 Estimadores de Máxima Verosimilitud y Cuadrados Mínimos **77**
6.1 Estimador de Máxima Verosimilitud 77
6.2 Cuadrados Mínimos 79
6.2.1 Regresión Lineal 81
6.3 Temas del Programa 84

7 Intervalos de Confianza **85**
7.1 Temas del Programa 89

8 Test de Hipótesis **90**

Bibliografía **94**

Capítulo 1

Introducción

1.1 Definiciones y generalidades

Definición (Conjunto Universal o Espacio Muestral Ω)
Se define el *conjunto universal* Ω como el conjunto de todos los resultados posibles de un experimento aleatorio.

Observación
El conjunto universal puede ser finito, infinito numerable (misma cardinalidad que $\mathbb{N}$) o infinito no numerable.

Definición (Suceso A)
Sea A un subconjunto de Ω. Decimos que A es un *suceso* de Ω.

Definición (Complemento A′)
Sea A un suceso de Ω. Definimos el *complemento de A* A' como

$$A' = \Omega - A$$

Definición (Álgebra de Boole)
Sea S un conjunto de sucesos. Decimos que S es un *álgebra de Boole* si se cumple que $\forall A, B \in S$

(a) $A \cup B \in S$ (cerrado ante uniones)

(b) $A' \in S$ (cerrado ante complemento)

Proposición 1.1 (Propiedades del Álgebra de Boole)
Sea $A, B \in S$.

(a) $A \cap B \in S$ (cerrado ante intersecciones)

Demostración.

$$A \cap B = (A' \cup B')'$$

Por definición, es cerrado ante uniones y complementos. ■

(b) $A - B \in S$ (cerrado ante diferencias)

Demostración.

$$A - B = A \cap B'$$

■

(c) $\varnothing \in S$ ("elemento neutro")

Demostración.

$$\varnothing = A - A$$

■

(d) $\Omega \in S$

Demostración.

$$\Omega = \varnothing'$$

■

Generalmente, para espacios muestrales finitos, el conjunto de subconjuntos S que nos ocupará será

$$S = \{A : A \text{ es subconjunto de } \Omega\}$$

Ejemplo/Ejercicio: Moneda

$$\Omega = \{C, S\}$$

Entonces,

$$S = \{\varnothing, \Omega, C, S\}$$

Proposición 1.2 (Cardinal de S)
No es difícil ver que el cardinal de S está relacionado con el cardinal de Ω de la siguiente forma

$$\#S = 2^{\#\Omega}$$

Definición (Función de Conjunto / Medida)
Sea S un álgebra de Boole.
Sea $f : S \to \mathbb{R}$.
Decimos que f es una *función de conjunto* o *medida* si $\forall A, B \in S$

(a) $f(A \cup B) = f(A) + f(B) \qquad \forall A \cap B = \varnothing$

(b) $f(A) \geq 0$

Proposición 1.3 (Propiedades de una Medida)
Sea f una medida de S.
Entonces,

(a) $f(A \cup B) = f(A) + f(B) - f(A \cap B) \qquad \forall A, B \in S$

Demostración.

Por un lado, haciendo un diagrama de Venn,

$$A \cup B = A \cup (B - A)$$
$$f(A \cup B) = f(A \cup (B - A))$$

Como $A \cap (B - A) = \varnothing$, por la definición de medida,

$$f(A \cup B) = f(A) + f(B - A)$$

Por otro lado,

$$B = (B - A) \cup (A \cap B)$$
$$f(B) = f((B - A) \cup (A \cap B))$$

Como $(B - A) \cap (A \cap B) = \varnothing$, por la definición de medida,

$$f(B) = f(B - A) + f(A \cap B)$$

Restando las ecuaciones,

$$f(A \cup B) - f(B) = f(A) + \cancel{f(B - A)} - \cancel{f(B - A)} - f(A \cap B)$$
$$\boxed{f(A \cup B) = f(A) + f(B) - f(A \cap B)}$$

■

(b) $f(B - A) = f(B) - f(A) \qquad \forall A \supseteq B$

Demostración.

■

(c) $f(\varnothing) = 0$

Demostración.

$$\varnothing = \varnothing - \varnothing$$
$$f(\varnothing) = f(\varnothing - \varnothing)$$

Por la propiedad 2 de la medida,

$$f(\varnothing) = f(\varnothing) - f(\varnothing)$$
$$\boxed{f(\varnothing) = 0}$$

■

Observación (Ejemplos de Medidas)
Enunciamos algunos ejemplos de medidas.

- Masa
- Longitud, Área
- Cardinal de un conjunto

Definición (Probabilidad)
Sea $P : S \to \mathbb{R}$ una medida Decimos que P es una probabilidad si $\forall A, B \in S$

$$P(\Omega) = 1$$

Para un espacio muestral $\Omega = \{a_i : i = 1 \cdots n\}$, definimos los conjuntos $A_i = \{a_i\}$

y $P(A_i) = p_i$. Como P es una medida,

$$P\left(\cup_{i=1}^{n} A_i\right) = P\left(\Omega\right)$$
$$\sum_{i=1}^{n} P\left(A_i\right) = 1$$
$$\sum_{i=1}^{n} p_i = 1$$

Definición (Equiprobabilidad)
Sea Ω un espacio muestral finito con $\#\Omega = n$.
Decimos que los sucesos A_i son *equiprobables* si

$$p_1 = p_2 = \cdots = p_n$$

con $p_i = \frac{1}{n}$.

Por ejemplo, si $A = A_1 + A_2 + A_3 = \{a_1, a_2, a_3\}$

$$P(A) = p_1 + p_2 + p_3$$
$$P(A) = \frac{3}{n}$$

En general,

$$P(A) = \frac{n_A \text{ (\# de elementos de } A \text{ - casos favorables)}}{n \text{ (\# de elementos de } \Omega \text{ - casos totales)}}$$

1.2 Probabilidad Condicional

Ejemplo/Ejercicio: Tirar 2 dados

$\Omega = \{(a_1, a_2) : 1 \leq a_i \leq 6 \forall i\}$ Supongamos 2 sucesos A y B tales que

$$\begin{cases} A = \{(a_1, a_2) : a_1 + a_2 = 10\} \\ B = \{(a_1, a_2) : a_1 > a_2\} \end{cases}$$

En este ejemplo podemos escribir todos los elementos de estos conjuntos.

$$\begin{cases} A = \{\ (5,5), (6,4), (4,6)\ \} & \\ B = \{\ (6,5),\ \cdots\ , (6,1) & \text{5 elementos} \\ \qquad (5,4),\ \cdots\ , (5,1) & \text{4 elementos} \\ \qquad \cdots & \\ \qquad (2,1)\ \} & \text{1 elemento} \end{cases}$$

No es difícil calcular la cardinalidad de estos conjuntos.

$$\begin{cases} \#\Omega = 36 \\ \#A = 3 \\ \#B = \sum_{n=1}^{5} = 15 \end{cases}$$

La probabilidad de B sabiendo que ocurrió A, sólo habría que contar cuántos elemetos de B están contenidos en A (casos favorables posibles) y dividir por el número de elementos de A (casos totales). Es decir,

$$P(B|A) = \frac{\#(B \cap A)}{\#A}$$

Dividiendo por $\#\Omega$ arriba y abajo,

$$P(B|A) = \frac{\frac{\#(B \cap A)}{\#\Omega}}{\frac{\#A}{\#\Omega}}$$

$$\boxed{P(B|A) = \frac{P(B \cap A)}{P(A)}}$$

Motivados por este ejemplo, proponemos la siguiente definición:

Definición (Probabilidad Condicional)
Se define la *probabilidad condicional de un suceso A habiendo sucedido otro suceso B* $P(A|B)$ como

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

con $P(A) \neq 0$. Se lee "la probabilidad de A dado B".

Definida de esta forma, la probabilidad condicional es efectivamente una probabilidad. Verificamos que se cumplan las 3 condiciones para ser una probabilidad.

(a)

Demostración.

■

(b)

Demostración.

■

(c)

Demostración.

■

Definición (Independencia)
Sean $A, B \in S$.
Decimos que A es *independiente* de B sí y sólo sí

$$P(A|B) = P(A)$$

Proposición 1.4 (Reflexividad)

$$P(A|B) = P(A) \iff P(B|A) = P(B)$$

Demostración.

$$P(B|A) = \frac{P(B \cap B)}{P(A)}$$

Multiplicando por $P(A)$ arriba y abajo,

$$\begin{aligned} &= \frac{P(B \cap A)}{P(B)} \frac{P(B)}{P(A)} \\ &= \frac{P(A \cap B)}{P(B)} \frac{P(B)}{P(A)} \\ &= P(A|B) \frac{P(B)}{P(A)} \end{aligned}$$

Como A es independiente de B,

$$= \cancel{P(A)}\frac{P(B)}{\cancel{P(A)}}$$
$$P(B|A) = P(B)$$

■

Proposición 1.5 (Probabilidad de la intersección)
A y B son independientes sí y sólo sí

$$P(A|B) = P(A)P(B)$$

Demostración.

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$
$$P(A) = \frac{P(A \cap B)}{P(B)}$$
$$P(A \cap B) = P(A)P(B)$$

■

Observación (A y su complemento A')
Un conjunto A y su complemento A' no pueden ser nunca independientes dado que

$$P(A|A') = \frac{P(\cancel{A \cap A'})^{\varnothing}}{P(A'} = 0 \neq P(A)P(A')$$

Podríamos decir que son perfectamente dependientes: dado A' (A), la probabilidad de que ocurra A (A') está determinda y es 0.

Veamos una fórmula útil. Supongamos un conjunto universal Ω y sucesos B_i tales que

$$\begin{cases} B_i \cap B_j = \varnothing & \forall i \neq j \\ \cup_{i=1}^{N} = \Omega \end{cases}$$

Sea A un suceso de Ω, no es difícil ver que

$$A = \cup_{i=1}^{N} A \cap B_i$$
$$P(A) = P(\cup_{i=1}^{N} A \cap B_i)$$

$A \cap B_i$ disjuntos

$\forall i \neq j$

$$B_i \cap B_j = \varnothing$$
$$A \cap (B_i \cap B_j) = A \cap \varnothing$$
$$(A \cap B_i) \cap (A \cap B_j) = \varnothing$$

$$P(A) = \sum_{i=1}^{N} P(A \cap B_i)$$

Por la definición de probabilidad condicional,

$$\boxed{P(A) = \sum_{i=1}^{N} P(A|B_i)P(B_i)}$$

Observación

$$\begin{cases} P(\Omega|A) = 1 \\ P(A|\Omega) = P(A) \neq 1 \end{cases}$$

Observación
Observación:

- La probabilidad de la unión es la suma si son disjuntos.
- La probabilidad de la intersección es es producto si son independientes.

1.2.1 Teorema de Bayes

Teorema 1.6 (Teorema de Bayes)

$$P(B|A) = P(A|B)\frac{P(B)}{P(A)}$$

Demostración.

$$\begin{aligned} P(B|A) &= \frac{P(B \cap A)}{P(A)} \\ &= \frac{P(B \cap A)}{P(b)} \frac{P(B)}{P(A)} \\ P(B|A) &= P(A|B) \frac{P(B)}{P(A)} \end{aligned}$$

■

Ahora, sean B_k disjuntos tales que su unión es Ω.

Por el Teorema de Bayes,

$$P(B_k|A) = P(A|B_k) \frac{P(B_k)}{P(A)}$$

Por la propiedad de la probabilidad condicional que vimos anteriormente, $P(A) = \sum_{i=1}^{N} P(A|B_i)P(B_i)$.

$$P(B_k|A) = P(A|B_k) \frac{P(B_k)}{\sum_{i=1}^{N} P(A|B_i)P(B_i)}$$

Ejemplo/Ejercicio: Enfermos y Pruebas

Supongamos que un individuo puede estar enfermo e o no $\neg e$ y que a ese individuo se le hace un test que puede dar positivo a o negativo $\neg a$. El espacio muestral Ω es

$$\Omega = \{(e, a), (e, \neg a), (\neg e, a), (\neg e, \neg a)\}$$

y definamos los sucesos E y A como estar enfermo y haber dado positivo, respectivamente.

$$\begin{cases} E = \{(e, a), (e, \neg a)\} \\ A = \{(e, a), (\neg e, a)\} \end{cases}$$

$$\Rightarrow A \cap E = \{(e, a)\}$$

y sean las probabilidades condicionales

$$\begin{cases} P(A|E) = 0.97 & \text{eficiencia} \\ P(A|E') = 0.04 & \text{falso positivo} \\ P(E) = 0.05 & \text{estar enfermo} \end{cases}$$

Observación:

La suma $P(A|E) + P(A|E')$ no es necesariamente igual a 1.

Al paciente le interesa la probabilidad $P(E|A)$ (probabilidad de estar enfermo dado que su test salió positivo).

Recordando la expresión anterior,

$$\begin{aligned} P(E|A) &= P(A|E)\frac{P(E)}{P(A|E)P(E) + P(A|E')P(E')} \\ &= \frac{P(A|E)P(E)}{P(A|E)P(E) + P(A|E')P(E')} \\ P(E|A) &= 0.55 \end{aligned}$$

Este resultado puede parecer anti-intuitivo porque si bien la eficiencia del test y los falsos positivos parecían razonables, la probabilidad de estar enfermo habiendo dado positivo está lejos de 1. Esto sucede porque no tuvimos en cuenta la probabilidad de estar enfermo, que es relativamente baja para los otros parámetros.
Lo que nos indica cuán fiable es el positivo es cuán grande es la magnitud de $P(A|E)P(E)$ comparada con $P(A|E')P(E')$.

1.3 Distribución Binomial

Definición (Variable Aleatoria X)
Sea Ω un conjunto universal. Definimos una *variable aleatoria* de Ω como una función

$$X : \Omega \to \mathbb{R}^n$$

Observación:

Las mediciones son variables aleatorias.

Observación: Notación

X por definición es una función. Sin embargo, el símbolo X se usa también para designar a un conjunto. Por ejemplo, $X = a$ es el conjunto $\{\omega \in \Omega : X(\omega) = a\}$.

Ejemplo/Ejercicio: Detector de partículas

Sea un detector por el cual pasan 2 partículas.
Notamos a en la coordenada i si el detector detectó la partícula i.

$$\Omega = \{(a, a), (a, \neg a), (\neg a, a), (\neg a, \neg a)\}$$

Definimos la siguiente variable aleatoria

$$X = \#\text{de detecciones}$$

y los sucesos

$$\begin{cases} A_1 = \{(a, a), (a, \neg a)\} \\ A_2 = \{(a, a), (\neg a, a)\} \end{cases}$$

Además, como suponemos que el detector no se va arruinando con el paso del tiempo ni tiene tiempo muerto entre cada medición,

$$P(A_i) = p \forall i$$

y

$$P(A_2|A_1) = P(A_2) \Rightarrow \text{son independientes}$$

Agregar: Distribución Binomial

- Definición.
- Es una probabilidad.
- Máximos
- Promedio (Esperanza)

Clase 3

(a) Los experimentos son independientes.

(b) La probabilidad se mantiene constante en el tiempo.

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$$

1.4 Temas del programa

1. Introducción: Probabilidad y estadística en la investigación experimental. Estimación de parámetros, de los datos a los resultados. Las incertezas como intervalos de confianza, errores estadísticos y sistemáticos. Diseño de experimentos. Tests de hipótesis y la validación de modelos teóricos

2. Repaso de probabilidades: Variables aleatorias. Probabilidad condicional, independencia y correlación. Teorema de Bayes. Esperanza y varianza. Ley de grandes números. Desigualdad de Chebyshev. Distribución y densidad de probabilidad. Distribuciones multidimensionales y covarianza.

Capítulo 2

Distribuciones Discretas

2.1 Distribuciones Discretas

2.1.1 Generalidades y definiciones

Definición (Esperanza)
Sea una variable aleatoria X con una función de probabilidad $P(X = x_i)$.
Se define la *esperanza* como

$$\mathrm{E}\left[X\right] :- \sum_{i=1}^{n} x_i P(X = x_i)$$

Definición (Varianza)
Sea una variable aleatoria X con una función de probabilidad $P(X = x_i)$.
Sea $\mu = \mathrm{E}\left[X\right]$.
Se define la *varianza* como

$$\mathrm{Var}\left(X\right) :- \mathrm{E}\left[(X - \mu)^2\right]$$

Podemos llegar a una expresión equivalente (más útil).

$$\begin{aligned}\mathrm{Var}\left(X\right) &= \mathrm{E}\left[(X - \mu)^2\right] \\ &= \mathrm{E}\left[X^2 - 2X\mu + \mu^2\right]\end{aligned}$$

Como la esperanza se define como una serie, podemos asociar los términos.

$$\begin{aligned}&= \mathrm{E}\left[X^2\right] - 2\mathrm{E}\left[X\right]\mu + \mu^2 \\ &= \mathrm{E}\left[X^2\right] - 2\mu^2 + \mu^2 \\ &\boxed{\mathrm{Var}\left(X\right) = \mathrm{E}\left[X^2\right] - \mu^2}\end{aligned}$$

Definición (Desviación Estándar)
Sea una variable aleatoria X con una función de probabilidad $P(X = x_i)$.
Se define la *desviación estándar* o *desviación típica* σ como

$$\sigma = \sqrt{\mathrm{Var}\,(X)}$$

Agregar: Momentos

Centrados, estándar de distintos grados.

Definición
Momento n-ésimo de una distribución Se define el *momento n-ésimo de una distribución* como

$$\langle x \rangle = \int_{-\infty}^{\infty} x^n f(x)\, dx$$

para el caso contínuo.

2.1.2 Algunas distribuciones

Distribución Binomial

$$\mathscr{B}(k|n,p) = \binom{n}{k} p^k (1-p)^{n-k}$$

Observación (Es una probabilidad.)
Veamos que la distribución binomial es, efectivamente, una probabilidad.

(a)
$$\mathscr{B}(k|n,p) = \binom{n}{k} p^k (1-p)^{n-k} \geq 0$$

(b) La probabilidad de 2 conjuntos disjuntos (k distinto) es la suma de sus probabilidades.

(c) Está normalizada.

$$\begin{aligned} P(\Omega) &= \sum_{k=0}^{n} \mathscr{B}(k|n,p) \\ &= \sum_{k=0}^{n} \binom{n}{k} p^k (1-p)^{n-k} \end{aligned}$$

El número combinatorio $\binom{n}{k}$ es el coeficiente del término con una de los términos elevado a la k en el binomio $(p+q)^n$.Entonces, prácticamente, por definición,

$$\begin{aligned} &= (p+q)^n \\ P(\Omega) &= 1 \end{aligned}$$

Moda

- Si $(n+1)p \in \mathbb{N}$,

$$\text{Moda} = \left\{(n+1)p - 1, (n+1)p\right\}$$

- Si $(n+1)p \notin \mathbb{N}$,

$$\text{Moda} = \lfloor (n+1)p \rfloor$$

Esperanza

$$\begin{aligned} \mathrm{E}\left[X\right] &= \sum_{k=1}^{n} kP(X=k) \\ &= \sum_{k=1}^{n} k\binom{n}{k} p^k (1-p)^{n-k} \\ \boxed{\mathrm{E}\left[X\right] = np} \end{aligned}$$

Agregar: Cuenta Esperanza Binomial

Observación (Esperanza y media.)

$$\begin{aligned} \mathrm{E}\left[X\right] &= \sum_{k=1}^{n} kP(X=k) \\ &= \sum_{k=1}^{n} k\frac{n_k}{n} \\ &= \frac{1}{n}\sum_{k=1}^{n} kn_k \\ \mathrm{E}\left[X\right] &= \langle k \rangle \end{aligned}$$

Varianza

$$\mathrm{Var}\,(X) = \mathrm{E}\left[X^2\right] - \mu^2$$
$$\boxed{\mathrm{Var}\,(X) = np(1-p)}$$

Agregar: Cuenta Varianza Binomial

Distribución Binomial Negativa

Agregar: Derivación / Intuición

Nota: Definición no convencional

Definición (Distribución Binomial Negativa)
Se define la *distribución binomial negativa* como

$$\mathscr{BN}(X = n|k,p) = \binom{n-1}{k-1} p^k (1-p)^{n-k}$$

Esperanza

$$\mathrm{E}\,[X] = \frac{k}{p}$$

Observación: Distribución Geométrica

Es un caso particular de la distribución binomial negativa, con $k = 1$.

Distribución Hipergeométrica

Agregar: Derivación / Intuición

Definición (Distribución Hipergeométrica)
Se define la *distribución hipergeométrica* como

$$H(X = k \mid N, K, n) = \frac{\binom{n}{k}\binom{N-K}{n-k}}{\binom{N}{n}}$$

Agregar: Dibujo Explicativo

Distribución de Poisson

La distribución de Poisson se define como el límite de la distribución binomial cuando

$$\begin{cases} n \to \infty \\ p \to 0 \\ np = \mu \end{cases}$$

$$\begin{aligned} \mathcal{P}(k|\mu) &= \lim_{\substack{n\to\infty \\ p\to 0}} \mathscr{B}(k|n,p) \\ &= \lim_{\substack{n\to\infty \\ p\to 0}} \binom{n}{k} p^k (1-p)^{n-k} \\ &= \lim_{\substack{n\to\infty \\ p\to 0}} \frac{n!}{k!(n-k)!} p^k (1-p)^n (1-p)^{-k} \end{aligned}$$

$$\lim_{p\to 0} (1-p)^{-k} = 1$$

$$\begin{aligned} \lim_{n\to\infty} \frac{n!}{(n-k)!} &= \lim_{n\to\infty} n[n-1]\cdots[n-(k-1)] \\ &\approx n^k \end{aligned}$$

Nota:

Lo último no tiene sentido para nada.

$$\mathcal{P}(k|\mu) = \lim_{\substack{n\to\infty \\ p\to 0}} \frac{n^k}{k!} p^k (1-p)^n \cdot 1$$

Como $np = \mu$,

$$\begin{aligned}
\lim_{\substack{n\to\infty \\ p\to 0}} (1-p)^n &= \lim_{\substack{n\to\infty \\ p\to 0}} (1-p)^n \\
&= \lim_{\substack{n\to\infty \\ p\to 0}} (1-p)^{\frac{\mu}{p}} \\
&= \left(\lim_{\substack{n\to\infty \\ p\to 0}} (1-p)^{\frac{1}{p}} \right)^{\mu} \\
&= \left(\lim_{\substack{n\to\infty \\ p\to 0}} (1-p)^{\frac{1}{p}} \right)^{\mu}
\end{aligned}$$

$$A :- \lim_{\substack{n\to\infty \\ p\to 0}} (1-p)^{\frac{1}{p}}$$

$$\ln(A) \ln \left(\lim_{\substack{n\to\infty \\ p\to 0}} (1-p)^{\frac{1}{p}} \right)$$

$$\lim_{\substack{n\to\infty \\ p\to 0}} \frac{1}{p} \ln(1-p))$$

L' Hôpital

$$\lim_{\substack{n\to\infty \\ p\to 0}} (1-p)^n = e^{-\mu}$$

$$\begin{aligned}
\mathcal{P}(k|\mu) &= \lim_{\substack{n\to\infty \\ p\to 0}} \frac{1}{k!} n^k p^k e^{-\mu} \\
&= \lim_{\substack{n\to\infty \\ p\to 0}} \frac{1}{k!} \mu^k e^{-\mu}
\end{aligned}$$

$$\boxed{\mathcal{P}(k|\mu) = \frac{e^{-\mu}\mu^k}{k!}}$$

Observación (Es una probabilidad.)
Veamos que la distribución de Poisson es, efectivamente, una probabilidad.

(a) Es evidente que es mayor que 0.

Agregar: Formalizar

(b) La probabilidad de la suma de disjuntos es la suma de sus probabilidades.

Agregar: Falta

(c) Está normalizada.

$$\begin{aligned}\sum_{k=0}^{\infty}\mathcal{P}(k|\mu) &= \sum_{k=0}^{\infty}\frac{e^{-\mu}\mu^k}{k!}\\ &= e^{-\mu}\sum_{k=0}^{\infty}\frac{\mu^k}{k!}\end{aligned}$$

El segundo factor no es más que la serie de Taylor de e^x.

$$\begin{aligned}&= \cancel{e^{-\mu}}\cancel{e^{\mu}}\\ \sum_{k=0}^{\infty}\mathcal{P}(k|\mu) &= 1\end{aligned}$$

Esperanza

$$\begin{aligned}\mathrm{E}\left[X\right] &= \langle X\rangle\\ &= \sum_{k=0}^{\infty}k\mathcal{P}(k|\mu)\\ &= \sum_{k=0}^{\infty}k\frac{e^{-\mu}\mu^k}{k!}\\ &= e^{-\mu}\sum_{k=0}^{\infty}\frac{k\mu^k}{k!}\end{aligned}$$

$$\begin{aligned}\frac{k\mu^k}{k!} &= \mu\frac{k\mu^{k-1}}{k!}\\ &= \mu\frac{d\mu^k}{dk}\end{aligned}$$

$$\begin{aligned}\mathrm{E}\left[X\right] &= e^{-\mu}\sum_{k=0}^{\infty}\mu\frac{d\mu^k}{dk}\\ &= e^{-\mu}\mu\sum_{k=0}^{\infty}\frac{d\mu^k}{dk}\end{aligned}$$

Pasando el límite bajo la derivada,

$$= e^{-\mu}\mu\sum_{k=0}^{\infty}\frac{d\mu^k}{dk}$$

Agregar: No es así

Tengo que rehacerlo.

Varianza

$$\begin{aligned}\mathrm{Var}\left(X\right) &= \left\langle k^2\right\rangle - \left\langle k\right\rangle^2\\ &= \left\langle k^2\right\rangle - \mu^2\end{aligned}$$

$\langle k^2\rangle$

$$\begin{aligned}\left\langle k^2\right\rangle &= \sum_{k=0}^{\infty}k^2\mathcal{P}(k|\mu)\\ &= \sum_{k=0}^{\infty}k^2\frac{e^{-\mu}\mu^k}{k!}\\ &= \sum_{k=0}^{\infty}k^2\frac{e^{-\mu}\mu^k}{k!}\end{aligned}$$

$$\boxed{\mathrm{Var}\left(X\right) = \mathrm{E}(k) = \mu}$$

Veamos ahora una derivación de la distribución de Poisson más "física". Consideremos las siguientes hipótesis.

(a) En $I = [x, x + \Delta x]$, hay a lo sumo un evento.

$$P_I(k > 1) = 0$$

Podemos suponer esto porque el intervalo I es tan pequeño como queramos.

(b) La probabilidad de tener un evento en I es proporcional a Δx.

$$P_I(k = 1) \propto \Delta x$$

Esto de justifica porque la probabilidad de un evento es uniforme en todo x.

(c) La probabilidad de que haya un evento en I es independiente de la probabilidad de que haya un evento en otro intervalo que no contenga a I.

$$P_I(k = 1|k_{I'}) = P_I(k = 1)$$

con $I \not\subseteq I'$.

Las hipótesis 2 y 3 se cumplen para un caso donde la probabilidad de que ocurra un evento sea uniforme en x.

Por la hipótesis 2,

$$P_I(k = 1) = \lambda \Delta x$$

Por la hipótesis 1,

$$P_I(k = 0) = 1 - \lambda \Delta x$$

Si consideramos $I_{x+\Delta x} = [0, 0 + x + \Delta x] = [0, x + \Delta x]$,

Por la hipótesis 1,

$$P_{I_{x+\Delta x}}(k = 1) = P_{I_x}(k = 1)P_{I_{\Delta x}}(k = 0|k_{I_x} = 1) + P_{I_x}(k = 0)P_{I_{\Delta x}}(k = 1|k_{I_x} = 0)$$

Por la hipótesis 3,

$$P_{I_{x+\Delta x}}(k = 1) = P_{I_x}(k = 1)P_{I_{\Delta x}}(k = 0) + P_{I_x}(k = 0)P_{I_{\Delta x}}(k = 1)$$

Reemplazando los resusltados anteriores,

$$P_{I_{x+\Delta x}}(k = 1) = P_{I_x}(k = 1)(1 - \lambda \Delta x) + P_{I_x}(k = 0)\lambda \Delta x$$

$$\frac{P_{I_{x+\Delta x}}(k = 1) - P_{I_x}(k = 1)}{\Delta x} = \lambda(P_{I_x}(k = 0) - P_{I_x}(k = 1))$$

En la función distribución de probabilidad, la longitud del intervalo es un parámetro, tomando el límite $\Delta x \to 0$ queda la siguiente ecuación diferencial:

$$\boxed{\frac{dP_{I_x}(k=1)}{dx} = \lambda(P_{I_x}(k=0) - P_{I_x}(k=1))}$$

$$P_{I_{x+\Delta x}}(k=0) = P_{I_x}(k=0)P_{I_{\Delta x}}(k=0)$$
$$P_{I_{x+\Delta x}}(k=0) = P_{I_x}(k=0)(1-\lambda\Delta x)$$
$$\frac{P_{I_{x+\Delta x}}(k=0) - P_{I_x}(k=0)}{\Delta x} = -\lambda P_{I_x}(k=0)$$

En la función distribución de probabilidad, la longitud del intervalo es un parámetro, tomando el límite $\Delta x \to 0$ queda la siguiente ecuación diferencial:

$$\frac{dP_{I_x}(k=0)}{dx} = -\lambda P_{I_x}(k=0)$$

que, con la condición inicial $P_{I_0}(k=0)$, tiene como solución

$$\boxed{P_{I_x}(k=0) = e^{-\lambda x}}$$

Reemplazando este resultado en la ecuación diferencial anterior, tenemos

$$\frac{dP_{I_x}(k=1)}{dx} = \lambda(e^{-\lambda x} - P_{I_x}(k=1))$$

Esta expresión se podría generalizar para $k \in \mathbb{N}$, si hubieramos planteado

$$P_{I_{x+\Delta x}}(k) = P_{I_x}(k=k)P_{I_{\Delta x}}(k=0) + P_{I_x}(k=k-1)P_{I_{\Delta x}}(k=1)$$

Quedándonos

$$\boxed{\frac{dP_{I_x}(k)}{dx} = \lambda(e^{-\lambda x} - P_{I_x}(k))}$$

cuya solución es

$$\boxed{P_{Ix}(k) = \frac{e^{-\lambda x}(\lambda x)^k}{k!}}$$

Función Característica y Momentos

La cuenta está hecha en el Ejercicio 9.

$$\boxed{\Phi_X(t) = \exp\left(\mu\left[e^{it} - 1\right]\right)}$$

2.2 Temas del programa

2. Repaso de probabilidades: Variables aleatorias. Probabilidad condicional, independencia y correlación. Teorema de Bayes. Esperanza y varianza. Ley de grandes números. Desigualdad de Chebyshev. Distribución y densidad de probabilidad. Distribuciones multidimensionales y covarianza.

3. Ejemplos de distribuciones importantes: Definición y aplicaciones experimentales de las distribuciones Binomial, Multinomial, de Poisson, Normal, Exponencial, Gama, Log-normal y de Cauchy. Distribuciones de muestreo: chi-cuadrado, t de Student y función F.

Capítulo 3

Distribuciones Continuas

3.1 Distribuciones Contínuas

3.1.1 Conjuntos, álgebra

Definición (Numerable)

Agregar:

Definición (Conjunto no medible)

Agregar:

Definición (Distribución de Probabilidad Contínua)
Sea Ω no numerable (léase $\mathbb{R}$.
Sea S conjunto de los subconjuntos de Ω.

Agregar:

Definición (Álgebra de Borel)
Definimos el *álgebra de Borel* de $\mathbb{R}$ como $\mathscr{B}$ tales que sus elementos sean

- Intervalos abiertos, cerrados, semiabiertos.
- Complementos

- Unión numerable
- Intersección (derivable de lo anterior)

Teorema 3.1
Sea T el conjunto de puntos de $\mathbb{R}$ que tienen $P(X)$ no nula.
Entonces,

$$T = \{P \in \mathbb{R} : P(X(P) > 0)\} \quad \text{es numerable.}$$

3.1.2 Función de Probabilidad Acumulada (CDF)

Definición (Función de Distribución o Función de Distribución Acumulada (CDF))
Sea una variable aleatoria X con una función de probabilidad $P(X = x_i)$.
Se define la *función de distribución* F como

$$F(t) :- P(X \leq t)$$

Proposición 3.2 (Propiedades de la Función de Distribución)
Enunciamos algunas propiedades de las funciones de distribución.

(a) $0 \leq F(t) \leq 1$

(b) $P(a < X \leq b) = F(b) - F(a)$

Demostración.

Sean $a < X \leq b$ y $X \leq a$ dos sucesos disjuntos.

$$P(X \leq a) + P(a < X \leq b) = P(X \leq b)$$

Por definición de la función de distribución,

$$\begin{aligned} F(a) + P(a < X \leq b) &= F(b) \\ P(a < X \leq b) &= F(b) - F(a) \end{aligned}$$

■

(c) $F(a) < F(b) \qquad \forall a < b$

Demostración.

$$\begin{aligned} P(a < X \leq b) &\geq 0 \\ F(b) - F(a) &\geq 0 \\ F(a) &\leq F(b) \end{aligned}$$

■

(d)

$$\begin{cases} \lim\limits_{t\to-\infty} F(t) = 0 \\ \lim\limits_{t\to\infty} F(t) = 1 \end{cases}$$

Demostración.

$$\begin{aligned} P(a < X \leq b) &= F(b) - F(a) \\ \lim_{\substack{a\to-\infty \\ b\to\infty}} P(a < X \leq b) &= \lim_{\substack{a\to-\infty \\ b\to\infty}} F(b) - F(a) \\ P(\mathbb{R}) &= \lim_{t\to\infty} F(b) - \lim_{t\to\infty} F(a) \end{aligned}$$

Agregar:

Me falta un argumento.

■

(e) $P(a \leq X \leq) = F(b) - F(a) + P(a)$

Demostración.

Queda como ejercicio.

Agregar:

■

(f) $F(t)$ es contínua a derecha. Es decir,

$$lim_{h\to 0^+} f(c+h) = f(c) \forall t \in \mathbb{R}$$

Demostración.

$$\begin{cases} P(c < X \leq t) = F(t) - F(c) & \text{Límite por derecha} \\ P(t < X \leq c) = F(c) - F(t) & \text{Límite por izquierda} \end{cases}$$

$$\begin{cases} F(t) = P(c < X \leq t) + F(c) & \text{Límite por derecha} \\ F(t) = F(c) - P(t < X \leq c) & \text{Límite por izquierda} \end{cases}$$

$$\begin{cases} \lim\limits_{t\to c^+} F(t) = \lim\limits_{t\to c^+} P(c < X \leq t) + F(c) & \text{Límite por derecha} \\ \lim\limits_{t\to c^-} F(t) = \lim\limits_{t\to c^-} F(c) - P(t < X \leq c) & \text{Límite por izquierda} \end{cases}$$

$$c < X \leq t = \varnothing$$

y

$$t < X \leq c = \{c\}$$

Agregar:

Quedó feo.

$$\begin{cases} \lim\limits_{t \to c^+} F(t) = \overset{P(\varnothing)}{\cancel{\varnothing}} + F(c) & \text{Límite por derecha} \\ \lim\limits_{t \to c^-} F(t) = F(c) - P(X = c) & \text{Límite por izquierda} \end{cases}$$

$$\begin{cases} \lim\limits_{t \to c^+} F(t) = F(c) & \text{Límite por derecha} \\ \lim\limits_{t \to c^-} F(t) = F(c) - P(X = c) & \text{Límite por izquierda} \end{cases}$$

■

Teorema 3.3 (Vuelta de la proposición anterior)
Sea $F(t)$ una función monótona creciente tal que satisfaga $4.$ y $6.$ de la proposición anterior.
Entonces, $\exists P(X)/$

$$P(a < X \leq) = F(b) - F(a)$$

3.1.3 Función Densidad de Probabilidad (PDF)

Definición (Función Densidad de Probabilidad)
Sea $F(t)$ una función de distribución derivable en $\mathbb{R}$.
Se define la *densidad de probabilidad* $f(t)$ como

$$f(t) :- \frac{dF(t)}{dt}$$

Observación (Probabilidad en función de la Densidad de Probabilidad)
Sea $F(t)$ una función de distribución derivable en $\mathbb{R}$.
Entonces,

$$P(a \leq X \leq b) = F(b) - F(a)$$

Por el Segundo Teorema Fundamental del Cálculo,

$$\boxed{P(a \leq X \leq b) = \int_a^b f(u)\,du}$$

Más informalmente, podríamos escribir

$$P(t \leq X \leq t + dt) = f(t)\,dt$$

Observación
Al estar definida a partir de una derivada, la densidad de probabilidad está definida a menos de un conjunto numerable de puntos.

Teorema 3.4 (Desigualdad de Chebyshev)
Sea X una variable aleatoria que sigue una distribución cualquiera con una esperanza $\mathrm{E}[X]$ y una varianza $\mathrm{Var}(X)$.
Entonces, $\forall c \in \mathbb{R}$,

$$P(|X - \mathrm{E}[X]| > c) \leq \frac{\mathrm{Var}(X)}{c^2} \tag{3.1}$$

Definiendo $c = k\sigma$, tenemos una expresión alternativa.

$$P(|X - \mathrm{E}[X]| > k\sigma) \leq \frac{\cancel{\sigma^2}}{k^2\cancel{\sigma^2}}$$

$$\boxed{P(|X - \mathrm{E}[X]| > k\sigma) \leq \frac{1}{k^2}}$$

Demostración.

$$\begin{aligned}
\mathrm{Var}(X) &= \int_{-\infty}^{\infty} (t-\mu)^2 f_X(t)\,dt \\
&= \left(\int_{-\infty}^{\mu-c} + \int_{\mu-c}^{\mu+c} + \int_{\mu+c}^{\infty}\right)(t-\mu)^2 f_X(t)\,dt \\
&\geq \int_{-\infty}^{\mu-c} (t-\mu)^2 f_X(t)\,dt \int_{\mu+c}^{\infty} (t-\mu)^2 f_X(t)\,dt
\end{aligned}$$

Para $t \in (-\infty, \mu - c) \vee t \in (\mu + c, \infty) \implies (t-\mu)^2 \geq c^2$.

$$\begin{aligned}
&\geq \int_{-\infty}^{\mu-c} c^2 f_X(t)\,dt + \int_{\mu+c}^{\infty} c^2 f_X(t)\,dt \\
&\geq c^2\left(P(X \leq \mu - c) + P(X \geq \mu + c)\right) \\
&\geq c^2 P(|X - \mu| \geq c)
\end{aligned}$$

$$\boxed{\frac{VarX}{c^2} \geq P(|X - \mu| \geq c)}$$

■

Teorema 3.5 (Desigualdad de Vysochanskij)
Sea X una variable aleatoria que sigue una distribución **unimodal** con una esperanza $\mathrm{E}[X]$ y una varianza $\mathrm{Var}(X) \neq 0$.
Entonces, $\forall \lambda > \sqrt{\frac{8}{3}}$,

$$P(|X - \mathrm{E}[X]| > \lambda\sigma) \leq \frac{4}{9}\frac{1}{\lambda^2} \tag{3.2}$$

Observación (Terminología)
Al calificar a una distribución como "uni/bi/multimodal" estamos haciendo referencia al número de máximos locales que tiene esta, pudiendo tener distintos valores cada uno, a diferencia de la definición corriente de moda.

3.1.4 Función Característica (CF)

Definición (Función Caractarística)
Se define la *función caracterísitca* Φ_X como

$$\Phi_X(t) := \mathrm{E}\left[e^{itX}\right] \tag{3.3}$$

que no es más que la Transformada de Fourier de la densidad de probabilidad.

$$\Phi_X(t) = \int_{\infty}^{\infty} e^{itx} f_X(x)\, dx$$
$$\boxed{\Phi_X(t) = \int_{\infty}^{\infty} f_X(x) e^{itx}\, dx}$$

Observación (Sobre la función característica.)
Notemos lo siguiente:

- La función característica siempre existe.
- Hay una biyección entre las funciones características y las densidades de probabilidad.

Veamos que utilidad tiene esta función. Desarrollemos la exponencial en serie.

$$\begin{aligned}\Phi_X(t) &= \mathrm{E}\left[\sum_{n=0}^{\infty}\frac{(itx)^n}{n!}\right]\\ &= \sum_{n=0}^{\infty}\frac{(it)^n}{n!}\mathrm{E}\left[X^n\right]\\ \Phi_X(t) &= \sum_{n=0}^{\infty}\frac{(t)^n}{n!}i^n\mathrm{E}\left[X^n\right]\end{aligned}$$

Igualando con el desarrollo de Taylor en $t = 0$ de Φ_X, vemos que

$$\boxed{\left.\frac{d^n\Phi_X}{dt^n}\right|_{t=0} = i^n\mathrm{E}\left[X^n\right]}$$

o, también,

$$\boxed{\left.\frac{d^n\Phi_X}{d(it)^n}\right|_{t=0} = \mathrm{E}\left[X^n\right]}$$

3.1.5 Función Generadora de Momentos (MGF)

Nota: Motivación de la Función Generadora de Momentos

Supongo que la motivación para esta nueva función es cambiar el it por solamente un t.

Definición (Función Generadora de Momentos)
Se define la *función generadora de momentos* de una distribución o, simplemente, *función generatriz* M_X como

$$M_X := \mathrm{E}\left[e^{tX}\right] \tag{3.4}$$

Haciendo la misma cuenta que para la función característica, obtenemos

$$\boxed{\left.\frac{d^nM_X}{d(t)^n}\right|_{t=0} = \mathrm{E}\left[X^n\right]}$$

Teorema 3.6 (MGF de una Combinación Lineal)
Sean $\{X_i\}_{i=1,\ldots,n}$ variables aleatorias independientes.
Sea $Y = \sum_{i=1} na_iX_i$. Entonces,

$$M_Y(t) = \prod_{i=1} M_{X_i}(a_it) \tag{3.5}$$

Demostración.

$$\begin{aligned} M_Y(t) &= \mathrm{E}\left[e^{tY}\right] \\ &= \mathrm{E}\left[e^{t(\sum_{i=1} na_i X_i)}\right] \end{aligned}$$

Como las X_i son independientes, por linealidad de la esperanza,

$$= \prod_{i=1}^{n} \mathrm{E}\left[e^{ta_i X_i}\right]$$

$$\boxed{M_Y(t) = \prod_{i=1}^{n} M_{X_i}(a_i t)}$$

■

3.1.6 Función Generadora de Probabilidad (PGF)

Definición (Función Generadora de Probabilidad)
Se define la *función generadora de probabilidad* G_X como

$$G_X(t) := \mathrm{E}\left[t^X\right] \tag{3.6}$$

De la misma forma que venimos haciendo

$$\sum_{k=0}^{\infty} \frac{G^{(k)}(0)}{k!} z^k = \sum_{k=0}^{\infty} P(X = k) z^k \qquad \boxed{\frac{G^{(k)}(0)}{k!} = P(X = k)}$$

3.1.7 Cambio de Variable

Teorema 3.7 (Cambio de Variables)
Sea X una variable aleatoria.
Sea $Y = g(X)$.
Entonces,

$$f_Y(y) = f_X\left(g^{-1}(y)\right) \left| \frac{dg^{-1}}{dy}(y) \right|$$

En general, si $\mathbf{X}, \mathbf{Y} \in \mathbb{R}^n$.

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}\left(G^{-1}(\mathbf{y})\right) \left| \frac{\partial \mathbf{x}}{\partial \mathbf{y}}(\mathbf{y}) \right|$$

Nota:

Creo que esto solo vale para transformaciones biyectivas y transformaciones no biyectivas hacer como en el Ejemplo 3. Lo tendría que pensar, pero no tengo ganas.

Ejemplo/Ejercicio: Ejemplo 1 de Función de Variable Aleatoria

Sea X una variable aleatoria tal que

$$f_X(x) = \begin{cases} 1 & x \in [0,1] \\ 0 & x \notin [0,1] \end{cases}$$

$$F_X(x) = \begin{cases} t & x \geq 0 \\ 0 & x \leq 0 \end{cases}$$

Sea Y la variable aleatoria definida como

$$Y = \frac{X}{1-X}$$

Vemos que $Y \in [0, +\infty)$.

$$F_Y(y) = P(Y \leq y)$$

$$\begin{aligned} Y &\leq y \\ \frac{X}{1-X} &\leq y \\ X &\leq y - Xy \\ X &\leq \frac{y}{1+y} \end{aligned}$$

$$\begin{aligned} F_Y(y) &= P\left(X \leq \frac{y}{1+y}\right) \\ &= F_X\left(\frac{y}{1+y}\right) \\ F_Y(y) &= \frac{y}{1+y} \end{aligned}$$

Y, su densidad de probabilidad queda

$$\boxed{f_Y(y) = \frac{1}{(1+y)^2}}$$

Ejemplo/Ejercicio: Ejemplo 2 (Ejercicio 5) - Distribución de Cauchy

Ejercicio 5.

Ejemplo/Ejercicio: Ejemplo 3 (Ejercicio 6) - Distribución Chi-Cuadrado

[label = Ejemplo 3] Consideremos un caso más general, donde solo se da la relación entre Y e X pero no la PDF de X.
Sea $Y = X^2$.

$$F_Y(y) = P(Y \leq y)$$

$$\begin{aligned} Y &\leq y \\ X^2 &\leq y \\ |X| &\leq \sqrt{y} \end{aligned}$$

$$\begin{aligned} F_Y(y) &= P(|X| \leq \sqrt{y}) \\ &= P(X \leq \sqrt{y}) - P(X \leq -\sqrt{y}) \\ F_Y(y) &= F_X(\sqrt{y}) - F_X(-\sqrt{y}) \end{aligned}$$

Derivamos para tener la PDF.

$$\begin{aligned} \frac{dF_Y(y)}{dy} &= \frac{d}{dy}\left(F_X(\sqrt{y}) - F_X(-\sqrt{y})\right) \\ f_Y(y) &= f_X(\sqrt{y})\frac{1}{2\sqrt{y}} \cancel{-} f_X(-\sqrt{y})\frac{\cancel{-}1}{2\sqrt{y}} \\ \boxed{f_Y(y) = \frac{1}{2\sqrt{y}}\left(f_X(\sqrt{y}) + f_X(-\sqrt{y})\right)} \end{aligned}$$

Ahora, calculemos para $f_X = \mathcal{N}(0,1)$.

$$\boxed{f_Y(y) = \frac{1}{\sqrt{2\pi y}} e^{-\frac{y}{2}}}$$

Distribución Chi-cuadrado

3.1.8 Algunas distribuciones

Distribución Uniforme

Definición (Distribución Uniforme)
Se define la *distribución uniforme* como

$$U(X = t|a, b) := \begin{cases} \frac{1}{b-a} & x \in [a, b] \\ 0 & x \notin [a, b] \end{cases}$$

Esperanza

$$\boxed{\mathrm{E}\left[X\right] = \frac{a+b}{2}}$$

Varianza y Desviación Estándar

$$\boxed{\mathrm{Var}\left(X\right) = \frac{(b-a)^2}{12}}$$

$$\sigma = \frac{b-a}{\sqrt{12}}$$

Distribución Exponencial

Definición (Distribución Exponencial)
Se define la *distribución exponencial* como

$$E(X = t|\lambda) := \lambda e^{-\lambda t} \qquad \forall t > 0$$

Agregar: Derivación a partir de Poisson (Ejercicio 3)

Consideremos una probabilidad de la forma

$$P(X \leq t + dt|X \geq t) = \lambda\, dt$$

Observación: Derivación a partir de Poisson

En la distribución de Poisson, reemplazamos $\mu = \lambda t$. Consideramos la diferencia entre cada "exito" de la distribución de Possion.

Observación:

Es la única distribución de variable continua sin memoria, es decir,

$$P(X > t + s|X > t) = P(X > s) \tag{3.7}$$

La cuenta está hecha en el ejercicio 3)b. de la Guía 3.

Esperanza

$$\boxed{\mathrm{E}\left[X\right] = \frac{1}{\lambda}}$$

Varianza

$$\boxed{\mathrm{Var}\left(X\right) = \frac{1}{\lambda^2}}$$

Distribución Normal o Gaussiana

Definición (Distribución Normal o Gaussiana)
Se define la *distribución normal* o *gaussiana* como

$$N(X = t|\mu, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{t-\mu}{\sigma}\right)^2}$$

Función Distribución (CFD)

$$\boxed{F_X(x|\mu, \sigma) = \frac{1}{2}\left[1 + \mathrm{erf}\left(\frac{x-\mu}{\sigma\sqrt{2}}\right)\right]}$$

Comentario Matemático: Propiedades de la función Error $\mathrm{erf}(x)$

(a) Impar

$$\mathrm{erf}(-x) = -\,\mathrm{erf}(x)$$

Función Característica y Momentos

Ejercicio 9

La cuenta está hecha en el Ejercicio 9.

$$\boxed{\Phi_X(t) = e^{\mu it + \frac{1}{2}(it)^2\sigma^2}}$$

$$\frac{d\Phi_X}{dit} = (\mu it + \frac{1}{2}(it)^2\sigma^2)e^{\mu it + \frac{1}{2}(it)^2\sigma^2}(\mu + (it)\sigma^2)$$

Esperanza

$$\boxed{\mathrm{E}\left[X\right] = \mu}$$

Varianza

$$\boxed{\mathrm{Var}\,(X) = \sigma^2}$$

Tabla 3.1: Tabla de probabilidad de que la variable aleatoria esté contenida en el intervalo $[\mu - n\sigma, \mu + n\sigma]$.

n	$P(X \in [\mu - n\sigma, \mu + n\sigma])$
1	0.682689492137
2	0.954499736104
3	0.997300203937
4	0.999936657516
5	0.999999426697
6	0.999999998027

Observación: Errores Gaussianos

Decimos que tenemos "errores gaussianos" si la probabilidad de obtener cierto valores en nuestra medición sigue una distribución gaussiana.

$$P(\mu - \sigma < X < \mu + \sigma) = 0.68$$

Despejando μ en ambas desigualades, tenemos

$$P(X - \sigma < \mu < X - \sigma) = 0.68$$

Esto define un intervalo aleatorio $[X - \sigma, X + \sigma]$ cuya probabilidad de contener a μ es $\approx 68\,\%$.

Nota:

Esto de despejar los intervalos es útil y tendría que valer siempre, no sé por qué lo dio con la gaussiana.

Distribución de Cauchy (Lorentziana)

Definición (Distribución de Cauchy)
Se define la *distribución de Cauchy* como

$$f(X|x_0, \gamma) = \frac{1}{\pi\gamma\left[1 + \left(\frac{x - x_0}{\gamma}\right)^2\right]} \tag{3.8}$$

Un caso particular que se conoce como *distribución estándar de Cauchy* es cuando $x_0 = 0$ y $\gamma = 1$.

$$f(X|0, 1) = \frac{1}{\pi(1 + x^2} \tag{3.9}$$

Observación (Momentos)
Al no decaer lo suficientemente rápido. No tiene definido ningún momento.

Distribución Chi-Cuadrado

Definición (Distribución Chi-cuadrado (1 grado de libertad))
Se define la *distribución Chi-cuadrado (1 grado de libertad)* como

$$f_X(x) = \frac{1}{\sqrt{2\pi x}} e^{-\frac{x}{2}} \tag{3.10}$$

Decimos que tiene 1 grado de libertad porque es la distribución que tiene una variable aleatoria Y definida como el cuadrado de **una** variable aleatoria X que sigue una Gaussiana.

Esperanza

$$\boxed{\mathrm{E}\left[X\right] = 1}$$

Varianza

$$\boxed{\mathrm{Var}\left(X\right) = 2}$$

Distribución Gamma

Definición (Distribución de Cauchy)
Se define la *distribución gamma* como

$$\Gamma(\alpha, \lambda) = \frac{\lambda(\lambda x)^{\alpha-1} e^{-\lambda x}}{\Gamma(\alpha)} \tag{3.11}$$

con $\alpha, \lambda > 0$.

Comentario Matemático: Propiedades

- **Suma de V.A. con distribución Gamma:** Sea $X_i \sim \Gamma(\alpha_i, \lambda)$. Entonces,

$$\sum_{i=1}^{n} X_i \sim \Gamma(\sum_{i=1}^{n} \alpha_i, \lambda)$$

- **Escala:** Sea $X \sim \Gamma(\alpha, \lambda)$. Entonces,

$$cX \sim \Gamma\left(\alpha, \frac{\lambda}{c}\right)$$

Demostración.
Haciendo un cambio de variable. ■

Comentario Matemático: Casos Especiales

- Distribución Erlang Erlang(n, λ):

$$\begin{cases} \alpha = n & n \in \mathbb{N} \\ \lambda = \lambda \end{cases}$$

- Distribución Exponencial Exp(λ):

$$\begin{cases} \alpha = 1 \\ \lambda = \lambda \end{cases}$$

- Distribución Chi-cuadrado χ^2_n:

$$\begin{cases} \alpha = n/2 & n \in \mathbb{N} \\ \lambda = \dfrac{1}{2} \end{cases}$$

Nota: Relación entre algunas distribuciones

Relación entre algunas distribuciones

- Ejercicio 5 de la Guía 3. (Ángulo y tangente)
- Cociente de dos variables aleatorias $X, Y \sim N(0, \sigma)$

3.2 Temas del Programa

2. Repaso de probabilidades: Variables aleatorias. Probabilidad condicional, independencia y correlación. Teorema de Bayes. Esperanza y varianza. Ley de grandes números. Desigualdad de Chebyshev. Distribución y densidad de probabilidad. Distribuciones multidimensionales y covarianza.

3. Ejemplos de distribuciones importantes: Definición y aplicaciones experimentales de las distribuciones Binomial, Multinomial, de Poisson, Normal, Exponencial, Gama, Log-normal y de Cauchy. Distribuciones de muestreo: chi-cuadrado, t de Student y función F.

Capítulo 4

Distribuciones Multidimensionales

4.1 Distribuciones Multivariables

4.1.1 Probabilidades Marginal y Condicional

Sean X e Y 2 varaibles aleatorias con resultados $\{x_i\}$ y $\{y_j\}$. El espacio muestral está formado por pares de estas variables aleatorias y sus probabilidades están dadas por

$$P(X = x_i \cup Y = y_j) = p_{ij}$$

Definición (Probabilidad Marginal)
Se define la *probabilidad marginal* como la probabilidad de un suceso en una variable aleatoria, sin importar los otros en las otras variables.

$$P_X(X = x_i) = \sum_j P(X = x_i \cup Y = y_j) \tag{4.1}$$

La definición de la probabilidad condicional multivaraible es conceptualmente idéntica a la del caso univariable.

Definición (Probabilidad Condicional)
Se define la *probabilidad condicional* como

$$P(X = x_i \mid Y = y_j) = \frac{P(X = x_i \cap Y = y_j)}{P(Y = y_j)}$$

Definición (Densidad de Probabilidad Condicional)
Sea $f_{XY}(x, y)$ una PDF.

Sea $A = \{Y \in [y, y + dy]\}$.
Se define la *densidad de probabilidad condicional* como

$$f_X(x \mid A)dx := P(X \in [x, x + dx] \mid A)$$

Observación (Caso particular $A = \{Y = y\}$.)

Si consideramos $A = \{y < Y < y + dy\}$,

$$P(x < X < x + dx \mid y < Y < y + dy) = \frac{P(x < X < x + dx \cap y < Y < y + dy)}{P(y < Y < y + dy)}$$

No me cierra el pasaje de $A = \{y < Y < y + dy\}$ a $A = \{Y = y\}$.

$$f_X(x \mid y)\, dx = \frac{f_{XY}(x, y)\, dxdy}{f_Y(y)\, dy}$$

$$f_X(x \mid y)\, \cancel{dx} = \frac{f_{XY}(x, y)\, \cancel{dx}\cancel{dy}}{f_Y(y)\, \cancel{dy}}$$

$$\boxed{f_X(x \mid y) = \frac{f_{XY}(x, y)}{f_Y(y)}}$$

Agregar: Paradoja de Borel-Kolmogorov

No sé si mi duda en la cuenta anterior está relacionada con la Paradoja de Borel-Kolmogorov

---

Otra fórmula para B_j disjuntos

$$P(A) = \sum_k P(A \mid B_k)P(B_k)$$

Siguiendo con las extensiones al caso multivariable continuo,

$$\boxed{f_X(x) = \int f_X(x \mid y) f_Y(y)\, dy}$$

El Teorema de Bayes queda

$$f_X(x \mid y) = \frac{f_Y(y \mid x) f_X(x)}{f_Y(y)}$$

4.1.2 Esperanza

Definición (Esperanza Condicional)
Sea $f_{X|Y}(x \mid y)$ una distribución de probabilidad condicional.
Se define la *esperanza condicional* como

$$\mathrm{E}\left[X \mid Y\right] = \int X f_{X|Y}(x \mid y)\, dx \tag{4.2}$$

4.1.3 Varianza y Covarianza

En distribuciones multivariables la varianza puede calcularse como

$$\begin{aligned}
\mathrm{Var}\left(X_i\right) &= \int_{\mathbb{R}^n} \left(\prod_{i=1}^{n}(x_i - \mu_i)\right) f_{\mathbf{X}}(\mathbf{x})\, d^n\mathbf{x} \\
&= \int (x_i - \mu_i) \left[\int_{\mathbb{R}^{n-1}} \left(\prod_{i\neq j}(x_i - \mu_i)\right) f_{\mathbf{X}}(\mathbf{x}) \prod_{i\neq j}(dx_i)\right] dx_i
\end{aligned}$$

$$\boxed{\mathrm{Var}\left(X_i\right) = \int (x_i - \mu_i) f_{X_i}(x_i) dx_i}$$

Definición (Covarianza)
Sean X y Y dos variables aleatorias con $\mathrm{E}\left[X\right], \mathrm{E}\left[Y\right] < \infty$.
Se define la *covarianza* entre X e Y como

$$\mathrm{Cov}\left(X, Y\right) \coloneqq \mathrm{E}\left[(X - \mu_X)(Y - \mu_Y)\right] \tag{4.3}$$

Al igual que la varianza, usando la linealidad de la esperanza, podemos encontrar una expresión equivalente.

$$\mathrm{Cov}\left(X, Y\right) = \mathrm{E}\left[XY\right] - \mathrm{E}\left[X\right]\mathrm{E}\left[Y\right]$$

Definición (Matriz de Covarianza)
Sean $\{X_i\}_n$ n variables aleatorias.
Se define la *matriz de covarianza* como

$$\Sigma_{ij} \coloneqq \mathrm{Cov}\left(X_i, X_j\right) \tag{4.4}$$

Observación

$$\mathrm{Cov}\left(X_i, X_i\right) = \mathrm{Var}\left(X_i\right)$$

Proposición 4.1
Varianza de una combinación lineal

$$\mathrm{Var}\left(\sum_{i=1}^{n} a_i X_i\right) = \sum_{i=1}^{n} a_i^2 \mathrm{Var}\left(X_i\right) + 2\sum_{i=1}^{n}\sum_{j>i}^{n} a_i a_j \mathrm{Cov}\left(X_i, X_j\right)$$

Ejemplo/Ejercicio: Varianza del promedio: Ejercicio 1 de la Guía 6

Sean $\{X_i\}_n$ n mediciones independientes de un experimento: son varaibles aleatorias i.i.d. El promedio

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$$

es una combinación lineal de variables aleatorias. Vale, entonces,

$$\mathrm{Var}\left(\sum_{i=1}^{n} \frac{1}{n} X_i\right) = \sum_{i=1}^{n} \left(\frac{1}{n}\right)^2 \mathrm{Var}\left(x_i\right) + 2\sum_{i=1}^{n}\sum_{j>i}^{n} \left(\frac{1}{n}\right)^2 \mathrm{Cov}\left(X_i, X_j\right)$$

Además, $\mathrm{Cov}\left(X_i, X_j\right) = 0$ porque las mediciones son independientes.

$$\mathrm{Var}\left(\sum_{i=1}^{n} \frac{1}{n} X_i\right) = \left(\frac{1}{n}\right)^2 \sum_{i=1}^{n} \mathrm{Var}\left(x_i\right)$$

y $\sigma = \sigma_i$ pues son identicamente distribuidas, quedando

$$\begin{aligned}\mathrm{Var}\left(\sum_{i=1}^{n} \frac{1}{n} X_i\right) &= \left(\frac{1}{n}\right)^2 \sum_{i=1}^{n} \sigma^2 \\ &= \frac{1}{n^{\cancel{2}}}\cancel{n}\sigma^2\end{aligned}$$

$$\boxed{\mathrm{Var}\left(\sum_{i=1}^{n} \frac{1}{n} X_i\right) = \left(\frac{\sigma}{\sqrt{n}}\right)^2}$$

Observación (Covarianza nula)
Sean X e Y dos variables aleatorias tal que

$$\mathrm{Cov}\left(X, Y\right) = 0.$$

Decimos que X e Y son *no correlacionadas*.

Proposición 4.2 (Independencia implica no correlación)

Sean X_1 y X_2 dos variables aleatorias.
Entonces,

$$f_{X_1X_2}(x_1, x_2) = f_{X_1}(x_1)f_{X_2}(x_2) \Rightarrow \mathrm{Cov}\,(X_1, X_2) = 0 \tag{4.5}$$

Demostración.

Teórica 10 - 1:43:00 ■

Observación (Signo de la covarianza)
Indica cómo varían las variables conjuntamente.

- Si $\mathrm{Cov}\,(X, Y) > 0$, $\mathrm{E}\,[X - \mu_X \mid Y - \mu_Y] > 0$.
- Si $\mathrm{Cov}\,(X, Y) < 0$, $\mathrm{E}\,[X - \mu_X \mid Y - \mu_Y] < 0$.

Nota:

Los valores medios lo agregué yo. En la teórica estaban centradas en 0.

Para $\mu_X = \mu_Y = 0$, podemos escribir

$$\begin{aligned}
\mathrm{Cov}\,(X, Y) &= \iint xyf_{XY}(x, y)\,dx\,dy \\
&= \iint xyf_{X|Y}(x \mid y)f_Y(y)\,dx\,dy \\
&= \int y\left[\int xf_{X|Y}(x \mid y)\,dx\right] f_Y(y)\,dy
\end{aligned}$$

$$\boxed{\mathrm{Cov}\,(X, Y) = \int yf_Y(y)\,\mathrm{E}\,[X \mid Y]\;dy}$$

4.1.4 Factor de Correlación

Definición (Factor de Correlación)
Se define al *factor de correlación* ρ como

$$\rho := \frac{\mathrm{Cov}\,(X, Y)}{\sigma_X\sigma_Y} \tag{4.6}$$

Observación:

$$\begin{aligned}
\mathrm{Var}\,(kX + Y) &= k^2\mathrm{Var}\,(X) + \mathrm{Var}\,(Y) + 2k\mathrm{Cov}\,(X, Y) \\
\mathrm{Var}\,(kX + Y) &= \mathrm{Var}\,(X)\,k^2 + 2\mathrm{Cov}\,(X, Y)\,k + \mathrm{Var}\,(Y)
\end{aligned}$$

$$\begin{aligned}\mathrm{Var}\left(kX+Y\right) \geq 0 &\iff \left(2\mathrm{Cov}\left(X,Y\right)\right)^2 - 4\mathrm{Var}\left(X\right)\mathrm{Var}\left(Y\right) < 0 \\ &\iff \mathrm{Cov}\left(X,Y\right)^2 < \mathrm{Var}\left(X\right)\mathrm{Var}\left(Y\right)\end{aligned}$$

<u>$\rho \in \{1,-1\}$</u>

$$Y = -kX + c$$

- Para $\rho = \quad 1$, $\mathrm{Cov}\left(X,Y\right) > 0 \implies k < 0$.
- Para $\rho = -1$, $\mathrm{Cov}\left(X,Y\right) < 0 \implies k > 0$.

4.1.5 Función Característica

Para variables independientes

$$\boxed{\Phi_{\sum_{i=1}^n X_i}(t) = \prod_{i=1}^n \Phi_{X_i}(t)}$$

Tomando el logaritmo,

$$\boxed{\ln\left(\Phi_{\sum_{i=1}^n X_i}(t)\right) = \sum_{i=1}^n \ln\left(\Phi_{X_i}(t)\right)}$$

Desarrollando en serie de Taylor,

$$\ln\Phi(t) = \sum_{k=0}^{\infty} \frac{1}{k!} \left.\frac{d^k \ln\Phi}{dt^n}\right|_{t=0} t^k$$

Derivando el logaritmo y usando que $\frac{d^k\Phi}{d(it)^k} = \mathrm{E}\left[X^k\right]$,

$$\boxed{\ln\Phi(t) = i\mu t - \frac{1}{2}\sigma^2 t^2 - \frac{i}{6}M_3 + O(t^4)}$$

con $M_3 = \langle x^3\rangle - 3\langle x\rangle\langle x^2\rangle + 2\langle x\rangle^3$.

Para la gaussiana,

$$\ln\Phi(t) = i\mu t - \frac{1}{2}t^2\sigma^2$$

donde se ve que la suma de variables aleatorias gaussianas es gaussiana. También vemos que a través de $\ln\Phi$, tiene una expresión muy simple.

4.1.6 Propagación de Errores: Cambio de Variables

Ejemplo/Ejercicio: Ejemplo 1: Suma de 2 variables aleatorias (Ejercicio 3a.)

Sea $U = X + Y$.

$$\boxed{f_{X+Y} = \int_{-\infty}^{\infty} f_{XY}(x, u - x)\, dx}$$

Si, además, X e Y son independientes,

$$f_{X+Y} = \int_{-\infty}^{\infty} f_X(x) f_Y(u - x)\, dx$$
$$\boxed{f_{X+Y} = (f * g)}$$

Sean las variables aleatorias $X, Y \in D$ definidas como una función de $U, V \in D'$. Si la transformación $T : (U, V) \to (X, Y)$ es inyectiva,

$$P(U, V) \in T') = P(X, Y \in T)$$
$$\iint_{T'} f_{UV}(u, v)\, dudv = \iint_{T} f_{XY}(x, y)\, dxdy$$

Hacemos el cambio de variables.

$$= \iint_{T'} f_{XY}(x(u, v), y(u, v))|\det DT|\, dudv$$
$$\boxed{f_{UV}(u, v) = f_{XY}(x(u, v), y(u, v))|\det DT|}$$

Ejemplo/Ejercicio: Ejemplo 2: Suma de n gaussianas (Chicuadrado con n grados de libertad)

Suma de Gaussianas $N(0, 1)$.

Comentario Matemático: Función Gamma

Definición: Función Gamma

$$\Gamma(z) := \int_0^\infty e^{-t} t^{z-1}\, dt \tag{4.7}$$

- $$\begin{aligned} \Gamma(z+1) &= z\Gamma(z) \\ \Rightarrow &\boxed{\Gamma(n+1) = n!} \end{aligned}$$

- $$\begin{cases} \Gamma(1) = 1 \\ \Gamma\left(\frac{1}{2}\right) = \sqrt{\pi} \end{cases}$$

$$\boxed{F(u) = \frac{1}{2^{\frac{n}{2}}\Gamma\left(\frac{n}{2}\right)} e^{-\frac{u}{2}} u^{\frac{n}{2}-1}}$$

$$\mathrm{E}\left[X\right] = n\mathrm{Var}\left(X\right) \qquad = 2n\sigma = \sqrt{2n}$$

Observación:

Suma de variables aleatorias χ^2_n y χ^2_m es χ^2_{m+n}.

4.1.7 Aproximación Lineal

Sean $Y_k = Y_k(X_i)$ con $k = 1 \cdots m$ e $i = 1 \cdots n$ $(m \leq n)$.

En vez de calcular la distribución para las nuevas variables $\{Y_i\}$, nos conformamos con determinar $\mathrm{E}\left[Y_k\right]$ y $\mathrm{Var}\left(Y_k\right)$. Esto lo haremos a partir de con $\mu_i = \mathrm{E}\left[X_i\right]$ y $\mathrm{Cov}\left(X_i, X_j\right)$ (no hace falta conocer la distribución de las X_i.

Desarrollamos y_k en $\boldsymbol{\mu}$.

$$Y_k(\mathbf{X}) = Y_k(\boldsymbol{\mu}) + \sum_{i=1}^{n} \left.\frac{\partial Y_k}{\partial X_i}\right|_{\boldsymbol{\mu}} (X_i - \mu_i) + O\left((X_i - \mu_i)^2\right)$$

Por otro lado, tomando la esperanza,

$$\mathrm{E}\left[Y_k\right] = Y_k(\boldsymbol{\mu}) + \sum_{i=1}^{n} \left.\frac{\partial Y_k}{\partial X_i}\right|_{\boldsymbol{\mu}} \cancelto{0}{\mathrm{E}\left[(X_i - \mu_i)\right]} + O\left((X_i - \mu_i)^2\right)$$

$$\boxed{\mathrm{E}\left[Y_k\right] \approx Y_k(\boldsymbol{\mu})}$$

Para dos variables Y_k e Y_l, tenemos

$$\begin{cases} Y_k - \mathrm{E}\left[Y_k\right] \approx \displaystyle\sum_{i=1}^{n} \left.\frac{\partial Y_k}{\partial X_i}\right|_{\boldsymbol{\mu}} (X_i - \mu_i) \\ Y_l - \mathrm{E}\left[Y_l\right] \approx \displaystyle\sum_{i=j}^{n} \left.\frac{\partial Y_l}{\partial X_j}\right|_{\boldsymbol{\mu}} (X_j - \mu_j) \end{cases}$$

Ahora que tenemos esto, calculemos la covarianza de las nuevas variables. Por definición,

$$\mathrm{Cov}\left(Y_k, Y_l\right) = \mathrm{E}\left[(Y_k - \mathrm{E}\left[Y_k\right])(Y_l - \mathrm{E}\left[Y_l\right])\right]$$

Hacemos la aproximación lineal.

$$\approx \mathrm{E}\left[\left(\sum_{i=1}^{n} \left.\frac{\partial Y_k}{\partial X_i}\right|_{\boldsymbol{\mu}} (X_i - \mu_i)\right)\left(\sum_{j=1}^{n} \left.\frac{\partial Y_l}{\partial X_j}\right|_{\boldsymbol{\mu}} (X_j - \mu_j)\right)\right]$$

Dejamos de lado el $\approx$ porque se sobre entiende que esto es válido a primer orden.

$$= \mathrm{E}\left[\sum_{i=1}^{n}\sum_{j=1}^{n} \left.\frac{\partial Y_k}{\partial X_i}\right|_{\boldsymbol{\mu}} \left.\frac{\partial Y_l}{\partial X_j}\right|_{\boldsymbol{\mu}} (X_i - \mu_i)(X_j - \mu_j)\right]$$

Por la linealidad de la esperanza, saco términos constantes y la sumatoria fuera.

$$= \sum_{i=1}^{n}\sum_{j=1}^{n} \left.\frac{\partial Y_k}{\partial X_i}\right|_{\boldsymbol{\mu}} \left.\frac{\partial Y_l}{\partial X_j}\right|_{\boldsymbol{\mu}} \mathrm{E}\left[(X_i - \mu_i)(X_j - \mu_j)\right]$$

$$\boxed{\mathrm{Cov}\left(Y_k, Y_l\right) = \sum_{i=1}^{n}\sum_{j=1}^{n} \left.\frac{\partial Y_k}{\partial X_i}\right|_{\boldsymbol{\mu}} \left.\frac{\partial Y_l}{\partial X_j}\right|_{\boldsymbol{\mu}} \mathrm{Cov}\left(X_i, X_j\right)} \tag{4.8}$$

Si las variables X_i no son independientes, la formula para la varianza de Y_k queda

$$\begin{aligned}\mathrm{Var}\left(Y_k\right) &= \sum_{i=1}^{n}\sum_{j=1}^{n}\left.\frac{\partial Y_k}{\partial X_i}\right|_{\boldsymbol{\mu}}\left.\frac{\partial Y_k}{\partial X_j}\right|_{\boldsymbol{\mu}}\mathrm{Cov}\left(X_i,X_j\right)\\ &= \sum_{i=1}^{n}\left(\left.\frac{\partial Y_k}{\partial X_i}\right|_{\boldsymbol{\mu}}\left.\frac{\partial Y_k}{\partial X_i}\right|_{\boldsymbol{\mu}}\mathrm{Var}\left(X_i\right)+\sum_{j\neq i}^{n}\left.\frac{\partial Y_k}{\partial X_i}\right|_{\boldsymbol{\mu}}\left.\frac{\partial Y_k}{\partial X_j}\right|_{\boldsymbol{\mu}}\mathrm{Cov}\left(X_i,X_j\right)\right)\end{aligned}$$

Como $\mathrm{Cov}\left(X_i,X_j\right)=\mathrm{Cov}\left(X_j,X_i\right)$,

$$= \sum_{i=1}^{n}\left(\left(\left.\frac{\partial Y_k}{\partial X_i}\right|_{\boldsymbol{\mu}}\right)^2\mathrm{Var}\left(X_i\right)+2\sum_{j>i}^{n}\left.\frac{\partial Y_k}{\partial X_i}\right|_{\boldsymbol{\mu}}\left.\frac{\partial Y_k}{\partial X_j}\right|_{\boldsymbol{\mu}}\mathrm{Cov}\left(X_i,X_j\right)\right)$$

$$\boxed{\mathrm{Var}\left(Y_k\right)=\sum_{i=1}^{n}\left(\left.\frac{\partial Y_k}{\partial X_i}\right|_{\boldsymbol{\mu}}\right)^2\mathrm{Var}\left(X_i\right)+2\sum_{i=1}^{n}\sum_{j>i}^{n}\left.\frac{\partial Y_k}{\partial X_i}\right|_{\boldsymbol{\mu}}\left.\frac{\partial Y_k}{\partial X_j}\right|_{\boldsymbol{\mu}}\mathrm{Cov}\left(X_i,X_j\right)} \tag{4.9}$$

Si las variables aleatorias son independientes (o, por lo menos, no correlacionadas), $\mathrm{Cov}\left(X_i,X_j\right)=\delta_{ij}\mathrm{Var}\left(X_i\right)$.

$$\mathrm{Cov}\left(Y_k,Y_l\right)=\sum_{i=1}^{n}\sum_{j=1}^{n}\left.\frac{\partial Y_k}{\partial X_i}\right|_{\boldsymbol{\mu}}\left.\frac{\partial Y_l}{\partial X_j}\right|_{\boldsymbol{\mu}}\delta_{ij}\mathrm{Var}\left(X_i\right)$$

$$\boxed{\mathrm{Cov}\left(Y_k,Y_l\right)=\sum_{i=1}^{n}\left.\frac{\partial Y_k}{\partial X_i}\right|_{\boldsymbol{\mu}}\left.\frac{\partial Y_l}{\partial X_i}\right|_{\boldsymbol{\mu}}\mathrm{Var}\left(X_i\right)} \tag{4.10}$$

Vemos que la varianza de las desviación estándar de las nuevas variables queda

$$\begin{aligned}\mathrm{Var}\left(Y_k\right) &= \mathrm{Cov}\left(Y_k,Y_k\right)\\ &= \sum_{i=1}^{n}\left.\frac{\partial Y_k}{\partial X_i}\right|_{\boldsymbol{\mu}}\left.\frac{\partial Y_k}{\partial X_i}\right|_{\boldsymbol{\mu}}\mathrm{Var}\left(X_i\right)\\ &= \sum_{i=1}^{n}\left(\left.\frac{\partial Y_k}{\partial X_i}\right|_{\boldsymbol{\mu}}\right)^2\mathrm{Var}\left(X_i\right)\\ &= \sum_{i=1}^{n}\left(\left.\frac{\partial Y_k}{\partial X_i}\right|_{\boldsymbol{\mu}}\right)^2\sigma_{X_i}^2\\ &= \sum_{i=1}^{n}\left(\left.\frac{\partial Y_k}{\partial X_i}\right|_{\boldsymbol{\mu}}\sigma_{X_i}\right)^2\end{aligned}$$

$$\boxed{\sigma_{Y_k}=\sqrt{\sum_{i=1}^{n}\left(\left.\frac{\partial Y_k}{\partial X_i}\right|_{\boldsymbol{\mu}}\sigma_{X_i}\right)^2}} \tag{4.11}$$

4.2 Teorema del Límite Central

Teorema 4.3 (Teorema del Límite Central)
Sean X_i variables aleatorias independientes con esperanza $\mathrm{E}[X_i] = \mu_i$ y $\mathrm{Var}(X_i) = \sigma^2$.
Sea $Z = \sum_{i=1}^n X_i$. $\Rightarrow \mathrm{E}[Z] = \sum_{i=1}^n \mu_i$ y $\mathrm{Var}(Z) = n\sigma^2$.
Sea

$$Y_n = \frac{Z - \sum_{i=1}^n \mu_i}{\sqrt{n}\sigma}.$$

Entonces,

$$\lim_{n\to\infty} f_{Y_n}(z) = N(0,1) \tag{4.12}$$

Demostración.

$$\begin{aligned}
\Phi_Y(t) &= \mathrm{E}\left[e^{itY}\right] \\
&= \mathrm{E}\left[e^{it\frac{\sum_{i=1}^n X_i - \sum_{i=1}^n \mu_i}{\sqrt{n}\sigma}}\right] \\
&= \mathrm{E}\left[e^{i\frac{t}{\sqrt{n}\sigma}\left(\sum_{i=1}^n X_i - \sum_{i=1}^n \mu_i\right)}\right]
\end{aligned}$$

■

Nota:

Este teorema es como una mezcla del CLT clásico, donde las X_i son i.i.d. y el de Lindberg.

Agregar:

- Suma de Binomiales es Binomial
- Suma de Poissonianas es Poissoniana
- Como podemos escribir una Binomial / Poissoniana (Z) como una suma de Binomiales $\mathcal{B}(m/n|p)$ / Poissonianas $\mathcal{P}(\frac{\mu}{n})$, podemos aproximar con Normal. Podemos, también, hacer un cambio de variables.

Nota:

Con esos argumentos, no me queda claro por qué la Poissoniana no es *exactamente* una Normal.

4.3 Algunas Distribuciones

4.3.1 Distribución Multinormal

Ejercicio 10 - Guía 4

Proposición 4.4 (Equivalencia Independencia y No Correlación)
En esta distribución, vale

$$\mathrm{Cov}\,(X_1, X_2) = 0 \iff f_{\mathbf{X}} = \prod_{i=1}^{n} f_{X_i}$$

4.4 Temas del Programa

2. Repaso de probabilidades: Variables aleatorias. Probabilidad condicional, independencia y correlación. Teorema de Bayes. Esperanza y varianza. Ley de grandes números. Desigualdad de Chebyshev. Distribución y densidad de probabilidad. Distribuciones multidimensionales y covarianza.

3. Ejemplos de distribuciones importantes: Definición y aplicaciones experimentales de las distribuciones Binomial, Multinomial, de Poisson, Normal, Exponencial, Gama, Log-normal y de Cauchy. Distribuciones de muestreo: chi-cuadrado, t de Student y función F.

4. Propagación de errores: Funciones de variables aleatorias. Aproximación lineal a la propagación de errores y método exacto. El rol de la matriz de covarianza. Composición de variables aleatorias. Función característica. Teorema central del límite y la aproximación gaussiana.

Capítulo 5

Teoría de Estimadores

5.1 Generalidades y Definiciones

5.1.1 Estimador

Definición (Muestra)
Se define la *muestra* al conjunto de realizaciones $\{X_i\}$ de un experimento. Las realizaciones X_i son variables aleatorias.

Definición (Estimador)
Sean X_i realizaciones de un experimento que siguen una determinada función de probabilidad dada por ciertos parámetros.
Se define como *estimador* a una variable aleatoria función de variables X_i (y no de los parámetros) tal que nos dé información sobre la función de probabilidad que sigue el experimento del cual proviene la muestra.

Agregar:

Ejemplo/Ejercicio: Estimador de la Esperanza: Media

Tomo una muestra y defino

$$\boxed{\bar{X} = \sum_{i=1}^{n} X_i} \qquad \text{(Estimador de la Esperanza)}$$

Las mediciones son independientes.

5.1.2 Consistencia

Teorema 5.1 (Ley de los Grandes Números)
Sea $\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$.
Entonces,

$$\lim_{n\to\infty} P(\left|\bar{X} - \mathrm{E}\left[X\right]\right| > c) = 0$$

Demostración.

Aplicamos el Teorema de Chebyshev a la variable aleatoria $\bar{X} = \sum_{i=1}^{n} x_i$.

$$P(\left|\bar{X} - \mathrm{E}\left[\bar{X}\right]\right| > c) \leq \frac{\mathrm{Var}\left(X\right)}{c^2}$$

$$\mathrm{E}\left[\bar{X}\right] = \mathrm{E}\left[\frac{\sum_{i=1}^{n} X_i}{n}\right]$$

Por la linealidad de la esperanza, y como las X_i son iid,

$$\boxed{\mathrm{E}\left[\bar{X}\right] = \mathrm{E}\left[X\right]}$$

$$\Rightarrow \mathrm{Var}\left(\bar{X}\right) = \mathrm{Var}\left(\frac{\sum_{i=1}^{n} X_i}{n}\right)$$

Por la linealidad de la esperanza, y como las X_i son iid,

$$\boxed{\mathrm{Var}\left(\bar{X}\right) = \frac{\mathrm{Var}\left(X\right)}{n}}$$

$$\begin{aligned}
P(\left|\bar{X} - \mathrm{E}\left[\bar{X}\right]\right| > c) &\leq \frac{\mathrm{Var}\left(X\right)}{c^2 n} \\
\lim_{n\to\infty} P(\left|\bar{X} - \mathrm{E}\left[\bar{X}\right]\right| > c) &\leq \lim_{n\to\infty} \frac{\mathrm{Var}\left(X\right)}{c^2 n} \\
\lim_{n\to\infty} P(\left|\bar{X} - \mathrm{E}\left[\bar{X}\right]\right| > c) &\leq 0 \\
\Rightarrow \boxed{\lim_{n\to\infty}\lim_{n\to\infty} P(\left|\bar{X} - \mathrm{E}\left[\bar{X}\right]\right| > c) = 0}
\end{aligned}$$

■

Definición (Consistencia)
Decimos que un estimador es *consistente* si cumple la Ley de los Grandes Números.

Es decir, sea $\tilde{X}$ el estimador en cuestión y p el parámetro de la distribución que pretende estimar será consistente si cumple

$$\lim_{n\to\infty} P(\left|\tilde{X} - p\right| > c) = 0 \tag{5.1}$$

La consistencia es la primer característica que le tenemos que pedir a un estimador. Describe el comportamiento asintótico.

Nota:

Puedo usar la desigualdad de Chebyshev y ver que la varianza tiende a 0 para probar consistencia.

5.1.3 Sesgo

Definición (Sesgo o *Bias*)
Sea $\tilde{X}$ un estimador de un parámetro p.
Se define el *sesgo* de $\tilde{X}$ como

$$b := \mathrm{E}\left[\tilde{X}\right] - p \tag{5.2}$$

Decimos que un estimador es no sesgado si

$$b = 0$$

Observación (Signo del sesgo)
El signo del sesgo determina si el estimador sobre/subestima el parámetro. Si es positivo, lo sobrestima; si es negativo, lo subestima.

Que el estimador no sea sesgado es lo segundo que debemos pedirle a un estimador. Describe el comportamiento para n finito.

Ejemplo/Ejercicio: Estimador de la Varianza (Ejercicio 2 - Guía 7)

Proponemos el siguiente estimador para la varianza.

$$\delta^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \bar{X})^2$$

Veamos si es consistente.

$$\mathrm{E}\left[\delta^2\right] = \mathrm{E}\left[\frac{\sum_{i=1}^{n}(X_i - \bar{X})^2}{n}\right]$$

$$\begin{aligned}
\sum_{i=1}^{n}(X_i - \bar{X})^2 &= \sum_{i=1}^{n} {X_i}^2 - 2X_i\bar{X} + \bar{X}^2 \\
&= \sum_{i=1}^{n} {X_i}^2 - 2\bar{X}\underbrace{\sum_{i=1}^{n} X_i}_{n\bar{X}} + \bar{X}^2 \sum_{i=1}^{n} 1 \\
&= \sum_{i=1}^{n} {X_i}^2 - \cancel{2}n\bar{X}^2 \cancel{+ \bar{X}^2 n}
\end{aligned}$$

$$\boxed{\sum_{i=1}^{n}(X_i - \bar{X})^2 = \left(\sum_{i=1}^{n} {X_i}^2\right) - n\bar{X}^2}$$

$$\mathrm{E}\left[\delta^2\right] = \mathrm{E}\left[\frac{\left(\sum_{i=1}^{n} {X_i}^2\right) - n\bar{X}^2}{n}\right]$$

Por linealidad de la esperanza para X_i independientes,

$$\begin{aligned}
&= \frac{1}{n}\left[\left(\sum_{i=1}^{n} \mathrm{E}\left[{X_i}^2\right]\right) - n\mathrm{E}\left[\bar{X}^2\right]\right] \\
&= \frac{1}{n}\left(\sum_{i=1}^{n} \mathrm{E}\left[{X_i}^2\right]\right) - \mathrm{E}\left[\bar{X}^2\right]
\end{aligned}$$

$$\mathrm{Var}\left(X\right) = \mathrm{E}\left[X^2\right] - \mathrm{E}\left[X\right]^2$$
$$\boxed{\mathrm{E}\left[X^2\right] = \mathrm{Var}\left(X\right) + \mathrm{E}\left[X\right]^2}$$

$$\mathrm{Var}\left(\bar{X}\right) = \mathrm{E}\left[\bar{X}^2\right] - \mathrm{E}\left[\bar{X}\right]^2$$

Por la cuenta que hicimos en la demostración de la Ley de los Grandes números,

$$\frac{\mathrm{Var}\left(X\right)}{n} = \mathrm{E}\left[\bar{X}^2\right] - \mathrm{E}\left[X\right]^2$$
$$\boxed{\mathrm{E}\left[\bar{X}^2\right] = \frac{\mathrm{Var}\left(X\right)}{n} + \mathrm{E}\left[X\right]^2}$$

Con la notación usual $\mu = \mathrm{E}\left[X\right]$ y $\sigma^2 = \mathrm{Var}\left(X\right)$,

$$\begin{aligned}
\mathrm{E}\left[\delta^2\right] &= \frac{1}{n}\left(\sum_{i=1}^{n} \mathrm{E}\left[\sigma^2 + \mu^2\right]\right) - \left(\frac{\sigma^2}{n} + \mu\right) \\
&= \cancel{\frac{1}{n}}\cancel{\sum_{i=1}^{n}}\left(\sigma^2 \cancel{+\mu^2}\right) - \frac{\sigma^2}{n}\cancel{-\mu^2} \\
\boxed{\mathrm{E}\left[\delta^2\right] = \sigma^2 - \frac{\sigma^2}{n}}
\end{aligned}$$

Nota:

Nunca vimos que era consistente. ¿Basta con ver que la esperanza tienda al parámetro?

Ahora, calculemos su sesgo.

$$\begin{aligned}
b &= \mathrm{E}\left[\delta^2\right] - \sigma^2 \\
&= \cancel{\sigma^2} - \frac{\sigma^2}{n}\cancel{-\sigma^2} \\
\boxed{b = -\frac{\sigma^2}{n}}
\end{aligned}$$

En este caso, corregir el sesgo del estimador es trivial.

$$\begin{aligned}
\mathrm{E}\left[\delta^2\right] &= \frac{n\sigma^2 - \sigma^2}{n} \\
&= \frac{n-1}{n}\sigma^2 \\
\frac{n}{n-1}\mathrm{E}\left[\delta^2\right] &= \sigma^2 \\
\boxed{\mathrm{E}\left[\frac{n}{n-1}\delta^2\right] = \sigma^2}
\end{aligned}$$

Definimos, entonces, el estimador s^2 como

$$\begin{aligned}
s^2 &= \frac{n}{n-1}\delta^2 \\
&= \frac{\cancel{n}}{n-1}\sum_{i=1}^{n}\frac{X_i - \bar{X}}{\cancel{n}} \\
\boxed{s^2 = \sum_{i=1}^{n}\frac{X_i - \bar{X}}{n-1}} & \qquad \text{(Estimador de la Varianza)}
\end{aligned}$$

Agregar:

Tabla doble entrada Consistencia/Sesgo con gráficos cualitativos

Hasta ahora, solo hablamos del comportamiento del valor medio de un estimador (asintótico y finito). Como vimos, tanto el estimador para la esperanza como el estimador para la varianza son consistentes y no sesgados.

Nota: Mediana y Promedio Recortado

En la teórica se dijo que la mediana es un estimador de la media y no veo por qué sería así. Tal vez se refería sólo a la distribución de Poisson, pero no veo que se cumpla tampoco.
También está el promedio recortado, que consiste en tirar los valores más altos y bajos, pero no veo como se puede escribir matemáticamente.

Si quisiéramos estimar el valor del parámetro de la Poisson, podríamos usar tanto el estimador de la esperanza como el estimador de la varianza, entre otros. ¿Cuál será más conveniente?

5.1.4 Verosimilitud

Definición (Verosimilitud o *Likelihood*)
Sea X una variable aleatoria con PDF $f(x \mid \boldsymbol{\theta})$.
Sea $\{X_i\}$ el conjunto de realizaciones de un experimento (iid).
Por lo tanto, $f(\mathbf{x} \mid \boldsymbol{\theta}) = \prod_{i=1}^{n} f(x_i \mid \boldsymbol{\theta})$.
Se define la *verosimilitud* L como una función de los parámetros Θ

$$L(\boldsymbol{\theta} \mid \mathbf{x}) := \prod_{i=1}^{n} f(x_i \mid \boldsymbol{\theta}) \tag{5.3}$$

Ejemplo/Ejercicio: Ejemplo: Función de Verosimilitud para una variable aleatoria con distribución exponencial

$$L(\theta \mid \mathbf{x}) = \prod_{i=1}^{n} \theta e^{-\theta x_i}$$

$$\boxed{L(\theta \mid \mathbf{x}) = \theta^n e^{-\theta \sum_{i=1}^{n} x_i}}$$

5.2 Eficiencia y Suficiencia

Agregar: Información de Fisher

Definir la *Información de Fisher* en algún momento.

5.2.1 Teorema de Cramér-Rao

Teorema 5.2 (Cota de Cramér-Rao)
Sea $t(\mathbf{X})$ un estimador **no sesgado** de una función del parámetro $h(\theta)$.
El rango de la variable X no depende del parámetro θ.
Entonces,

$$\mathrm{Var}\,(t) \geq \frac{(\partial_\theta h)^2}{\mathrm{E}\left[(\partial_\theta \ln L)^2\right]} \qquad \text{(Cota de Cramér-Rao)}$$

Puede reescribirse como

$$\mathrm{Var}\,(t) \geq \frac{(\partial_\theta h)^2}{-\mathrm{E}\left[\partial_\theta^2 \ln L\right]}$$

La igualdad vale si y solo si

$$\frac{\partial \ln L}{\partial \theta} = A(\theta)\left[t(\mathbf{x}) - h(\theta)\right]$$

Demostración.

$$\begin{aligned}\mathrm{E}\left[t(\mathbf{X})\right] &= \int t(\mathbf{x}) f(\mathbf{x} \mid \theta)\, d^n\mathbf{x} \\ &= \int t(\mathbf{x}) L(\theta \mid \mathbf{x})\, d^n\mathbf{x}\end{aligned}$$

Como t es un estimador no sesgado, $\mathrm{E}\left[t(\mathbf{X})\right] = h(\theta)$.

$$h(\theta) = \int t(\mathbf{x}) L(\theta \mid \mathbf{x})\, d^n\mathbf{x}$$

Derivo con respecto a θ. Como los límites de intergración no dependen de θ, por la regla de Leibniz,

$$\frac{\partial h}{\partial \theta} = \int t(\mathbf{x}) \frac{\partial L(\theta \mid \mathbf{x})}{\partial \theta}\, d^n\mathbf{x}$$

$$\boxed{\frac{\partial L(\theta \mid \mathbf{x})}{\partial \theta} = \frac{\partial \ln L}{\partial \theta} L(\theta \mid \mathbf{x})}$$

$$\boxed{\frac{\partial h}{\partial \theta} = \int t(\mathbf{x}) \frac{\partial \ln L}{\partial \theta} L(\theta \mid \mathbf{x})\, d^n\mathbf{x}}$$

Por otro lado,

$$\begin{aligned}\int f(\mathbf{x} \mid \theta)\, d^n\mathbf{x} &= 1 \\ \int L(\theta \mid \mathbf{x})\, d^n\mathbf{x} &= 1\end{aligned}$$

Derivo con respecto a θ. Como los límites de intergración no dependen de θ, por la regla de Leibniz,

$$\begin{aligned}\int \frac{\partial L(\theta \mid \mathbf{x})}{\partial \theta}\, d^n\mathbf{x} &= 0 \\ \int \frac{\partial \ln L}{\partial \theta} L\, d^n\mathbf{x} &= 0 \\ h(\theta) \int \frac{\partial \ln L}{\partial \theta} L\, d^n\mathbf{x} &= 0\end{aligned}$$

Como la integral es sobre $\mathbf{x}$,

$$\boxed{\int h(\theta) \frac{\partial \ln L}{\partial \theta} L\, d^n\mathbf{x} = 0}$$

Restando miembro a miembro las dos ecuaciones encuadradas.

$$\int \big(t(\mathbf{x}) - h(\theta)\big) \frac{\partial \ln(L)}{\partial \theta} L \, d^n\mathbf{x} = \frac{\partial h}{\partial \theta}$$
$$\left[\int \big(t(\mathbf{x}) - h(\theta)\big) \frac{\partial \ln(L)}{\partial \theta} L \, d^n\mathbf{x}\right]^2 = \left(\frac{\partial h}{\partial \theta}\right)^2$$

Desigualdad de Schartz

$$\left(\int f(x) g(x) \, dx\right)^2 \leq \int f^2(x) \, dx \int g^2(x) \, dx$$

La igualdad vale sii $g(x) \propto f(x)$.
Tomo

$$\begin{cases} f(x) = (t-h)\sqrt{L} \\ g(x) = \dfrac{\partial \ln L}{\partial \theta}\sqrt{L} \end{cases}$$

$$\left[\int \big(t(\mathbf{x}) - h(\theta)\big) \frac{\partial \ln(L)}{\partial \theta} L \, d^n\mathbf{x}\right]^2 \leq \int (t-h)^2 L \, d^n\mathbf{x} \int \left(\frac{\partial \ln L}{\partial \theta}\right)^2 L \, d^n\mathbf{x}$$

$$\int (t-h)^2 L \, d^n\mathbf{x} \int \left(\frac{\partial \ln L}{\partial \theta}\right)^2 L \, d^n\mathbf{x} \geq \left(\frac{\partial h}{\partial \theta}\right)^2$$
$$\mathrm{E}\left[(t-h)^2\right] \mathrm{E}\left[\left(\frac{\partial \ln L}{\partial \theta}\right)^2\right] \geq \left(\frac{\partial h}{\partial \theta}\right)^2$$

Como el estimador es no sesgado, $\mathrm{E}\left[t(X)\right] = h(\theta)$.

$$\mathrm{E}\left[(t - \mathrm{E}\left[t\right])^2\right] \mathrm{E}\left[\left(\frac{\partial \ln L}{\partial \theta}\right)^2\right] \geq \left(\frac{\partial h}{\partial \theta}\right)^2$$
$$\mathrm{Var}\left(t\right) \mathrm{E}\left[\left(\frac{\partial \ln L}{\partial \theta}\right)^2\right] \geq \left(\frac{\partial h}{\partial \theta}\right)^2$$
$$\boxed{\mathrm{Var}\left(t\right) \geq \frac{\left(\partial_\theta h\right)^2}{\mathrm{E}\left[\left(\partial_\theta \ln L\right)^2\right]}}$$

Falta ver que podemos reescribir el denominador.

Vimos que

$$0 = \int \frac{\partial \ln L}{\partial \theta} L \, d^n\mathbf{x}$$

Derivamos nuevamente respecto de θ.

$$\begin{aligned}
0 &= \int \frac{\partial^2 \ln L}{\partial \theta^2} L \, d^n\mathbf{x} + \int \frac{\partial \ln L}{\partial \theta} \frac{\partial L}{\partial \theta} \, d^n\mathbf{x} \\
0 &= \int \frac{\partial^2 \ln L}{\partial \theta^2} L \, d^n\mathbf{x} + \int \frac{\partial \ln L}{\partial \theta} \frac{\partial \ln L}{\partial \theta} L \, d^n\mathbf{x} \\
0 &= \int \frac{\partial^2 \ln L}{\partial \theta^2} L \, d^n\mathbf{x} + \int \left(\frac{\partial \ln L}{\partial \theta} \right)^2 L \, d^n\mathbf{x} \\
0 &= \mathrm{E}\left[\frac{\partial^2 \ln L}{\partial \theta^2} \right] + \mathrm{E}\left[\left(\frac{\partial \ln L}{\partial \theta} \right)^2 \right]
\end{aligned}$$

$$\boxed{\mathrm{E}\left[\left(\frac{\partial \ln L}{\partial \theta} \right)^2 \right] = -\mathrm{E}\left[\frac{\partial^2 \ln L}{\partial \theta^2} \right]}$$

■

5.2.2 Estimadores Óptimos y Eficiencia

Ejemplo/Ejercicio: Ejemplo: Aplicación del Teorema de Cramér-Rao para un estimador del μ de una distribución de Poisson.

En este caso,

$$h(\mu) = \mu$$
$$\Rightarrow \boxed{\frac{\partial h}{\partial \mu} = 1}$$

$$
\begin{aligned}
L(\mu \mid \mathbf{k}) &= \prod_{i=1}^{n} e^{-\mu} \frac{\mu^{k_i}}{k_i!} \\
\ln L &= \sum_{i=1}^{n} (-\mu + k_i \ln(\mu) - \ln(k_i!)) \\
\frac{\partial \ln L}{\partial \mu} &= \sum_{i=1}^{n} (-1 + k_i \frac{1}{\mu}) \\
\frac{\partial \ln L}{\partial \mu} &= -n + \frac{1}{\mu} \sum_{i=1}^{n} k_i \\
\frac{\partial^2 \ln L}{\partial \mu^2} &= -\frac{1}{\mu^2} \sum_{i=1}^{n} k_i \\
\mathrm{E}\left[\frac{\partial^2 \ln L}{\partial \mu^2}\right] &= \mathrm{E}\left[-\frac{1}{\mu^2} \sum_{i=1}^{n} X_i\right] \\
&= -\frac{1}{\mu^2} \mathrm{E}\left[\sum_{i=1}^{n} X_i\right]
\end{aligned}
$$

Por linealidad de la esperanza para X_i independientes,

$$
= -\frac{1}{\mu^2} \sum_{i=1}^{n} \mathrm{E}\left[X_i\right]
$$

Como los X_i son iid,

$$
\begin{aligned}
&= -\frac{n\mathrm{E}\left[X\right]}{\mu^2} \\
&= -\frac{n\cancel{\mu}}{\mu^{\cancel{2}}}
\end{aligned}
$$

$$
\boxed{-\mathrm{E}\left[\frac{\partial^2 \ln L}{\partial \mu^2}\right] = \frac{n}{\mu}}
$$

La Cota de Cramér-Rao queda

$$
\mathrm{Var}\left(t\right) = \frac{1}{\frac{n}{\mu}}
$$

$$
\boxed{\mathrm{Var}\left(t\right) = \frac{\mu}{n}}
$$

Veamos cuál es la varianza del estimador

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$$

$$\mathrm{Var}\left(\bar{X}\right) = \mathrm{Var}\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right)$$

$$\boxed{\mathrm{Var}\left(\bar{X}\right) = \frac{\mu}{n}}$$

Vemos que el estimador promedio $\bar{X}$ es un estimador óptimo del parámetro μ en la distribución de Poisson.

Observación: Existencia y Unicidad del estimador óptimo

- El estimador óptimo es único.
  Demostración.
  Sean t_1 y t_2 dos estimadores óptimos. Entonces,

$$\begin{cases} \dfrac{\partial \ln L}{\partial \theta} = A(\theta)\left[t_1(\mathbf{x}) - h(\theta)\right] \\ \dfrac{\partial \ln L}{\partial \theta} = A(\theta)\left[t_2(\mathbf{x}) - h(\theta)\right] \end{cases}$$

  Restando miembro a miembro,

$$0 = \cancel{A(\theta)}\,(t_1 - t_2)$$

$$\boxed{t_1 = t_2}$$

■

- No está garantizada la existencia de un estimador óptimo.

Ejemplo/Ejercicio: Estimador no sesgado del parámetro λ en la distribución exponencial

En este caso

$$h(\lambda) = \lambda$$

$$\Rightarrow \boxed{\frac{\partial h}{\partial \lambda} = 1}$$

Definimos el estimador de λ

$$T(\mathbf{X}) = \frac{n-1}{\sum_{i=1}^{n} X_i}$$

$$\begin{cases} \mathrm{E}\left[T\right] = \lambda \\ \mathrm{Var}\left(T\right) = \dfrac{\lambda^2}{n-1} \end{cases}$$

Veamos si es un estimador óptimo.

$$L(\lambda \mid \mathbf{x}) = \lambda^n e^{-\lambda \sum_{i=1} x_i}$$

$$\ln L = n \ln \lambda - \lambda \sum_{i=1}^{n} x_i$$

$$\frac{\partial \ln L}{\partial \lambda} = \frac{n}{\lambda} - \sum_{i=1}^{n} x_i$$

$$\frac{\partial^2 \ln L}{\partial \lambda^2} = -\frac{n}{\lambda^2}$$

$$-\mathrm{E}\left[\frac{\partial^2 \ln L}{\partial \lambda^2}\right] = \mathrm{E}\left[\frac{n}{\lambda^2}\right]$$

$$\boxed{-\mathrm{E}\left[\frac{\partial^2 \ln L}{\partial \lambda^2}\right] = \frac{n}{\lambda^2}}$$

La cota de Cramér-Rao queda

$$\mathrm{Var}\left(t\right) \geq \frac{1}{\frac{n}{\lambda^2}}$$

$$\boxed{\mathrm{Var}\left(t\right) \geq \frac{\lambda^2}{n}}$$

No es un estimador óptimo. ¿Existirá algún estimador óptimo para λ?

$$\frac{\partial \ln L}{\partial \lambda} = A(\lambda)\left[t(\mathbf{x}) - h(\lambda)\right]$$

Reemplazamos LHS por lo que vale en el caso de la distribución exponencial y $h(\lambda) = \lambda$.

$$\frac{n}{\lambda} - \sum_{i=1}^{n} x_i = A(\lambda)\left[t(\mathbf{x}) - \lambda\right]$$

$$-\frac{n}{\lambda^2}\left[\frac{\lambda^2}{n}\sum_{i=1}^{n} x_i - \lambda\right] = A(\lambda)\left[t(\mathbf{x}) - \lambda\right]$$

El estimador tendría que ser

$$t(\mathbf{X}) = \frac{\lambda^2}{n}\sum_{i=1}^{n} X_i$$

Pero esto no es posible dado a que sería una función de los parámetros. Volviendo a la ecuación anterior

$$\frac{n}{\lambda} - \sum_{i=1}^{n} x_i = A(\lambda)\left[t(\mathbf{x}) - \lambda\right]$$
$$-n\left[\frac{1}{n}\sum_{i=1}^{n} x_i - \frac{1}{\lambda}\right] = A(\lambda)\left[t(\mathbf{x}) - \lambda\right]$$

vemos que

$$t(\mathbf{X}) = \frac{1}{n}\sum_{i=1}^{n} X_i = \bar{X}$$

es un estimador óptimo de $h(\lambda) = \frac{1}{\lambda}$.

Corolario 5.2.1 (Estimador Óptimo)
Puedo usar la ecuación para construirme un estimador óptimo para alguna función del parámetro en cuestión.

Demostración.

$$\frac{\partial \ln L}{\partial \theta} = A(\theta)\left[t(\mathbf{x}) - h(\theta)\right]$$
$$\mathrm{E}\left[\frac{\partial \ln L}{\partial \theta}\right] = \mathrm{E}\left[A(\theta)\left[t(\mathbf{X}) - h(\theta)\right]\right]$$

$$\mathrm{E}\left[\frac{\partial \ln L}{\partial \theta}\right] = \int \frac{\partial \ln L}{\partial \theta} L \, d^n\mathbf{x}$$

Por la cuenta que ya hicimos antes,

$$\mathrm{E}\left[\frac{\partial \ln L}{\partial \theta}\right] = 0$$

$$0 = \mathrm{E}\left[\cancel{A(\theta)}\left[t(\mathbf{X}) - h(\theta)\right]\right]$$
$$\mathrm{E}\left[t\right] = \mathrm{E}\left[h(\theta)\right]$$
$$\boxed{\mathrm{E}\left[t\right] = h(\theta)}$$

■

Definición (Eficiencia)
Se define la eficiencia de un estimador T como

$$e(T) := \frac{\text{Var}_{\text{min}}}{\text{Var}\,(T)} \tag{5.4}$$

donde Var_{min} es la varianza mínima dada por la Cota de Cramér-Rao.

Corolario 5.2.2
Sea $h(\theta) = \theta$ y t un estimador óptimo de θ.
Entonces,

(a)
$$A(\theta) = \frac{1}{\text{Var}\,(t)}$$

En realidad, vale para $h(\theta)$ arbitrario

$$\boxed{A(\theta) = \frac{\frac{\partial h}{\partial \theta}}{\text{Var}\,(t)}}$$

(b)
$$A(\theta = t) = -\left.\frac{d^2 \ln L}{d\theta^2}\right|_{\theta=t}$$

Demostración.

(a) Para el caso $h(\theta) = \theta$:

$$\begin{aligned} \frac{\partial \ln L}{\partial \theta} &= A(\theta)\left[t(\mathbf{X}) - \theta\right] \\ \left(\frac{\partial \ln L}{\partial \theta}\right)^2 &= \left(A(\theta)\left[t(\mathbf{X}) - \theta\right]\right)^2 \end{aligned}$$

Tomando la esperanza con respecto a $f_{\mathbf{X}}$,

$$\begin{aligned} \text{E}\left[\left(\frac{\partial \ln L}{\partial \theta}\right)^2\right] &= A^2(\theta)\text{E}\left[\left[t(\mathbf{X}) - \theta\right]^2\right] \\ \text{E}\left[-\frac{\partial^2 \ln L}{\partial \theta^2}\right] &= A^2(\theta)\text{Var}\,(t) \end{aligned}$$

Como t es un estimador óptimo y $h(\theta) = \theta$,

$$\frac{1}{\mathrm{Var}\,(t)} = A^2(\theta)\mathrm{Var}\,(t)$$

Hay que tomar la solución positiva porque la varianza es positiva.

$$\boxed{A(\theta) = \frac{1}{\mathrm{Var}\,(t)}}$$

(b) Parto de la misma ecuación pero, en vez de elevarla al cuadrado, tomo la derivada wrt θ y evalúo en $\theta = t$.

■

Proposición 5.3
Mismas condiciones de que Cramér-Rao. Entonces,

$$\mathrm{E}\left[-\frac{d^2 \ln L}{d\theta^2}\right]\bigg|_{\theta=t} = -\left.\frac{d^2 \ln L}{d\theta^2}\right|_{\theta=t} \tag{5.5}$$

Demostración.

Se deduce inmediatamente del corolario anterior. ■

Teorema 5.4 (Teorema de Cramér-Rao (varios parámetros))
Sea $\boldsymbol{\theta}_k = \theta_k$ para $k = 1, \ldots, m$.
Sea $t_i(\mathbf{X})$ un estimador *no sesgado* de $h_i(\boldsymbol{\theta})$ para $i = 1, \ldots, n$.
Sea $\mathbb{I}$ la matriz dada por

$$\begin{aligned}\mathbb{I}_{kl} &= \mathrm{E}\left[\frac{\partial \ln L}{\partial \theta_k}\frac{\partial \ln L}{\partial \theta_l}\right] \\ &= \mathrm{E}\left[-\frac{\partial^2 \ln L}{\partial \theta_k \partial \theta_l}\right]\end{aligned}$$

Entonces,

$$\boxed{\mathrm{Cov}\,(t_i, t_j) \geq \sum_{k=1}^{m}\sum_{j=1}^{m}\frac{\partial h_i}{\partial \theta_k}\mathbb{I}_{kl}^{-1}\frac{\partial h_i}{\partial \theta_l}} \tag{5.6}$$

Definiendo

$$\mathbb{H}_{ik} = \frac{\partial h_i}{\partial \theta_k}$$

podemos reescribirlo como

$$\boxed{\Sigma \geq \mathbb{H}\mathbb{I}^{-1}\mathbb{H}^T} \tag{5.7}$$

donde el $\geq$ vale para cada elemento Σ_{ij}. En el caso que $h_i = \theta_i$ para $i, \ldots, m$.

$$\Sigma \geq \mathbb{I}^{-1} \tag{5.8}$$

5.2.3 Suficiencia

Definición (Estadístico)
Se define como *estadístico* a una variable aleatoria que solo sea función de las muestras.

> **Nota:**
>
> Como un estimador cualquiera. No sé para qué existe esa definición.

> **Nota:**
>
> Como que hay que ver como es la dependencia funcional de L con las X_i.
> Si $\frac{\partial L}{\partial \theta} = T(\mathbf{X})$ o, equivalentemente, $f(\mathbf{X} \mid \theta) = g(t(\mathbf{X}) \mid \theta)\, h(\mathbf{X})$,
> Entonces
> $$P(\mathbf{X} = \mathbf{x} \mid \theta \mid T(\mathbf{X}) = P(\mathbf{X} = \mathbf{x} \mid T(\mathbf{X})$$

Definición (Suficiencia)
Sea T un estadístico.
Decimos que T es un estadístico *suficiente* con respecto a un modelo y a un determinado parámetro de este si

$$P\left(\mathbf{X} = \mathbf{x} \mid \theta \mid T(\mathbf{X})\right) = P\left(\mathbf{X} = \mathbf{x} \mid T(\mathbf{X})\right) \tag{5.9}$$

> **Nota: ¿Definición Equivalente?**
>
> no existe otro estadístico que con la misma muestra pueda dar más información sobre ese parámetro.

Teorema 5.5 (de Factorización de Fisher-Neyman)
Sea $\{X_i\}$ una muestra de $X \sim f(x \mid \theta)$.
$T(\mathbf{X})$ es suficiente para θ si, y solo si,

$$\prod_{i=1}^{n} f(x_i \mid \theta) = g\left(T(\mathbf{X}) \mid \theta\right)\, h(\mathbf{X})$$

Demostración.

Escribimos explicitamente la dependencia de θ.

$$f_X(\mathbf{x}, \theta) = f_{\mathbf{X},t(\mathbf{X}}(\mathbf{x}, t(\mathbf{x}, \theta)$$

Por la definición de probabilidad condicional,

$$= f_{\mathbf{X}}(\mathbf{x}, \theta \mid t) f_{t(\mathbf{X}}(t(\mathbf{x}), \theta)$$

Si t es suficiente, por definición,

$$\boxed{f_X(\mathbf{x}, \theta) = f_{\mathbf{X}}(\mathbf{x} \mid t) f_{t(\mathbf{X}}(t(\mathbf{x}), \theta)}$$

Como t es un estadístico,

$$f_X(\mathbf{x}, \theta) = h(\mathbf{x}) g(t(\mathbf{x}), \theta)$$

■

Teorema 5.6 (de Blackwell-Rao)
Sea $T(\mathbf{X})$ un estimador de $h(\theta)$.
Si T es un estadístico suficiente para θ, entonces, es el de mayor eficiencia posible.

Observación (Función de un estimador suficicente es suficiente)
Sea T un estimador suficiente.
Entonces, $T' = g(T)$, es un estimador suficiente.

Definición (Familia Exponencial)
Decimos que $f(\mathbf{X} \mid \theta)$ es de *familia exponencial* si

$$f_{\mathbf{X}}(\mathbf{x} \mid \theta) = \exp\left[B(\theta)C(\mathbf{x}) + D(\theta) + E(\mathbf{x})\right] \tag{5.10}$$

Si tenemos s parámetros,

$$f_{\mathbf{X}}(\mathbf{x} \mid \boldsymbol{\theta}) = \exp\left[\sum_{j=1}^{s} B_j(\boldsymbol{\theta}) C_j(\mathbf{x}) + D(\boldsymbol{\theta}) + E(\mathbf{x})\right] \tag{5.11}$$

En los casos que nos ocupan en este capítulo, $\mathbf{X}_i = X_i$ es una realización de una variable aleatoria X, por lo tanto, $\{X_i\}$ son i.i.d.

Proposición 5.7 (Familia Exponencial $\Rightarrow$ Suficiencia)
Sea f de familia exponencial.
Entonces, $t = \sum_{i=1}^{n} C(x_i)$ es un estimador suficiente de θ.

Demostración.

$$\begin{cases} f_{\mathbf{X}}(\mathbf{x} \mid \theta) = \exp\left[B(\theta)C(\mathbf{X}) + D(\theta) + E(\mathbf{X})\right] \\ f_{\mathbf{X}}(\mathbf{x} \mid \theta) = \prod_{i=1}^{n} f_{X_i}(x_i \mid \theta) \end{cases}$$

y llegamos a

$$\begin{aligned} f_{\mathbf{X}}(\mathbf{x} \mid \theta) &= \prod_{i=1}^{n} \exp\left[B(\theta)C(x_i) + D(\theta)E(x_i)\right] \\ &= \exp\left[B(\theta)\sum_{i=1}^{n} C(x_i) + nD(\theta) + \sum_{i=1}^{n} E(x_i)\right] \\ &= \exp\left[B(\theta)\sum_{i=1}^{n} C(x_i) + nD(\theta)\right] \exp\left[\sum_{i=1}^{n} E(x_i)\right] \end{aligned}$$

Definiendo $t = \sum_{i=1}^{n} C(x_i)$ y

$$\begin{cases} g(t \mid \theta) = \exp\left[B(\theta)\sum_{i=1}^{n} C(x_i) + nD(\theta)\right] \\ h(\mathbf{X}) = \exp\left[\sum_{i=1}^{n} E(x_i)\right] \end{cases}$$

queda

$$\boxed{f_{\mathbf{X}}(\mathbf{x} \mid \theta) = g(t \mid \theta)h(\mathbf{X})}$$

■

Teorema 5.8 (Teorema de Darmois)
Vale la inversa de la proposición anterior.

Ejemplo/Ejercicio: Ejemplo: Distribución Binomial

Recordamos que

$$\begin{cases} \dfrac{\partial \ln L}{\partial \theta} = A(\theta)\,[t - h(\theta)] & \text{(Eficiencia Óptima)} \\ L = g(t \mid \theta)\, h(\mathbf{X}) & \text{(Suficiencia)} \end{cases}$$

Tomando el logaritmo natural y derivando respecto de θ, reescribimos la ecuación para la suficiencia como

$$\frac{\partial \ln L}{\partial \theta} = \frac{\partial \ln g(t \mid \theta)}{\partial \theta} \frac{\partial \ln L}{\partial \theta} \qquad = f(t, \theta)$$

Definiendo $f(t, \theta) = A(\theta)\,[t - h(\theta)]$, vemos que si un estimador es óptimo, entonces es suficiente.

Proposición 5.9 (Eficiencia Óptima $\Rightarrow$ Suficiencia)
Sea t un estimador óptimo.
Entonces, t es suficiente.

Demostración.

Demostrado en el párrafo anterior. ■

Observación: Notación

De aquí en más, notaremos $\hat{\theta}$ a un estimador del parámetro θ.

5.3 Temas del Programa

5. Inferencia de parámetros I: Teoría de estimadores. Propiedades generales: consistencia, convergencia, sesgo, eficiencia, suficiencia, y robustez. Información de Fisher y condición de Darmois para suficiencia. Teorema de Cramér-Rao, eficiencia y estimadores óptimos.

Capítulo 6

Estimadores de Máxima Verosimilitud y Cuadrados Mínimos

6.1 Estimador de Máxima Verosimilitud

Definición (Estimador de Máxima Verosimilitud (*MLE*))
Sea L la función verosimilitud de una muestra.
Se define el *estimador de máxima verosimilitud* al estimador $\hat{\theta}$ tal que

$$L(\hat{\theta} \mid \mathbf{X}) \geq L(\theta \mid \mathbf{X}) \tag{6.1}$$

Ejemplo/Ejercicio: MLE de la SD para una variable aleatoria Gaussiana

Asumimos μ conocido.

$$\boxed{\hat{\sigma} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(X_i - \mu)}}$$

Proposición 6.1 (Principio de Máxima Verosimilitud)
Veamos algunas propiedades que tienen los MLE.

(a) Consistencia

Demostración.

Falta.

Agregar:

Chebyshev.

■

(b) Invariancia Funcional

$$\widehat{h(\theta)} = h(\hat{\theta}) \tag{6.2}$$

Demostración.

Falta.

Agregar:

Frodesen.

■

(c) Si existen estimadores suficientes, el MLE será suficiente.

(d) Si existe un estimador óptimo, será el MLE.

(e) Propiedades Asintóticas

- Eficiencia óptima.
- $\hat{\theta} \sim N(\theta, \sqrt{\text{Var}_{\text{C-R}}})$.

Ejemplo/Ejercicio: MLE de μ para una variable aleatoria Gaussiana

Sea $\{X_i\}$ una muestra con $X_i \sim N(\mu, \sigma_i)$.
Asumimos σ_i conocido.
La verosimilitud está dada por

$$L(\mu \mid X_i) = \frac{1}{\sqrt{2\pi}^n \prod_{i=1}^n \sigma_i} e^{-\frac{1}{2}\sum_{i=1}^n \left(\frac{X_i-\mu}{\sigma_i}\right)^2}$$

Queremos maximizar L con respecto a μ. Tomando el logaritmo,

$$\begin{aligned}
\ln L &= -\frac{n}{2}\ln(2\pi) - \sum_{i=1}^{n}\ln(\sigma_i) - \frac{1}{2}\sum_{i=1}^{n}\left(\frac{X_i-\mu}{\sigma_i}\right)^2 \\
\frac{\partial \ln L}{\partial \mu} &= \cancel{-}\frac{\cancel{1}}{2}\sum_{i=1}^{n}\cancel{-2}\frac{X_i-\mu}{\sigma_i^2} \\
\frac{\partial \ln L}{\partial \mu} &= \sum_{i=1}^{n}\frac{X_i-\mu}{\sigma_i}
\end{aligned}$$

Igualamos la derivada a 0.

$$\begin{aligned}
0 &= \sum_{i=1}^{n}\left(\frac{X_i}{\sigma_i^2} - \frac{\hat{\mu}}{\sigma_i^2}\right) \\
\hat{\mu}\sum_{i=1}^{n}\frac{1}{\sigma_i^2} &= \sum_{i=1}^{n}\frac{X_i}{\sigma_i^2} \\
&\boxed{\hat{\mu} = \frac{\sum_{i=1}^{n}\frac{X_i}{\sigma_i^2}}{\sum_{i=1}^{n}\frac{1}{\sigma_i^2}}}
\end{aligned}$$

6.2 Cuadrados Mínimos

Observación:

Se llama cuadrados mínimos porque siempre quedan cuadrados porque estamos considerando errores Gaussianos.

Errores en Y. Supongamos que tenemos una muestra $\{X_i, Y_i)\}$.
Las variables Y_i tienen un error gaussiano y las variables X_i tienen error despreciable.
Supongamos que hay una relación funcional $y = h(x)$ entre x e y.
Entonces, podemos escribir $Y_i \sim N\left(h(X_i), \sigma_i\right)$.

La verosimilitud está dada por

$$L(\boldsymbol{\theta} \mid Y_i) = \frac{1}{\sqrt{2\pi}^n \prod_{i=1}^{n}\sigma_i} e^{-\frac{1}{2}\sum_{i=1}^{n}\left(\frac{Y_i - h(X_i|\boldsymbol{\theta})}{\sigma_i}\right)^2}$$

Queremos maximizar L con respecto a μ. Tomando el logaritmo,

$$\ln L = -\frac{n}{2}\ln(2\pi) - \sum_{i=1}^{n}\ln(\sigma_i) - \frac{1}{2}\sum_{i=1}^{n}\left(\frac{Y_i - h(X_i \mid \boldsymbol{\theta})}{\sigma_i}\right)^2$$

Notamos que los primeros 2 términos son constantes respecto de $\boldsymbol{\theta}$.

$$\begin{aligned}
\text{Maximizar} \ln L &\iff \text{Maximizar} -\frac{1}{2}\sum_{i=1}^{n}\left(\frac{Y_i - h(X_i \mid \boldsymbol{\theta})}{\sigma_i}\right)^2 \\
&\iff \text{Maximizar} -\sum_{i=1}^{n}\left(\frac{Y_i - h(X_i \mid \boldsymbol{\theta})}{\sigma_i}\right)^2 \\
&\iff \text{Minimizar} \sum_{i=1}^{n}\left(\frac{Y_i - h(X_i \mid \boldsymbol{\theta})}{\sigma_i}\right)^2 \\
\text{Maximizar} \ln L &\iff \text{Minimizar} \sum_{i=1}^{n}\left(\frac{Y_i - h(X_i \mid \boldsymbol{\theta})}{\sigma_i}\right)^2
\end{aligned}$$

Si la variable Y_i tiene errores gaussianos idénticos $\sigma_i = \sigma$ y $h(X_i \mid \boldsymbol{\theta})$ es una combinación lineal de los parámetros,

$$\boxed{\text{Estimación por Máxima Verosimilitud} \iff \text{Cuadrados Mínimos}}$$

Errores en X y en Y.

Seguímos suponiendo que X e Y son independientes, entonces,

$$\begin{aligned}
f_{XY}(x, y) &= f_X(x) f_Y(y) \\
f_{\mathbf{XY}}(\mathbf{x}, \mathbf{y}) &= \prod_{i=1}^{n} f_{X_i}(x_i) f_{Y_i}(y_i)
\end{aligned}$$

Consideremos errores Gaussianos no idénticos tanto en X como en Y.

$$= \prod_{i=1}^{n} N(\mu_{Xi}, \sigma_{Xi})\, N(\mu_{Yi}, \sigma_{Yi})$$

Dada la relación funcional $y = h(x)$,

$$\begin{aligned}
&= \prod_{i=1}^{n} N(\mu_{Xi}, \sigma_{Xi})\, N(h(\mu_{Xi}), \sigma_{Yi}) \\
L(\boldsymbol{\theta} \mid \mathbf{x}, \mathbf{y}) &= \prod_{i=1}^{n} N(\mu_{Xi}, \sigma_{Xi})\, N(h(\boldsymbol{\theta}, \mu_{Xi}), \sigma_{Yi})
\end{aligned}$$

Agregar: Cuentas

$$\boxed{\ln L = -\frac{1}{2}\left[\sum_{i=1}^{n}\left(\frac{x_i - \mu_{Xi}}{\sigma_{Xi}}\right)^2 + \sum_{i=1}^{n}\left(\frac{y_i - h(\mu_{Xi}, \boldsymbol{\theta})}{\sigma_{Xi}}\right)^2\right]}$$

6.2.1 Regresión Lineal

Errores Gaussianos en Y correlacionados.

$$L(\boldsymbol{\theta} \mid \mathbf{y}) = \frac{1}{\sqrt{2\pi}^n \det(\Sigma)} \exp\left[-\frac{1}{2}\left(\mathbf{y} - \boldsymbol{\mu}_\mathbf{Y}\right)^T \Sigma^{-1} \left(\mathbf{y} - \boldsymbol{\mu}_\mathbf{Y}\right)\right]$$

$$\ln L = -\frac{n}{2} \ln\left(2\pi \det(\Sigma)\right) - \frac{1}{2} S(\boldsymbol{\theta})$$

donde

$$S(\boldsymbol{\theta}) = \left(\mathbf{y} - \boldsymbol{\mu}_\mathbf{Y}\right)^T \Sigma^{-1} \left(\mathbf{y} - \boldsymbol{\mu}_\mathbf{Y}\right)$$

con $\mu_{Yi} = h(x_i, \boldsymbol{\theta})$.

Consideremos que h es lineal en $\boldsymbol{\theta}$. Es decir,

$$h(x_i, \boldsymbol{\theta}) = \sum_{j=1}^{k} \theta_j f_j(x_i)$$

Definimos la matriz $\mathbb{A}$ con elementos $A_{ij} = f_j(x_i)$ para poder escribir

$$\mathbb{A}\boldsymbol{\theta} = \boldsymbol{\mu}_\mathbf{Y}$$

Reemplazamos en la expresión para S.

$$\boxed{S(\boldsymbol{\theta}) = \left(\mathbf{y} - \mathbb{A}\boldsymbol{\theta}\right)^T \Sigma^{-1} \left(\mathbf{y} - \mathbb{A}\boldsymbol{\theta}\right)}$$

Agregar: Cuentas

Desarrollamos y derivamos respecto de θ_j.

$$\nabla S = 2\mathbb{A}^T \Sigma^{-1} \mathbb{A}\boldsymbol{\theta} - 2\mathbb{A}^T \Sigma^{-1} \mathbf{y}$$

Igualando LHS a 0 para encontrar el máximo.

$$\mathbb{A}^T \Sigma^{-1} \mathbb{A}\hat{\boldsymbol{\theta}} = \mathbb{A}^T \Sigma^{-1} \mathbf{y}$$

$$\boxed{\hat{\boldsymbol{\theta}} = \left(\mathbb{A}^T \Sigma^{-1} \mathbb{A}\right)^{-1} \mathbb{A}^T \Sigma^{-1} \mathbf{y}}$$

Definimos $\mathbb{C}$ tal que $\hat{\boldsymbol{\theta}} = \mathbb{C}\mathbf{y}$.

Agregar: Cuentas

Matriz de Covarianza.

Como los $\hat{\theta}_j$ son combinación lineal de los y_i, tenemos que la matriz de covarianza par los estimadores es

$$\Sigma_{\hat{\boldsymbol{\theta}}} = \mathbb{C}\Sigma\mathbb{C}^T$$

que puede reducirse a

$$\boxed{\Sigma_{\hat{\boldsymbol{\theta}}} = \left(\mathbb{A}^T\Sigma^{-1}\mathbb{A}\right)^{-1}}$$

Observación:

Los estimadores de los parámetros pueden estar correlacionados entre sí, aún cuando las mediciones no lo están.

Agregar: Los estimadores son no sesgados.

¿Eso no era una propiedad de todos los MLE?

Agregar: Minimización χ^2

El estadístico $S(\boldsymbol{\theta})$ tiene distribución χ^2_n. El estadístico $S(\hat{\boldsymbol{\theta}})$ tiene distribución χ^2_{n-k}.
Si el valor de S difiere mucho de lo esperado en esa distribución, hay alguna de las hipótesis que no se cumplen.

- La relación funcional $h = \sum_{j=1}^{k} \theta_j f_j$ no es adecuada.
- Los errores no son Gaussianos.
- Los errores son muy grandes (χ^2 chico) o muy pequeños (χ^2 grande).

No conozco los errores en y. Si no conozco los errores pero puedo suponerlos no correlacionados e iguales, tengo

$$\Sigma = \sigma^2\mathbb{1}$$

La fórmula para $\hat{\boldsymbol{\theta}}$ queda

$$\boxed{\hat{\boldsymbol{\theta}} = \mathbb{A}^{-1}\mathbf{y}}$$

Y, su matriz de covarianza

$$\boxed{\Sigma_{\hat{\boldsymbol{\theta}}} = \sigma^2\left(\mathbb{A}^T\mathbb{A}\right)^{-1}}$$

Además,

$$\mathrm{E}\left[S(\hat{\boldsymbol{\theta}}\right] = n - k$$

$$\mathrm{E}\left[\frac{\left(\mathbf{y} - \mathbb{A}\hat{\boldsymbol{\theta}}\right)^T \left(\mathbf{y} - \mathbb{A}\hat{\boldsymbol{\theta}}\right)}{\sigma^2}\right] = n - k$$

$$\boxed{\mathrm{E}\left[\frac{\left(\mathbf{y} - \mathbb{A}\hat{\boldsymbol{\theta}}\right)^T \left(\mathbf{y} - \mathbb{A}\hat{\boldsymbol{\theta}}\right)}{n - k}\right] = \sigma^2}$$

Y encontramos un estimador no sesgado de σ^2.

Observación:

En el caso del estimador de la varianza que vimos al comienzo del Capítulo 5, $h(\boldsymbol{\theta}, \mathbf{x}) = \theta$.

$$\widehat{\sigma^2} = \frac{\left(\mathbf{y} - \mathbb{A}\hat{\boldsymbol{\theta}}\right)^T \left(\mathbf{y} - \mathbb{A}\hat{\boldsymbol{\theta}}\right)}{n - k}$$

$$\boxed{\widehat{\sigma^2} = \frac{\sum_{i=1}^{n}(y_i - \hat{\theta})^2}{n - 1}}$$

El estimador de la varianza tiene el $n - 1$ en el denominador porque $k = 1$.

6.3 Temas del Programa

Estimadores de máxima verosimilitud, invarianza ante transformación de parámetros, propiedades asintóticas óptimas. Combinación de experimentos. Estimadores de cuadrados mínimos, teorema de Gauss-Markov, solución matricial exacta. Cuadrados mínimos con errores en ambas variables y con funciones no lineales.

Capítulo 7

Intervalos de Confianza

Definición (Cobertura (*Coverage*))
Sean $L(\mathbf{X})$ y $U(\mathbf{X})$ dos estadísticos tales que $L(\mathbf{X}) < U(\mathbf{X})$.
Se define la *cobertura* de un parámetro θ como la probabilidad de que de que el parámetro se encuentre en el intervalo $[L, U]$. Es decir,

$$\text{Cobertura} := P(\theta \in [L(\mathbf{X}), U(\mathbf{X})]) \tag{7.1}$$

Ejemplo/Ejercicio: Ejercicio 1 - Guía 8 (incisos a, b, c y d)

Sea $\{X_i\}_{i=1,\dots,n}$ una muestra de $X \sim U([0, \theta])$.
Definimos el estimador

$$Y = \max_{i=1,\dots,n} \{X_i\}$$

y los estadísticos

$$\begin{cases} L(\mathbf{X}) = aY \\ U(\mathbf{X}) = bY \end{cases}$$

con $b > a > 1$. También, podríamos definir los estadísticos

$$\begin{cases} L(\mathbf{X}) = Y + c \\ U(\mathbf{X}) = Y + d \end{cases}$$

con $d > c > 0$.
Por el resultado del Ejercicio 8.a - Guía 3, la PDF de Y es

$$f_Y(y) = \frac{ny^{n-1}}{\theta^n} \qquad y \in [0, \theta]$$

En particular,

$$f_Y(\theta) = \frac{n}{\theta}$$

Su CDF es

$$F_Y(y) = \left(\frac{y}{\theta}\right)^n$$

Ahora, calculemos la cobertura de θ para cada par de estadísticos. Comencemos por el segundo par.

$$\begin{aligned}
\text{Cobertura} &= P(\theta \in [Y+c, Y+d]) \\
&= P(Y \in [\theta - d, \theta - c]) \\
&= \left(\frac{\theta - c}{\theta}\right)^n - \left(\frac{\theta - d}{\theta}\right)^n
\end{aligned}$$

$$\boxed{\text{Cobertura} = \left(1 - \frac{c}{\theta}\right)^n - \left(1 - \frac{d}{\theta}\right)^n}$$

Nota: $d > \theta$

En este caso la cobertura va a depender de c, d, n y del propio parámetro θ. Notemos que si $d > \theta$, la fórmula no tiene sentido (probabilidad negativa). Supongo que esto es porque si $d > \theta$, la cobertura es trivialmente 1.

Para el primer par,

$$\boxed{\text{Cobertura} = \frac{1}{a^n} - \frac{1}{b^n}}$$

Vemos que en los casos donde la cobertura depende del parámetro, esta es insuficiente a la hora de decidir si el intervalo que tenemos es "bueno" o no. En el ejemplo anterior teníamos que

$$\lim_{\theta \to \infty} \text{Cobertura} = 0$$

En el segundo caso, la cobertura no dependía del parámetro, por lo que era posible determinar cuán "bueno" era el intervalo que habíamos elegido. Por eso, introducimos la siguiente definición.

Definición (Nivel de Confianza (*Confidence Level*))
Se define el *nivel de confianza* γ de un intervalo dado por dos estadísticos como el valor mínimo de su cobertura. Es decir,

$$\text{Nivel de Confianza} = \min_{\theta} \text{Cobertura} \tag{7.2}$$

Ejemplo/Ejercicio:

Siguiendo con el ejemplo anterior, consideremos el primer par de estadísticos. Tomemos $a = 1$.

$$\begin{cases} L(\mathbf{X}) = Y \\ U(\mathbf{X}) = bY \qquad b > 1 \end{cases}$$

Calculemos b en función del nivel de confianza γ.

La cobertura nos queda

$$\text{Cobertura} = 1 - \frac{1}{b^n}$$

En este caso, la cobertura no depende del parámetro θ. Por lo tanto, el mínimo respecto de θ es lo mismo el valor de la cobertura.

$$\gamma = 1 - \frac{1}{b^n}$$

$$\boxed{b = \frac{1}{\sqrt[n]{1-\gamma}}}$$

Para $\gamma = 0.95$ y $n = 10$,

$$b = 1.34$$

Ejemplo/Ejercicio: CI para μ de una distribución normal con σ conocido.

Para una distribución normal tenemos

$$P(\mu - \sigma < X < \mu + \sigma) = 0.68$$

que podemos reescribirlo como

$$P(X - \sigma < \mu < X + \sigma) = 0.68$$

Si llamamos

$$\begin{cases} L(X) = X - \sigma \\ U(X) = X + \sigma \end{cases}$$

encontramos el intervalo de confianza de $68\,\%$ para μ-

Nota: V

ale para 1 medición.
Si tuvieramos varias mediciones,

$$\begin{cases} X \to \bar{X} \\ \sigma \to \sqrt{\dfrac{\sigma}{\sqrt{n}}} \end{cases}$$

7.1 Temas del Programa

Intervalos frecuentistas. Recubrimiento. Estimación de la matriz de covariancia en la aproximación parabólica. Elipse de covarianza. Intervalos de confianza generales a partir de la función verosimilitud y determinación gráfica de estimadores y sus errores. Intervalos exactos y el cinturón de confianza de Neyman. Cotas superiores e inferiores. Feldman-Cousins. Incorporación de errores sistemáticos vía perfilado, Métodos de remuestreo: boostrap y jacknife.

Capítulo 8

Test de Hipótesis

Observación: Etimología: "Hipótesis Nula"

> El término hipótesis nula surge de las primeras aplicaciones agrícolas y médicas de la estadística. Con el fin de probar la efectividad de un nuevo fertilizante o un nuevo medicamento, la hipótesis de la cual se parte es que su aplicación no tiene efecto, es decir, no hay diferencia entre las muestras tratadas y las no tratadas.
>
> Wikipedia

Nota:

Por como están formuladas ciertas cosas, solo aplican a una región de rechazo definida como $\Omega = [T_C, +\infty)$.

Definición (Hipótesis Simple)
Se dice que una hipótesis H es *simple* cuando está completamente determinada.

Definición (Hipótesis Compuesta)
Se dice que una hipótesis H es *compuesta* cuando **no** está completamente determinada.

Ejemplo/Ejercicio:

$$\theta > C$$

Definición (Contraste / Prueba / *Test*)

Sea $\mathbf{X} \in \mathbb{R}^n$ una muestra y sea $T(\mathbf{X})$ un estadístico.
Sea $\Omega \in \mathbb{R}$ una región del espacio llamada *región de rechazo* o *región crítica*.
Se define una *prueba* δ como una función de la muestra tal que

$$\delta = \begin{cases} 1 & T(\mathbf{X}) \in \Omega \\ 0 & T(\mathbf{X}) \notin \Omega \end{cases} \tag{8.1}$$

tal que si

$$\delta = \begin{cases} 1 & \Rightarrow \text{rechazo } H_0 \\ 0 & \Rightarrow \text{acepto } H_0 \end{cases}$$

Observación:

Usar un estadístico hace que la región de rechazo Ω esté en $\mathbb{R}$ en lugar de en $\mathbb{R}^n$.

Definición (Nivel de Significancia)
Se define el *nivel de significancia* α como la probabilidad de rechazar la hipótesis nula H_0 siendo cierta. Es decir,

$$P(T \in \Omega \mid H_0) = \alpha$$
$$\int_\Omega f_{T|H_0}(t)\, dt = \alpha$$

Definición (Error Tipo I o Error α)
Se define como *error de Tipo I* α a la probabilidad de rechazar la hipótesis nula H_0 siendo cierta. Es decir,

$$P(T \in \Omega \mid H_0) = \alpha$$
$$\int_\Omega f_{T|H_0}(t)\, dt = \alpha$$

Nota:

Según entendí, el nivel de significancia y el error Tipo I son exactamente lo mismo.

Definición (Error Tipo II o Error β)
Se define como *error de Tipo II* β a la probabilidad de aceptar la hipótesis nula H_0

siendo falsa. Es decir,

$$P(T \notin \Omega \mid H_1) = \beta$$
$$\int_{\mathbb{R}-\Omega} f_{T|H_1}(t)\, dt = \beta$$

Definición (p-valor (*p-value*))
Se define el *p-valor* p como la probabilidad de tener una serie de realizaciones tanto o más incompatibles que la realizada. Es decir

$$p := \int_{T_{\text{medido}}}^{+\infty} f_{T|H_0}(t)\, dt \tag{8.2}$$

Nota:

Los límites de integración creo que dependen de cómo estemos definiendo la región de rechazo Ω.

Observación
Esta definición nos permite reformular la condición de aceptación/rechazo de la hipótesis nula como

$$\begin{cases} p < \alpha \Rightarrow \text{rechazo } H_0 \\ p > \alpha \Rightarrow \text{acepto } H_0 \end{cases}$$

Observación
El p-valor es una variable aleatoria.
Aún más, el p-valor sigue una distribución uniforme si la hipótesis nula H_0 es cierta.

Definición (Unidad Tipificada (*Standard Score*))
Se define la *unidad tipificada* z de una realización x como la desviación respecto de la media en unidades de la desviación estándar. Es decir,

$$z := \frac{x - \mu}{\sigma} \tag{8.3}$$

Si la media μ y la desviación estándar σ de la distribución de X no son conocidas, se usan la media $\bar{x}$ y desviación estándar s de la muestra.

$$z = \frac{x - \bar{x}}{s}$$

Definición (z-valor)
Si la distribución del estadístico T f_T puede aproximarse por una distribución normal $N(\mu, \sigma)$, escribiendo t en unidades tipificadas

$$z' = \frac{t - \mu}{\sigma}$$

$Z' \sim N(0, 1)$ Se define el *z-valor* z tal que

$$p = \int_z^{+\infty} N(0, 1)\, dz' \tag{8.4}$$

que puede reescribirse como

$$\begin{aligned} 1 - p &= \int_{-\infty}^{z} N(0, 1)\, dz' \\ 1 - p &= \mathrm{erf}(z) \\ &\boxed{z = \mathrm{erf}^{-1}(1 - p)} \end{aligned}$$

Nota:

Los límites de integración creo que dependen de cómo estemos definiendo la región de rechazo Ω.

Nota:

En la teórica dijeron que no hacía falta suponer que la distribución de T se pudiera aproximar por una normal y que esto era solamente una biyección entre p y z.

Bibliografía

[1] G. Bohm and G. Zech. *Introduction to Statistics and Data Analysis for Physicists*. 1st edition, 2010.

[2] G. Casella and R. L. Berger. *Statistical Inference*. Duxbury Advanced Series. Duxbury Thomson Learning, second edition, 2002.

[3] A. G. Frodesen, O. Skjeggestad, and H. Tofte. *Probability and Statistics in Particle Physics*. Columbia University Press, 1st edition, 1979.

[4] M. G. Kendall. *Advanced Theory of Statistics*, volume 1. Charles Griffin & Company Limited, 42 Drury Lane, London, second edition, 1945.

[5] M. G. Kendall. *Advanced Theory of Statistics*, volume 2. Charles Griffin & Company Limited, 42 Drury Lane, London, second edition, 1961.

[6] M. G. Kendall. *Advanced Theory of Statistics*, volume 3. Charles Griffin & Company Limited, 42 Drury Lane, London, second edition, 1966.